队伍编号	A MCB2100805
赛道	（A）

二手车估价及影响因素分析建模

摘　要

针对问题 1——二手车零售交易价格预测建模。首先，对数据进行探索与预处理，填补空缺值、删除异常值、对几个特征的数据分布进行对数处理使得数据满足大致的正态分布等。然后，建立线性模型、非线性模型数据集进行建模，通过回归模型的评测指标选取随机森林回归模型作为基准模型。最后，通过特征提取、特征选择等技术对数据集进一步的处理，再分别建立随机森林回归、XGBoost 回归、LightGBM 回归三个集成学习模型，并对模型的参数使用贝叶斯优化后得到初步的结果，三个优化后的模型在混合评价指标 Mape-Accuracy$_5$ 都有所提升，其中 LightGBM 回归提升最明显，提高了 8%。最终将优化后的三个模型进行加权融合建立融合模型，融合模型的三个评测指标得分分别为：Mape 为 0.0783、RMSE 为 2.1418、Mape-Accuracy$_5$ 为 0.5937。三个指标得分都比单一模型高，即采用融合模型预测测试集中二手车交易价格最优。

针对问题 2——影响二手车成交周期的关键因素分析建模。将数据集进行融合，并进行数据预处理和特征构造，将所有样本分为易交易和不易交易车辆，对于销售周期短的前 50%设置为易交易车辆，剩下的样本设置为不易交易车辆。将销售周期的关键因素挖掘转化为是否易交易的关键因素挖掘，从统计方法和机器学习模型两个角度进行挖掘。统计方法角度：对于每个类别特征，可视化每个类别上是否易交易的分布状况，若每个类别上的分布相似，则说明这个特征对是否易交易的影响不大，反之，这个特征对是否易交易的影响较大。结果表示，类别特征中，cityId 的影响比较大，brand、color 和 gearbox 的影响一般，其他类别特征的影响比较低。机器学习模型角度：利用树模型对特征重要性打分的特性，分别用随机森林分类模型、XGBoost 分类模型以及 LightGBM 分类模型对是否易交易进行拟合，LightGBM 的拟合效果最好，AUC 得分相对最高，为 0.6785。以 LightGBM 得出的特征重要性为基准 ，类别特征的重要

性与统计方法角度得出的结论一致，数值型特征中 newprice、mileage 和 used_time 的重要性较高。最后根据两种方法的结论，提出了 3 点建议。

针对问题 3——二手车保值率的影响因素分析。首先在问题一、二结论的基础上对二手车保值率产生影响的因素进行探索性分析，筛选出二手车保值率评估的备选指标。接着，通过对备选指标进行定性分析进而构建出二手车保值率的评估指标体系。最后，从统计模型和算法模型两个方面对二手车保值率高低的影响因素进行探索，应用 Logistic 回归模型和 XGBoost 模型对二手车保值率的影响因素进行定量分析，结果表明注册日期、上牌时间、上牌日期、厂商类型、国别、年款、品牌和燃油类型是对二手车的保值率高低产生影响的重要指标。

关键词：二手车估价、集成学习、融合模型、因素分析、保值率

目 录

1. 问题重述.....1

1.1 问题背景.....1

1.2 问题描述.....1

2. 问题分析.....2

2.1 针对问题 1 的分析.....2

2.2 针对问题 2 的分析.....3

2.3 针对问题三的分析.....4

3. 模型假设.....4

4. 符号定义与说明.....4

5. 问题 1：二手车零售交易价格预测建模..... 5

5.1 数据探索与数据处理.....5

5.1.1 处理缺失值.....5

5.1.2 异常值检测与处理.....6

5.1.3 探索数据分布情况.....6

5.2 特征工程.....8

5.2.1 特征提取.....8

5.2.2 特征选择.....8

5.3 模型建立.....10

5.3.1 基准模型的建立.....10

5.3.2 集成学习模型.....11

5.3.3 融合模型的建立.....15

5.3.4 模型结求解结果分析.....15

6. 问题 2：影响二手车成交周期的关键因素分析建模..... 16

6.1 数据探索与预处理.....16

6.1.1 异常值处理.....16

6.1.2 缺失值处理.....16

6.2 特征构造.....17

6.3 对销售周期影响的关键因素挖掘..... 18

6.3.1 基于统计特性的关键因素挖掘..... 18

6.3.2 基于模型的关键因素挖掘.....21

6.4 加快销售速度措施.....23

7. 问题 3：二手车保值率影响因素分析..... 24

7.1 数据来源.....24

7.2 二手车保值率影响因素的定性分析..... 25

7.3 二手车保值率的 Logistic 模型..... 26

7.3.1 Logistic 回归算法..... 26

7.3.2 Logistic 回归模型构建..... 26

7.3.3 影响因素分析.....30

7.4 二手车保值率的 XGBoost 模型..... 31

7.4.1 XGBoost 模型构建..... 31

7.4.2 影响因素分析.....32

7.5 小结.....33

8. 模型评价与推广.....34

参 考 文 献.....35

附录.....36

1. 问题重述

1.1 问题背景

随着我国居民的生活水平的不断提高，人们对机动车的需求量也在急剧增长。目前，我国的的二手车市场正处于飞速发展时期，随着互联网、人工智能技术的飞速发展，我国出现了较多的二手车交易平台为二手车交易带来了便捷、可靠的方式，扩大了市场交易份额[3]。二手车作为一种电商商品，具有“一车一况”的特性，使得二手车的交易要比一般的电商商品交易要复杂。如今二手车市场存在问题主要在：价格评估的合理性、信息不对称以及缺少信用、安全保障等，其中价格评估的合理性是二手车市场发展的主要问题。在实际生活中，二手车价格很难准确估计和设定，因为二手车受到各方面因素的影响，比如品牌、车系、车龄、行驶里程、过户次数以及价格变化等。目前国家没有一个二手车价值评价标准，二手车的的价值评估完全由二手车交易平台和二手车第三方估价平台都从自身的角度建立。

二手车的交易基本上采用的是一种 O2O 门店模式，这种模型主要是将二手车的信息通过互联网线上渠道发布，通过线下实体门店对外展销和售卖。对于购买用户和销售厂商来说,准确合理的估值价格能够同时满足消费者和商家的心理预期价位，促进交易快速顺利进行。在二手车交易行业中，商家掌握着车辆的交易价格，而消费者则手握交易决策权。针对交易而言，估值的最大作用就是通过用户和商家交易需求背景分析来有效降低估算过程中的逻辑错误风险和交易成本。本文基于以上的研究背景，通过构建数学模型来解决二手车交易相关问题。

1.2 问题描述

根据以上研究背景以及给定的数据集，本文需要解决研究如下三个问题：

问题 1：预二手车的零售交易价格

训练集“附件 1：估价训练数据”中包含了车辆的主要信息数据，共 36 列变量信息，根据已有的主要体特征，提取相关的特征，选用合适的模型方法对二手车交易价格进行估计，采用合适的评价准则对模型的优劣进行评估。再根据训练好的最优模型对“附件 2：估价验证数据”的二手车交易价格进行预测，将结果保存在至“附件 3：

估价模型结果”中，提交至竞赛平台。

问题 2：挖掘影响二手车辆成交周期的关键因素

在 O2O 门店模型中，车辆在被买主看中后会进入到门店的售卖阶段，车辆交易成功的关键因素是车辆本身是否受到消费者的青睐以及价格是否合理。根据“附件 4：门店交易训练数据”对车辆的成交周期进行分析，挖掘出影响车辆成交的影响因素。根据关键的影响因素提出相应的有效手段加快门店二手车辆的销售速度。并具体说明这些手段的的适用条件与预期的效果。

问题 3：二手车保值率影响因素分析

汽车保值率代表着一辆汽车生命周期内的价值曲线,消费者通过保值率能够进行更加理性的购车和用车。保值率所代表的含义并不单单指二手车在卖车时的残值，保值率高一方面代表了二手车流通量大，另一方面代表了消费者对于这款车在产品方面的认可。因此，本问拟根据给出的样本数据，对二手车保值率的影响因素进行分析研究，通过构建二手车保值率预测模型，帮助消费者对二手车进行全方面的认识。

2. 问题分析

2.1 针对问题 1 的分析

问题 1 的核心是构建回归预测模型对给定的二手车交易样本数据的零售价格进行预测。首先，对数据进行探索分析。给定的数据集中存在缺失值、异常值，对缺失值与异常值进行初步处理后，根据给定的特征建立线性模型以及随机森林非线性回归模型，对比模型的优劣，将得到较好结果的模型作为基准模型，并对该模型进行评价得到初步结果。然后，通过已有的特征以及问题背景构造有效特征，并对极端特征进行筛选、删除。最后根据构造的特征建立随机森林回归模型、XGB 回归模型、LGB 回归模型，通过贝叶斯分别优化三个模型的参数后将三个模型结果进行加权融合后得到最终的预测结果，然后最终预测结果与基准模型结果进行对比分析。具体的思路流程如下图所示：

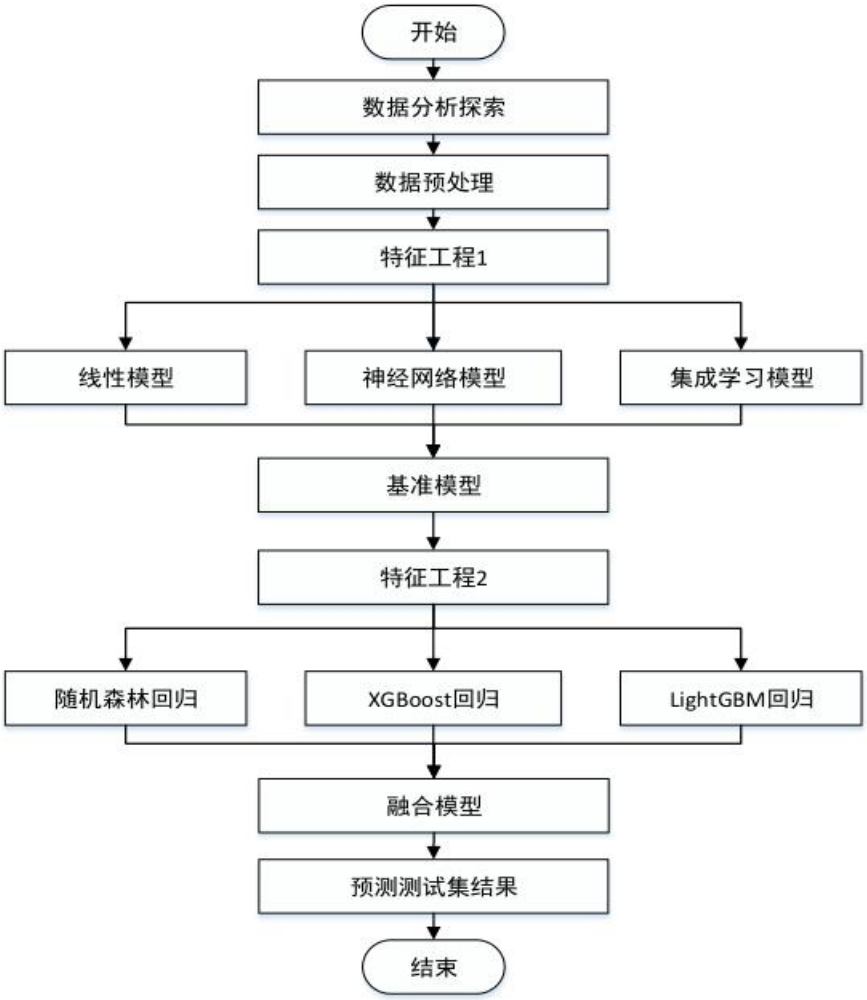


图 1 问题 1 思路流程图

2.2 针对问题 2 的分析

问题 2 在问题 1 数据的基础上给出了关于销售周期的特征，主要目的是挖出影响销售周期的关键影响因素。首先，将估价训练数据和门店交易数据进行融合，因为需要特征的实际意义，所以舍弃估价训练数据中的匿名特征。然后，对异常值和缺失值进行处理，并根据已有特征的实际意义构造一些新的特征。通过对数据探索，发现 10000 个样本中有 8000 是成功交易的样本，而剩下 2000 个样本没有交易直接下架。基于这种情况，将此问题视为一个二分类问题，将销售周期短的车辆划分为容易销售车辆，将销售周期长和没有售出的车辆划分为不容易销售车辆。最后，构建机器学习模型并结合一些描述性的分析挖掘影响销售的关键因素。

2.3 针对问题三的分析

本问拟研究二手车保值率的影响因素。首先，在问题一、二分析了二手车定价和销售周期的影响因素的基础上，得出评估二手车保值率的备选指标；其次，通过对这些备选指标的定性分析来研究二手车保值率影响因素的作用机制，进而构建二手车保值率的评价指标体系；最后，通过构建二手车保值率的预测模型，对二手车保值率影响因素进行定量分析。

3. 模型假设

根据已有的数据以及问题背景，在满足如下假设情况下分别对问题 1、问题 2 以及问题 3 进行建模分析。

假设 1：假设所有的二手车交易价格不考虑人为因素的影响。

假设 2：假设所有的二手车交易符合门店的交易规则，交易公平。

假设 3：假设二手车价格服从低于新车价格的实际规律。

4. 符号定义与说明

表 1 部分符号含义说明

符号	含义
used_time	使用时间
outdated_year	过时时间
quarter	交易所在季节
semiannual	交易是否在上半年
pull_quarter	下架所在季节
pull_semiannual	下架是否在上半年
easytrade	是否易交易
Ape	为相对误差
$Accuracy_5$	为 5%误差准确率

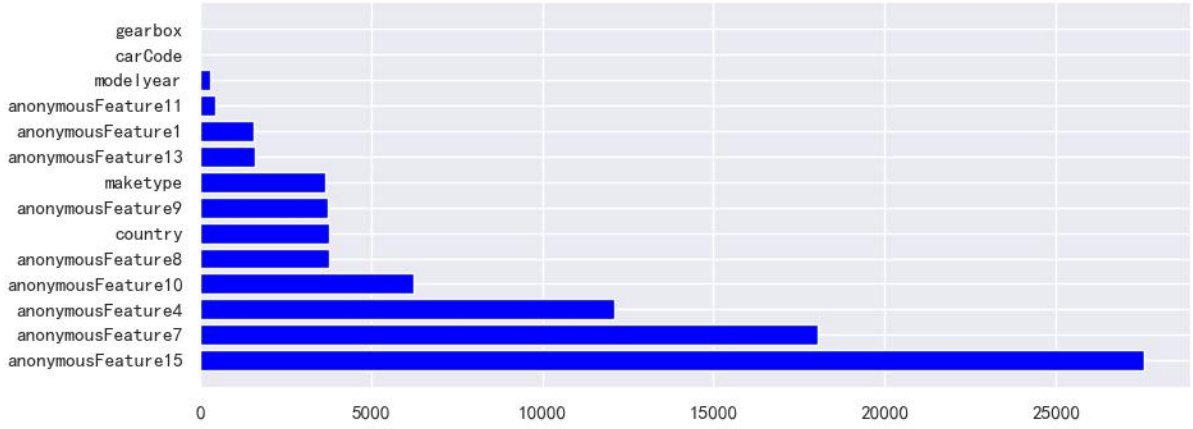
注:表中仅列举了部分符号与含义说明，其余的在文中右详细解释

5. 问题 1：二手车零售交易价格预测建模

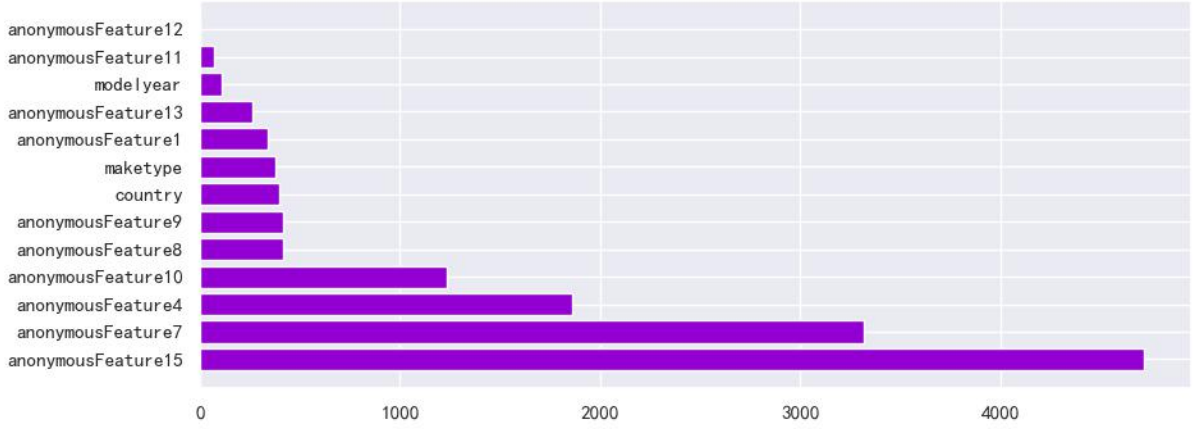
5.1 数据探索与数据处理

5.1.1 处理缺失值

问题 1 中给定的数据集中包含了训练集与测试集。其中，训练集包含了 30000 个样本、每个样本 36 个特征信息（包含价格标签）；测试集中包含了 5000 个样本、每个样本 35 个特征信息（不包含价格标签）。数据探索的第一步是对各个特征的数据缺失情况进行检测与处理，本文对训练集与测试集同时进行的检测，得到的缺失情况如下图所示：



（1）训练集中缺失值数量的特征排序图



（2）测试集中缺失值数量的特征排序图

图 2 训练集与测试集中部分特征的数据缺失情况

图 2 中（1）和（2）分别为训练集与测试集上缺失值数量的特征排序图，从图中

可以看出匿名特征 15、7、4、10、8 在训练集和测试集上都有大量的缺失值，说明数据整体在训练集和测试集上分布较为一致。其中，匿名特征 15、7、4 这三个特征的缺失情况比较严重，缺失的数量占总数的 1/3 以上，根据这三个特征很难反映出交易价格的分布规律，所以将这三个特征进行删除；modelyear 是反映时间的特征，可以寻找与其他时间特征的关系，发现 modelyear 与 rigsterDate 在同一年或者比早 1~2 年，所以选择用 rigisterDate 所在的年份对 modelyear 进行填充；gearbox 和 carCode 的缺失量非常少，只在训练集中有缺失，又因为它们都是类别特征，所以采用众数对其进行填充。其他特征的缺失值使用 KNN 分类方法进行填补。KNN 方法借助其他特征的分布来对目标特征进行缺失值填充，因为考虑了与其他特征的关系，所以 KNN 比固定值填补、均值填补等方法更可靠。

5.1.2 异常值检测与处理

（1） 极端值情况检测

首先对交易价格（标签）值进行异常值检测，通过查看最小的和最大的前 10 个数据，发现存在 109000（单位：万元），根据实际情况不存在这个价位的车，所以认定为异常值。但是并不是将其直接删除，而是根据实际情况进行改正，猜测可能是记录错误，109000 是 以元为单位，而数据集中所有的交易价格是以万元为单位的，所以在此基础上除以 10000，将该异常值修正为 10.9（单位：万元）。

（2） 结合实际规律检测

训练集中包含有新车价格以及二手交易价格，根据实际规律新车价格应该高于二手交易价格，并假设所有的二手车价格都是低于新车价格的。将二手交易价格与新车价格比较，发现有 193 个样本的交易价格大于新车价格，说明这 193 个样本属于异常值。由于不确定这 193 个样本新车价格与二手车交易价格的真实情况，为了便于后续的建模，将这 193 个样本直接剔除掉。

5.1.3 探索数据分布情况

为了防止建立的回归预测模型过拟合以及提高模型的泛化能力，需要对训练集以及的测试集的数据分布情况进行探索分析，力求保证数据集分布情况一致，并呈现出大致的正态分布。对数据集的原始特征进行分析，有大部分的特征都属于类别特征，类别特征的分析将在下一节特征工程中进行分析，这里仅仅探讨了里程、新车价格以

及交易价格三个特征的分布情况。根据原始数据，首先求出分别求出三个特征的峰度与偏度统计指标，得到的结果如下表所示。根据表中统计指标数据可知，三个指标都是尖峰，右偏分布，不满足正态分布。再将三个特征原始数据分别绘制三个特征的数据分布直方图，得到的结果如下图 3 所示：

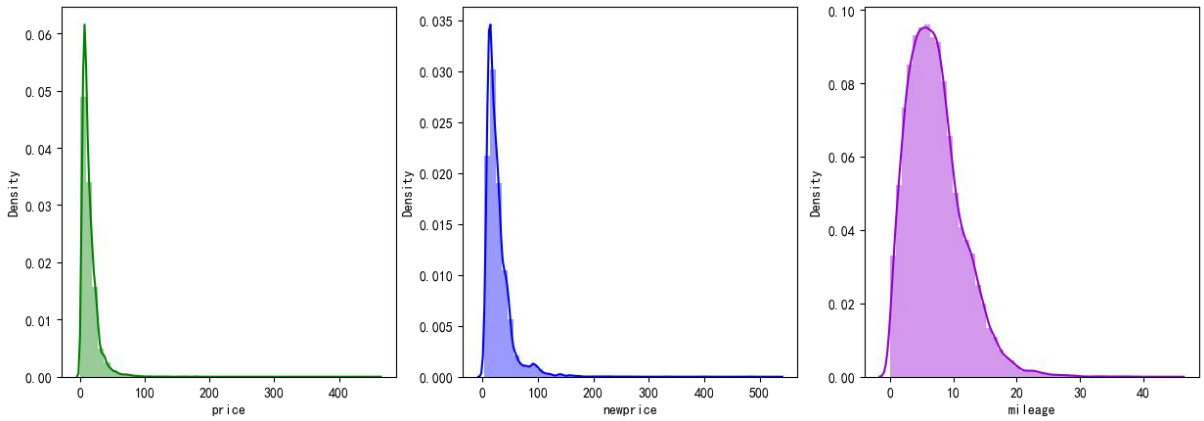


图 3 三个特征的数据分布情况

根据图中可以直观看出，三个特征的分布情况一致，都是尖峰、右偏分布，不满足正态分布情况。针对此情况需要对特征进行处理，使得特征大致满足正态分布。在这里对原始特征数据取对数，计算方式为：

$$x_{\ln_feature_i} = \ln(x_{feature_i} + 1) \tag{5.1}$$

其中，$x_{feature_i}$ 表示特征 i 的原始数据，$x_{\ln_feature_i}$ 表示特征 i 取对数后的数据，加 1 的作用是防止出现 0 或者无穷的情况。将取对数后的三个特征数据分别绘制三个特征的数据分布直方图，得到的结果如下图所示：

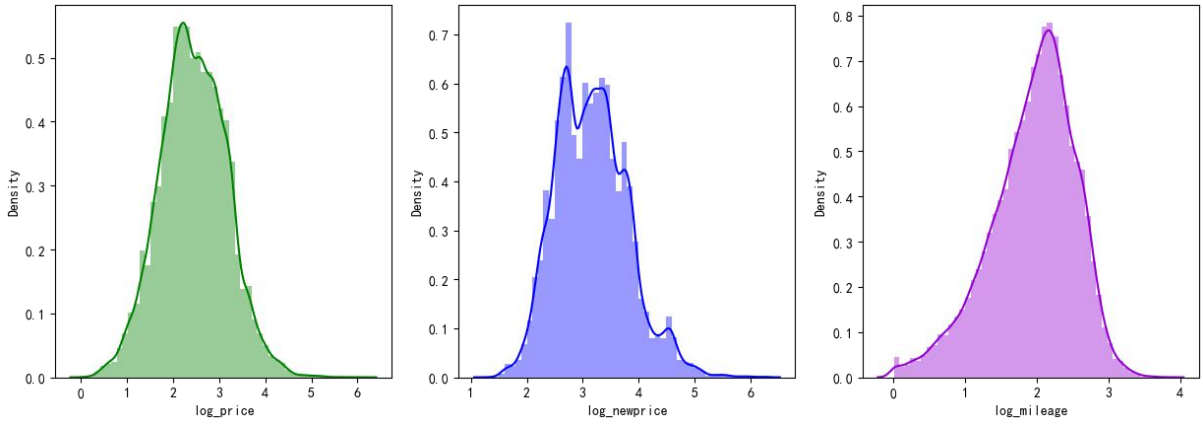


图 4 取对数后三个特征的数据分布情况

从上图 4 可以看出，三个特征经过取对数处理后，整体分布偏正态分布，有轻微

的尖峰分布，可以用于建立模型。

5.2 特征工程

5.2.1 特征提取

上一节中说明了原始数据集中包含了较多的分类特征，分类特征各个类型之间的差异在回归预测模型中的作用被缩小，所以本文对分类特征进行频数编码处理。频数编码是将某一类别出现的频数作为该类别的特征数据，数据的大小由频数决定，每个类别的频数差异较大，更有利于建立回归模型。

对于一些类别特征，可以采取目标编码的方式进行转换。目标编码需要用到目标变量 price，所以只能用到训练集数据对各个类别进行编码，测试集直接沿用训练集的编码结果，为了使得每个测试集特征的类别都有编码值，所以要保证测试集某特征的类别集合是测试集对应类别集合的子集。经过筛选，可以进行频率目标编码的非匿名特征有：color、carCode、transferCount、country、displacement、gearbox。将这些特征各个类别交易价 price 的最大值、最小值、中位数、总和、平均值和标准差作为新的特征加入。

根据数据探索部分，对数值型特征 newprice、mileage 进行对数变换，可以消除异方差的影响。

构造了新的特征之后可以将原来的特征删除，经过一系列的特征构造与删除，现有征数量为 61。

5.2.2 特征选择

特征构造中已经进行过类别特征编码，现在所有的特征的数字都具有大小关系，而不仅仅是标记作用。因为目标编码 price 是数值型变量，所以可以列出各个特征与 price 的相关性，删除相关性低的特征。由于特征数量较多，图 5 仅展示了与 price 相关性排名前 25 个特征的相关性热力图。对于一些相关性低的特征，可以删除，设定相关性阈值为 0.1，对于与 price 的相关性小于 0.1 的特征进行删除，一共删除了包括 color_price_min、carCode_amount 在内的 21 个特征，还剩下 40 个特征。

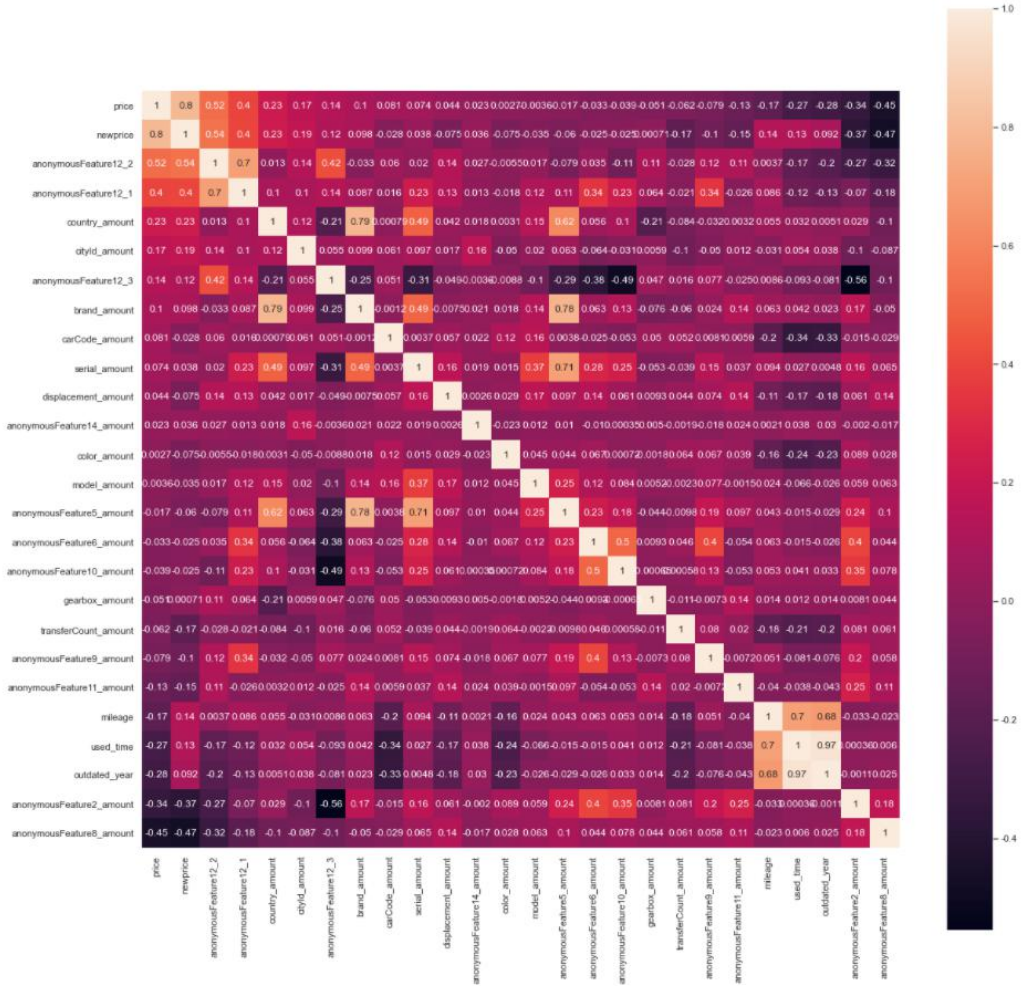


图 5 相关热力图

树模型有特征选择的功能，对经过相关性筛选特征后的数据进行随机森林回归模型拟合，得出每个特征的重要性如图 6 所示。

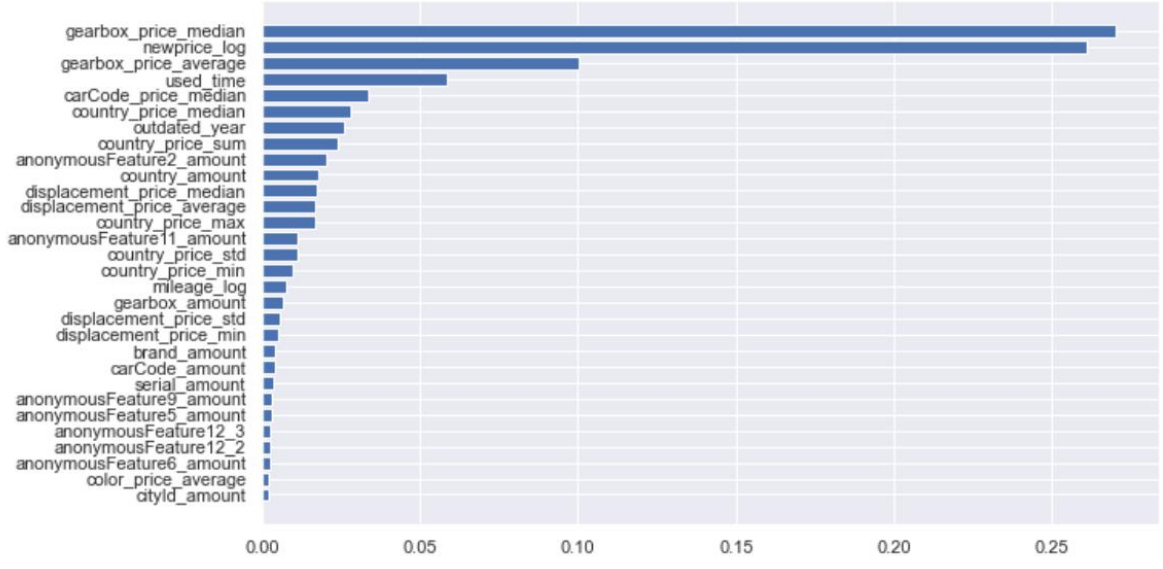


图 6 随机森林特征选择重要性

图 6 展示了随机森林模型各个特征的重要性排序，其中 gearbox_price_median、neworice_log、gearbox_price_average、used_time 的重要性较高，其他特征的重要性较低。图中只展示了 30 个特征的重要性，另外 10 个特征的重要性为 0，将特征重要性为 0 的特征删除，保留了 30 个特征。

5.3 模型建立

根据给定的数据集以及问题背景，在该问题中主要的建立回归预测模型对测试集二手车的交易价格进行预测。并利用评测回归模型额常用指标以及题目中要求的指标对模型优劣进行评价，得到最优的模型。

5.3.1 基准模型的建立

前面两节通过对数据集的探索与处理、并对特征进行提取与选择后得到新的数据集，利用新的数据集建立基准模型。首先，使用线性回归模型探索特征与交易价格之间的线性关系，得到初步的结果。然后，再利用非线性回归模型探索特征与交易价格之间的非线性关系，这里主要用到树模型。最后，对比线性模型与非线性模型的优劣，选出最优模型作为基准模型，在基准模型的基础上再继续进行优化。模型通过 Python3.8+,scikit-learn 来搭建，模型的性能利用平均相对误差（Mean absolute percentage error，Mape）、均方根误差（Root Mean Square Error，RMSE）以及题目中题目要求的混合评价指标，记为 Mape-Accuracy$_5$。其计算公式如下：

平均相对误差：

$$Mape = \frac{1}{m}\sum_{i=1}^{m} | \hat{y}_i - y_i | / y_i \tag{5.2}$$

均方根误差：

$$RMSE = \sqrt{\frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}} \tag{5.3}$$

混合评测 指标计算过程：

$$Ape = | \hat{y} - y | / y \tag{5.4}$$

$$Accuracy_5 = count_{Ape<=0.05} / n \tag{5.5}$$

$$Mape-Accuracy_5 = 0.2\times(1-Mape)+0.8\times Accuracy_5 \tag{5.6}$$

其中，y表示真实值、$\hat{y}$表示预测值；Ape为相对误差；$Accuracy_5$为5%误差准确率；$count_{Ape<=0.05}$表示相对误差Ape在5%以内的样本数量，n为总的样本数量。

根据数据集建立机器学习模型，得到各个模型的评价指标结果如下表所示：

表 2 线性模型与非线性模型的评测结果

模型	Mape	RMSE	Mape-Accuracy$_5$
LinearRegrssion	0.1517	4.0022	0.3659
Ridge	0.1517	4.0044	0.3658
RandomForestRegressor	0.0881	2.2731	0.5422
XGBRegressor	0.0907	2.2731	0.5222
LGBMRegressor	0.9580	2.5508	0.4881

根据上表 2 可以看出，线性回归模型的 Mape、RMSE 均高于集成树模型，Mape-Accuracy 均低于集成回归树模型，集成回归树模型的三个评测指标得分都比线性模型高，说明线性非线性回归模型要优于线性回归模型。对比三个集成回归树模型来看，随机森林回归模型的混合评测指标 Mape-Accuracy 得分高于 XGB 与 LGB 回归模型。所以将随机森林回归模型作为基准模型，接下来参考随机森林得到的结果进行优化改进。

5.3.2 集成学习模型

1、随机森林回归模型

（1）模型建立

随机森林（Random Forest）[1]是以决策树为基学习器模型构建 Bagging 集成模型。并且在基学习器决策树训练过程中引入了随机属性的选择，也即是在结点处划分属性时，在当时结点的属性集合中随机选择一个包含个属性的子集，通常情况下为特征总数。然后再从这个子集中选择一个最优的属性，相对于传统的决策树来说增加了一个随机选择属性子集的过程[7]。输入待测的分类样本后，由决策树进行投票决定输出的分类结果。如图 1 随机森林分类过程所示：

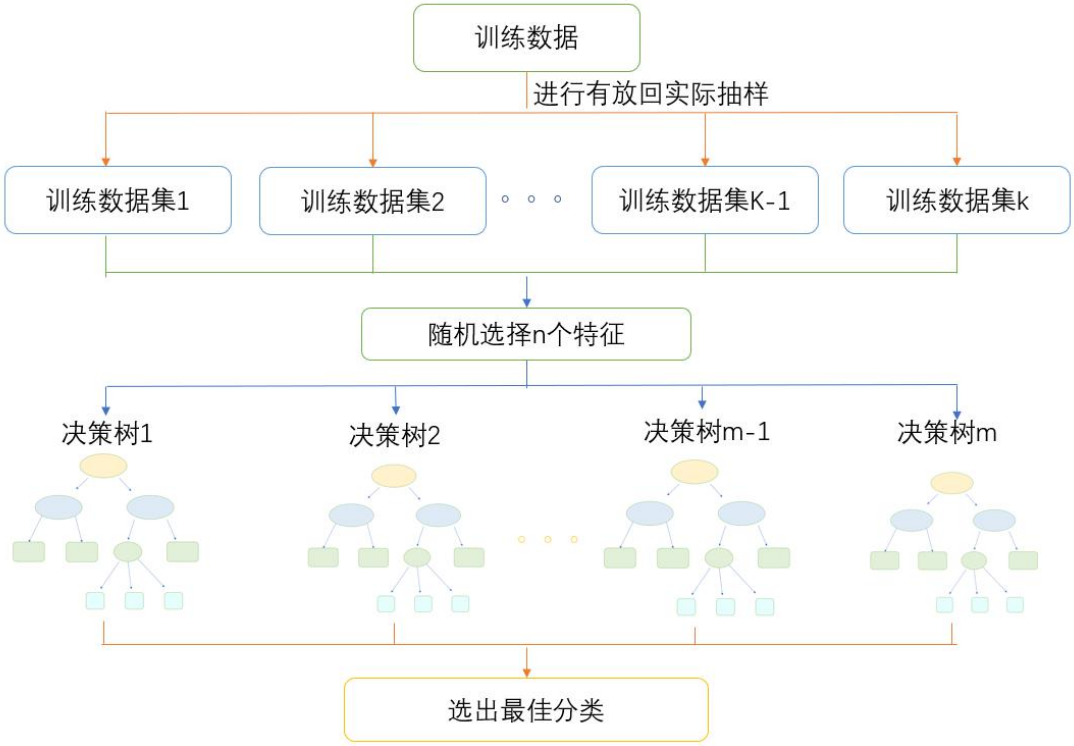


图 7 随机森林分类过程

（2）优化模型以及模型评价结果

根据以上随机森林算法原理建立了随机森林回归模型，得到的初步结果后，在这里对模型进行优化，主要是采用贝叶斯优化算法对模型的参数进行自动搜索得到最优参数。贝叶斯优化的原理：充分利用之前的信息，通过对目标函数的形状进行学习，找到使得目标函数达到全局最优的参数。基本步骤为：首先，根据先验信息分布，假设一个搜索函数；然后每一次都使用新的采样点来测试目标函数，利用这个信息来更新目标函数的先验分布；最后，通过算法测试后验分布给出的全局最值最可能出现的位置点。贝叶斯优化在探索和利用之间找到平衡点，避免陷入局部最优。

根据以上模型的建立与优化结果，对测试集进行预测，将结果保存为初步结果（result1）。模型在验证集上得到随机森林回归模型优化后的指标评测结果如下表 3 所示：

表 3 优化后随机森林回归模型的评测结果

模型	Mape	RMSE	Mape-Accuracy$_5$
RandomForestRegressor	0.0866	2.4000	0.5600

经过优化后，随机森林回归模型的评测指标得分情况为：Mape 从 0.0881 下降到 0.0866；RMSE 从 2.27 提高到了 2.4000；综合得分 Mape-Accuracy$_5$ 从 0.5422 提高到

0.56，提高了 2%。虽然 RMSE 提高了，但是总体的得分提高，说明优化后模型的性能得到提升。

2、XGBoost 回归模型

（1）模型建立

XGBoost[2]是基于梯度提升树 GBDT 的思想，对 GBDT 模型的优化，是一种集成回归树模型，可以用来做回归预测和分类预测等问题，目前也是运用比较强广泛的机器学习模型。其基本的原理是单一树的线性加权求和，其模型的复杂度是根据树的个数来决定的，所有树结点的预测误差为模型的损失。机器学习模型的常用目标函数为表达式为：

$$O(\Theta) = L(\Theta) + \Omega(\Theta) \tag{7}$$

其中，$O(\Theta)$ 为目标函数；$L(\Theta)$ 为模型训练损失，常用的损失函数有平方误差损失和逻辑斯蒂函数损失，用来评估模型的优劣；$\Omega(\Theta)$ 为正则化项，常用的有 Lasso 回归和 L2 范式，用来评估模型的复杂度；Θ 为样本空间。

XGBoost 是基于单一树模型进行线性加权集成，模型的训练过程采用加法训练，根据目标函数，模型从常数项开始，逐次加入一个新的函数迭代更新。其预测原理是：某时刻的预测值是前一时刻的预测值与该时刻的函数之和。其目标函数的详细表达式为：

$$O^{(t)} = \sum_{i=1}^{n} l(y_i, \hat{y}_i^{(t)}) + \sum_{i=1}^{t} \Omega(f_i) = \sum_{i=1}^{n} l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) + c \tag{8}$$

其中，$\sum_{i=1}^{n} l(y_i, \hat{y}_i^{(t)}) = \sum_{i=1}^{n} (y_i - \hat{y}_i^{(t)})^2$ 为平方损失函数；$\sum_{i=1}^{t} \Omega(f_i)$ 为正则化项；c 为常数项；f_t 表示 t 时刻的函数。该原理就是通过寻找最优的函数 f_t 来最小化目标函数 $O^{(t)}$。

损失函数采用泰勒定理来求解可以得到近似结果。定义 $g_i = \partial_{\hat{y}^{(t-1)}} l(y_i, \hat{y}^{(t-1)})$ 表示损失函数对预测值的一阶偏导，$h_i = \partial^2_{\hat{y}^{(t-1)}} l(y_i, \hat{y}^{(t-1)})$ 表示损失函数对预测值的二阶阶偏导。根据泰勒定理，泰勒公式为：

$$f(x + \Delta x) \approx f(x) + f'(x)\Delta x + \frac{1}{2} f''(x)\Delta x^2 \tag{9}$$

利用此公式可以将目标函数表示成如下形式：

$$O^{(t)}=\sum_{i=1}^{n}[g_i f_t(x_i)+\frac{1}{2}h_i f_t^2(x_i)]+\Omega(f_t) \tag{10}$$

树模型的复杂度定义为:$\Omega(f_t)=\gamma T+\frac{1}{2}\lambda\sum_{j=1}^{T}w_j^2$,其中，T 为树的深度，w_j^2 为叶子节点得分。利用复杂度公式中参数的变化更新目标函数，再进行学习与优化。本问继续使用 XGBoost 模型对二手车交易价格进行预测。

（2）优化模型以及模型评价结果

同样将建立的 XGB 回归模型进行参数优化后对测试集进行预测，保存为初步结果（result2），优化后的模型评测结果如下表 4 所示：

表 4 优化后 XGB 回归模型评测结果

模型	Mape	RMSE	Mape-Accuracy$_5$
XGBRegressor	0.0800	2.4000	0.5845

经过优化后，XGB 回归模型的评测指标得分情况为：Mape 从 0.0907 下降到 0.0800；RMSE 从 2.2731 提高到了 2.4000；综合得分 Mape-Accuracy$_5$ 从 0.5222 提高到 0.5845，提高了 6%。虽然 RMSE 提高了，但是总体的得分提高了，说明优化后模型的性能得到提升。

3、LightGBM 回归模型

LightGBM 模型与 XGBoost 模型一样都是基于 GBDT 思想的实现的集成树模型，两者的原理类似，这里不再介绍该模型的原理。但是由于 LightGBM 使用的算法与 XGBoost 不同，不需要进行预先的排序，所以该模型比 XGBoost 运行效率更高、更节省空间。Light GBM 模型得到的结果保存为初步结果（result3），模型评测结果如下表 5 所示：

表 5 优化后 LGB 回归模型评测结果

模型	Mape	RMSE	Mape-Accuracy$_5$
LGBMRegressor	0.0807	2.7797	0.5749

经过优化后，XGB 回归模型的评测指标得分情况为：Mape 从 0.0958 下降到 0.0807；RMSE 从 2.5508 提高到了 2.7797；综合得分 Mape-Accuracy$_5$ 从 0.4881 提高到 0.5749，提高了 8%。虽然 RMSE 提高了，但是总体的得分提高了 8%，说明优化后模型的性能得到提升。

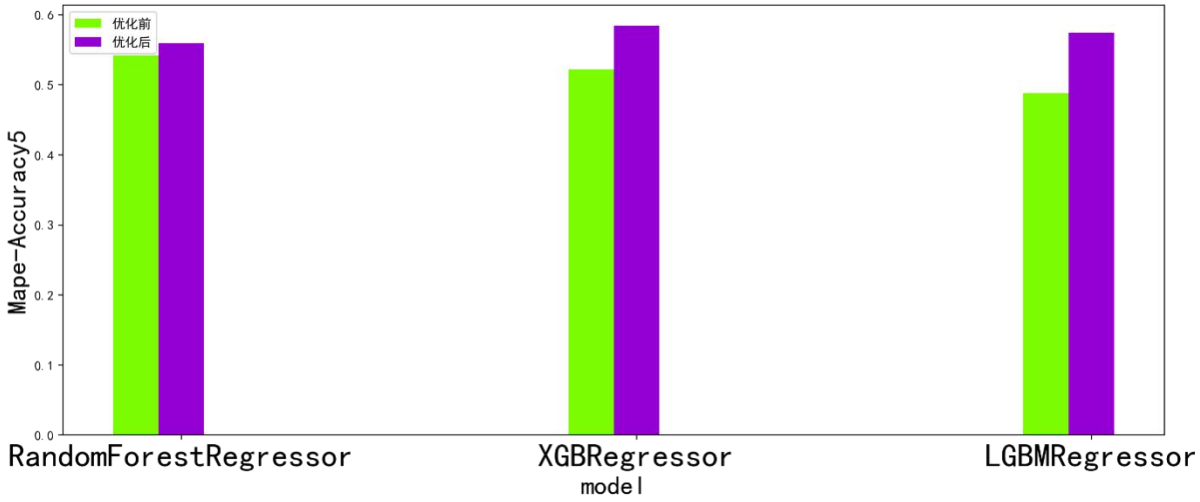


图 8 三个集成模型优化前后的评测对比图

上图 8 为三个模型在优化前后混合评测指标值的对比，从图中可以看出三个模型在优化后都有所提升，LGB 回归模型提升最明显。

5.3.3 融合模型的建立

根据以上建立的三个集成模型得到的初步结果，这里我们采用融合的方式对以上三个模型进行融合，采用加权融合的方法，具体的模型如下所示：

$$result = \beta_1 \cdot result_1 + \beta_2 \cdot result_2 + \beta_3 \cdot result_3 \tag{5.11}$$

其中 β_1、β_2、β_3 位权重系数，经过调试学习，得到最好的权重组合为：β_1=0.1、β_2=0.7、β_3 = 0.2；*result* 为最终预测的结果，并将结果保存至文件“估价模型结果.txt”中，提交至平台。

5.3.4 模型结求解结果分析

这里我们将对比分析以上建立的三个集成模型与融合模型的评测结果，评测结果如下表 6 所示：

表 6 融合模型与优化后的三个集成模型评测结果对比

模型	Mape	RMSE	Mape-Accuracy$_5$
RandomForestRegressor	0.0866	2.4000	0.5600
XGBRegressor	0.0800	2.4000	0.5845
LGBMRegressor	0.0807	2.7797	0.5749
融合模型	0.0783	2.1418	0.5937

根据前面所述，经过优化后，三个集成模型在基准模型的基础上都有所提升。将

三个优化的模型按照融合的方式融合后得到的融合模型的评测结果为：Mape 为 0.0783，比三个集成模型的都要低；RMSE 为 2.1418，比三个集成模型的都要低；综合得分 Mape-Accuracy$_5$ 为 0.5937，比三个集成模型的都要高。三个指标都是融合模型优于单一模型，说明融合后的模型对二手车的预测更加准确。

6. 问题 2：影响二手车成交周期的关键因素分析建模

6.1 数据探索与预处理

本题在问题 1 使用的估价训练数据的基础上增加了门店交易数据，包含了上架时间、上架价格、下架时间、成交时间以及价格调整过程。将估价训练数据和门店交易数据进行融合，估价训练数据中一共有 30000 条样本，门店交易数据中一共有 10000 条数据，根据 carid 列，门店交易数据中每一条样本都能在估价训练数据中找到对应的信息。因为本题要考虑特征的实际意义，因此对于估计训练数据中的匿名特征可以进行剔除。对于门店交易数据中的价格调整过程，由于数据记录格式的问题，不能直接为模型所用，必须对其进行一些转化，提取出价格变动次数和价格变动差值，再将价格调整过程删除。

6.1.1 异常值处理

对比 price 和 newprice，发现有 48 个样本存在 price 大于 newprice 的情况，二手车交易价格大于新车价格，与现实情况相悖，对于这 48 个样本直接进行剔除。

查看 country 的分布，发先少数样本标记非国家编码，而是 0，所以先将 country 为 0 的替换为缺失值，之后再进行缺失值填补。

6.1.2 缺失值处理

对于特征缺失值进行可视化，结果如图 9 所示。

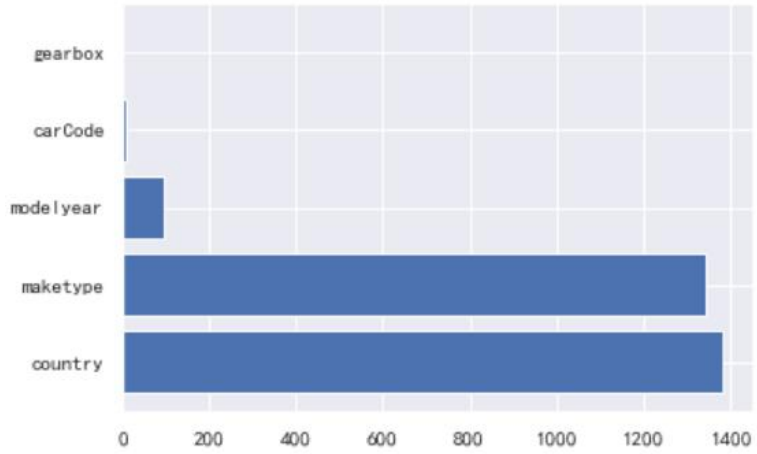


图 9 问题 2 特征缺失情况

观察图 9，一共有 5 个特征有缺失情况，其中 country 和 maketype 缺失较严重，但是总样本数量为 9952，而 country 和 maketype 的缺失值不超过 1400，可以进行填补，为了填补更加准确，选择 KNN 进行填充；gearbox 和 carCode 的缺失样本比较少，由于它们都分类特征，所以选择众数进行填充；modelyear 是表示时间的特征，与其他时间特征存在一定的关系，所以可以通过其他时间特征进行填充。

（1） 时间特征填充

有 96 个样本的 modelyear 缺失，观察 modelyear 和其他时间特征关系，发现 modelyear 跟 registerDate 大多在同一年或者比早 1~2 年，选择用 registerDate 的年份来填充 modelyear。

（2）众数填充

有 6 个样本的 carCode 缺失，1 个样本的 gearbox 缺失，缺失量非常少，又因为它们是类别特征，选择用众数进行填充。

（3）KNN 填充

有 1384 个样本的 country 缺失，有 1345 个样本的 maketype 缺失，缺失量较大，选着 KNN 进行填充。KNN 的临近值个数取 5，且因为 country 和 maketype 和是类别特征，所以选着最近 5 个样本的众数进行填充。

6.2 特征构造

本题中的特征分为时间特征、类别特征、数值特征，对于每种特征都有不同的处理方式。

（1）时间特征

目前具有的时间特征有 tradeTime，registerDate，modelyear，pushDate，pullDate，可以在这些特征的基础上构造一些新的特征：

used_time 表示车辆使用时间，由 tradeTime 减去 registerDate 得到；

outdated_year 表示车辆过时程度，由 tradeTime 所在年份减去 modelyear 得到；

display_time 表示车辆展示的时间长短，由 pullDate 减去 pushDate 得到；

pull_quarter 表示下架季度；

pull_semiannual 表示下架是否在上半年；

pull_isweekend 表示下架是否在周末。

（2）类别特征

类别特征可以进行频率编码，将每个类别的频数作为特征值。

（3）数值特征

问题 1 中查看数值特征 mileage 和 newprice 的分布，发现存在一些右偏，对这两个特征取对数。

特征构造完成后，可以将之前的特征删除，还剩下 26 个特征。

6.3 对销售周期影响的关键因素挖掘

对数据进行查看，发现有 2000 个样本没有成交时间，意味着车辆没有售出而直接下架，没有销售周期。若只考虑销售成功的车辆，则会浪费 2000 个样本，因此根据销售周期将一半的样本设置为易销售车辆，另一半设置为不易销售车辆，并且删除 display_time 特征。问题 2 就变成了一个二分类问题，挖掘出影响车辆是否容易交易的关键因素。

6.3.1 基于统计特性的关键因素挖掘

对于类别特征，若不是易交易的关键影响因素，则每个类别中，易交易和不易交易的比例相差应该不大。可以观察类别特征的堆积柱状图进行查看，图 2 至图 11 展示了各个类别特征是否易交易的柱状堆积图，由于 serial 和 model 的类别数量过多，无法画出柱状堆积图，所以不予展示。

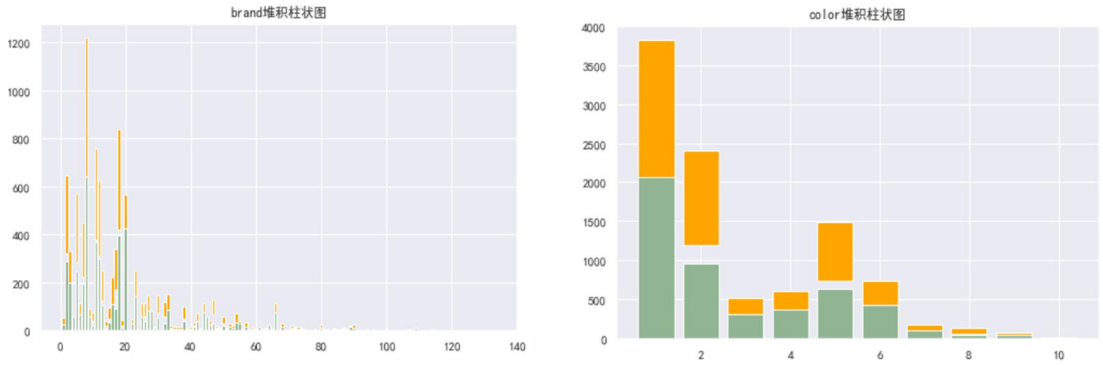


图 10 brand（左）与 color（右）堆积柱状图

图 10（左）展示了 brand 每个类别不易销售和易销售的比例，橙色部分代表不易销售，绿色部分代表易销售，总体来说，是否易销售在不同品牌的分布差异不大。但也可以看出部分品牌不易销售和易销售的比例与多数品牌有差异，可以具体找出易销售所占比重多的品牌和不易销售所占比重多的品牌，在之后的收车过程中可以着重收购易销售品牌，对不易销售品牌的车辆可以降低收购价格和定价。

图 10（右）展示了是否易销售在不同 color 上的分布状况，可以看出颜色 1 最为大众，其次是颜色 2。具体观察每个颜色是否易销售的分布，可以较明显看出颜色 1、3、4、6、7 上的都是易销售数量大于不易销售数量；颜色 2、5 易销售数量和不易销售数量相差不大；颜色 8 上不易销售数量大于易销售数量。总体来说，销售难易情况在不同颜色上的差别不是很大。

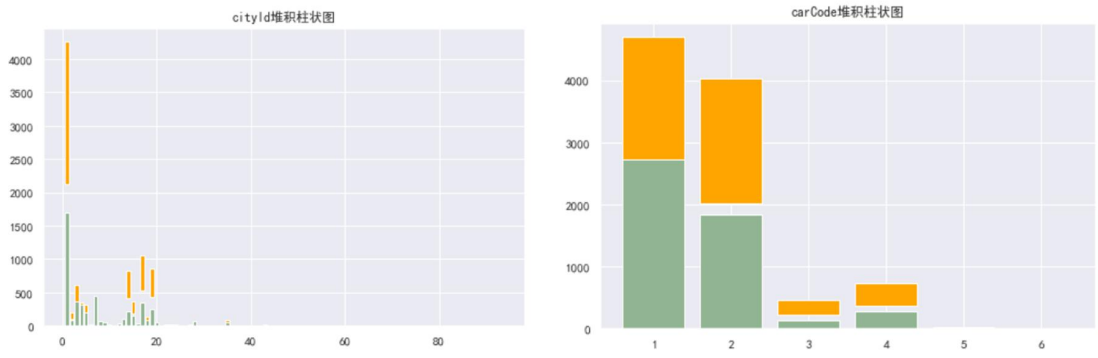


图 11 cityId（左）与 carCode（右）堆积柱状图

图 11（左）展示了是否易销售在不同 cityId 上的分布状况，城市 1 的数量最多，易销售和不易销售比重较为平衡，另外较为平衡的城市有城市 2、3、14、15、17、19，剩下的城市都存在较不平衡的销售情况，因此，城市对于销售的难以程度具有较大影响。

图 11（右）展示了是否易销售在不同 carCode 上的分布状况，可以看出 carCode 为 1 和 2 的车辆数最多。观察具体的 carCode 类别，车辆在 1 类上易销售数量更多，在 3 类上不易销售数量更多，在 2 类和 4 类上易销售和不易销售的数量相差不大。总体来说，销售难易情况在不同国标码上差异不大。

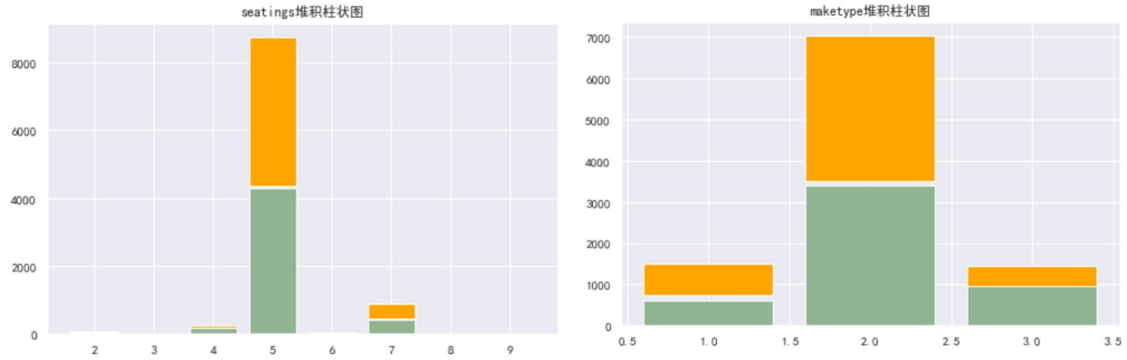


图 12 seatings（左）与 maketype（右）堆积柱状图

图 12（左）展示了是否易销售在不同 seatings 上的分布状况，可以看出大多车辆都是 5 座。观察具体的座位类别，4 座的车辆易销售数量更多，5 座和 7 座车辆易销售和不易销售的数量相差不大。总体来说，销售难易情况在不同座位数量上的差异不大，并且样本大多都是 5 座的，分布极为不平衡，若要建立预测模型，这个特征对于预测目标的帮助不大。

图 12（右）展示了是否易销售在不同 maketype 上的分布状况，可以看出大多数车辆的厂商类型都为类型 2。观察具体的厂商类型，类型 3 的易销售数量更多，类型 1 和类型 2 易销售和不易销售数量差异不大。总体来说，销售难易情况在不同厂商类型上的差异不大，并且样本大多都是类型 2，分布极为不平衡，若要建立预测模型，这个特征对于预测目标的帮助不大。

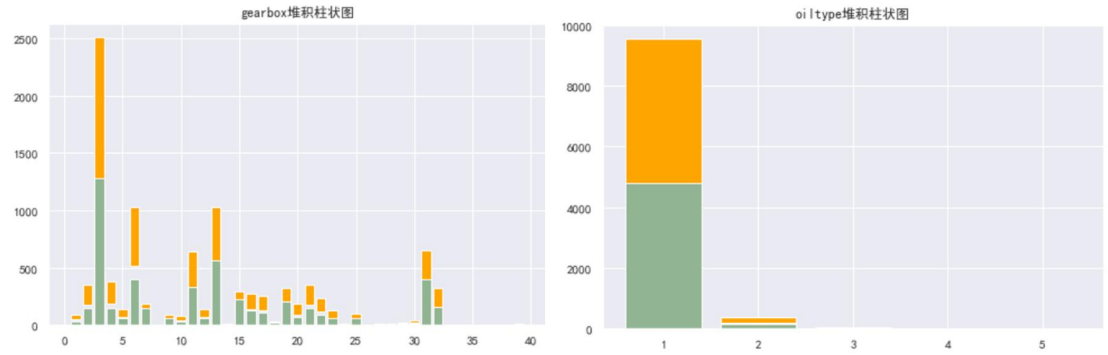


图 13 gearbox（左）与 oiltype（右）堆积柱状图

图 13（左）展示了是否易销售在不同 gearbox 上的分布状况，可以看出大多数车

辆的变速箱都为类型 3。观察具体的变速箱销售难易分布情况，类型 9 和类型 15 易销售数量更多，其他类型在的易销售和不易销售数量差异不明显。总体来说，销售难易情况在变速箱类型上的差异不大。

图 13（右）展示了是否易销售在不同 oiltype 上的分布状况，可以看出大多数车辆的燃油类型都为类型 1。观察具体的燃油类型销售难易分布情况，销售难易程度在类型 1 和类型 2 上的数量相当，没有明显的差异。并且，数据分布极不平衡，对于预测目标的帮助很小，可以忽略这个特征。

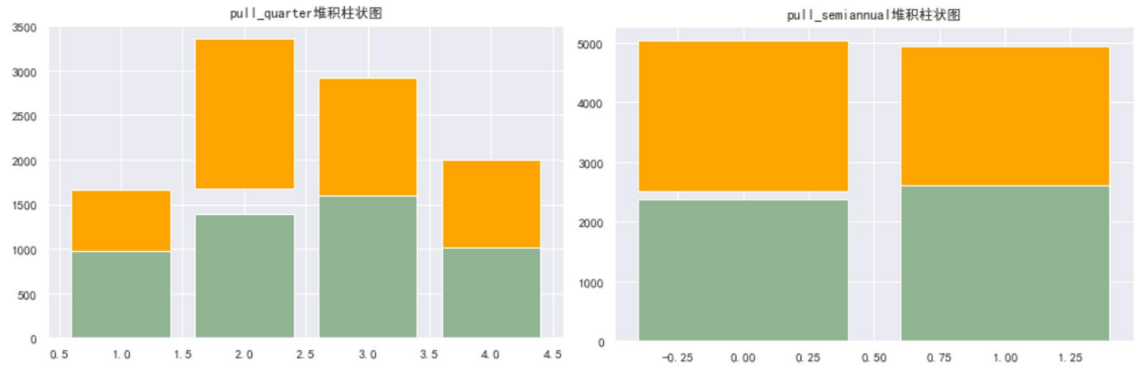


图 14 pull_quarter（左）与 pull_semiannual（右）堆积柱状图

图 14（左）展示了是否易销售在不同 pull_quarter 上的分布状况，可以看出第二季度和第三季度的销售量更高。观察具体的季度销售难易分布情况，销售难易程度第一季度和第三季度易销售数量略大于不易销售数量，在第二季度和第四季度的易销售数量和不易销售数量相当。总体来说，销售难易情况在季度上的差异不大。

图 14（右）展示了是否易销售在不同 pull_semiannual 上的分布状况，可以看出销售难易程度上半年和下半年易销售数量和不易销售数量相当，销售难易情况在上半年还是下半年的分布差异不大。

综上所述，对是否易交易影响较大的类别特征有：cityId；影响一般的特征有：brand、color、gearbox；影响很低的特征有 country、carCode、seatings、maketype、oiltype。

6.3.2 基于模型的关键因素挖掘

经过数据预处理和特征构造，可以构建特征与是否易交易之间的预测模型，因为树模型对特征重要性排序的优点，所以，构建树模型来预测车辆是否易交易，并得到模型的特征重要性排序。

分别用随机森林模型、XGBoost 模型、LightGBM 模型进行模型拟合。先划分训练

集和测试集，将 30%的样本座位测试集，采用网格搜索和 10 折交叉验证进行超参数搜索，最后各个模型的 F1_score 以及 AUC 得分如表 7 所示。

表 7 预测是否易交易各模型得分

模型	F1_score	AUC
RandomForest	0.66	0.6449
XGBoost	0.66	0.6587
LightGBM	0.68	0.6785

无论从 F1_score 还是 AUC 得分来看，LightGBM 的预测效果最好，F1_score 得分为 0.68，AUC 得分为 0.6785。LightGBM 的 ROC 曲线如图 15 所示。

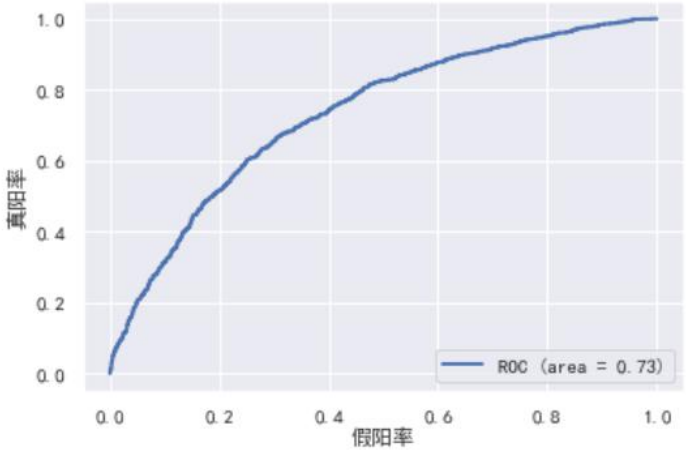


图 15 LightGBM 模型的 ROC 曲线

图 15 展示了 LightGBM 模型的 ROC 曲线，曲线下面积所占比例为 0.73，模型预测效果良好。

可视化 LightGBM 的各个特征的重要性，如图 16 所示。

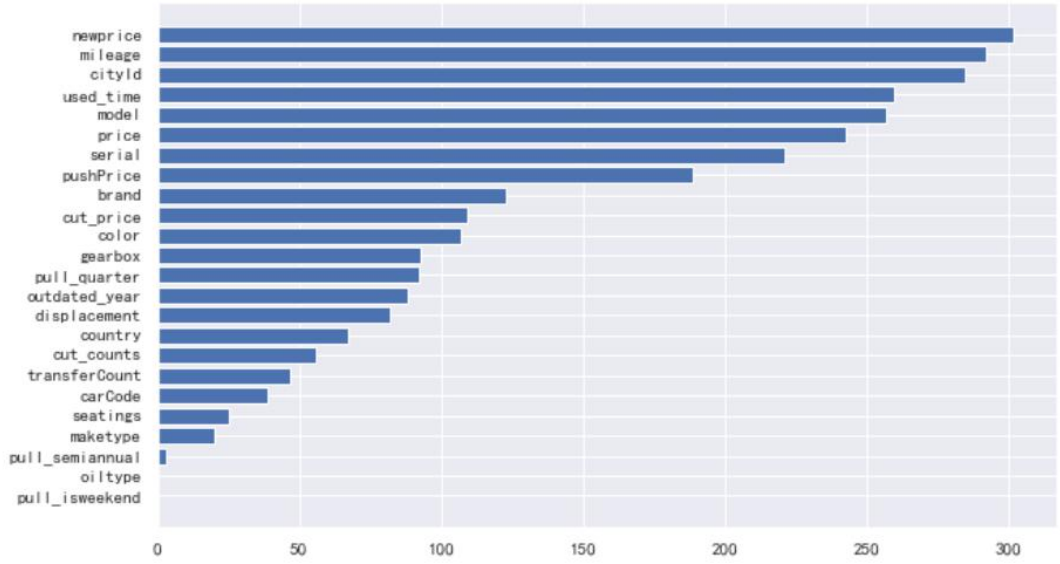


图 16 LightGBM 特征重要性

图 16 展示了 LightGBM 模型得出的各个特征的重要性，排名靠前的特征有 newprice、mileage、cityId、used-time、model、price、serial、pushprice；排名靠后的特征有 country、cut_couts、transferCount、carCode、seatings、maketype、pull_semiannual、oiltype、pull_isweekend。其中的类别特征和单独分析每个特征时得出的结论一致，是否易交易在不同类别上差异较大的特征重要性也比较高，是否易交易在不同类别上差异不明显或者类别分布极不平衡的特征的重要性比较低。

6.4 加快销售速度措施

根据模型的特征重要性，着重考虑重要性排名靠前的特征。根据这些特征提出一些针对性的建议。

（1）newprice 的特征重要性排名最高，在进行二手车收购时要重点关注车辆购入价位，优先收购二手车交易中更易交易价位的车辆。对于一些车辆，交易量虽然少，但是利润却比其他车辆高，特别是一些价格昂贵的车辆，要更加慎重得定价，在保证较高收益的同时能快速销售出。

（2）mileaged 在二手车交易中所受的关注也非常多，一般而言，行驶里程越短，越容易销售出，因此对于一些行驶里程高的车辆可以定较低的价格，以便更快速地出售。

（3）cityId 的对是否容易交易的影响也很大，各个城市的二手车交易难易程度不一样。可以针对性地对难以较难销售的城市加大广告投入，而不是所有城市都投放相

同的广告，可以以较少的成本缩短交易周期。

7. 问题 3：二手车保值率影响因素分析

消费者可以通过汽车保值率来对汽车进行全方面的认识。汽车保值率，即一辆汽车生命周期内的价值曲线,消费者通过保值率能够进行更加理性的购车和用车。同时如果将汽车保值率最新研究成果运用到汽车生产链条的各个环节中，可以促进汽车行业各业务的紧密连接，重构创新业务模式。

保值率所代表的含义并不单单指二手车在卖车时的残值，保值率高一方面代表了二手车流通量大，另一方面代表了消费者对于这款车在产品方面的认可[4]。不仅如此，一款车型的流通量大能够从侧面反映车辆在日常使用和保养过程的成本能够进一步降低，对于消费者来说这个现象更容易被他们所接受。

7.1 数据来源

选取附件一“估价训练数据.txt”进行分析，在问题一数据预处理的基础上，对某些时间变量进行如下的数据变换：

(1)注册日期

附件一“估价训练数据.txt”中的注册日期数据形如“2018-8-1”，不便于进行数据建模，因此以 2021 年 12 月为基准，构造出连续变量，以“月”作为单位，并分别计算出每辆二手车注册日期至 2021 年 12 月的月份数，取值为 7-213。

(2)上牌时间

附件一“估价训练数据.txt”中的上牌数据形如“2017-9-16”，不便于进行数据建模，因此以 2021 年 12 月 1 日为基准，构造出连续变量，以“天”作为单位，并分别计算出每辆二手车注册日期至 2021 年 12 月 1 日的天数，取值为 149-6104。

由于本问要分析的是二手车保值率的影响因素，因此将附件一“估价训练数据.txt”中的 15 个匿名变量剔除，仅分析余下的 17 个有名变量对二手车保值率的影响

7.2 二手车保值率影响因素的定性分析

通过查阅相关文献[5][6]，基于问题一、二中分析出的二手车定价和销售周期的影响因素，结合附件“估价训练数据.txt”和“门店交易训练数据.txt”中各属性字段含义，主要从以下几个方面考虑二手车保值率的影响因素。

（1）二手车的基本信息

二手车的基本信息主要指汽车生产厂商、汽车品牌（品牌国别)、汽车生产国、车系车型等。问题一中已经证明这些因素对二手车的定价具有一定的影响，而二手车的保值率与二手车的定价高度相关，故将其放入影响因素之列。

（2）二手车的使用情况

二手车的基本使用情况包括上牌时间、行驶里程以及过户次数等。一般来讲，二手车的保值率会随着使用年限的增加而降低，在其他条件固定的情况下，汽车使用时间越长，其折旧也就会越多，剩余价值就会越低，即保值率越低;汽车的行驶里程亦是如此;对于汽车的过户次数，依据经验来讲，过户次数越多的汽车，保值率可能也会越低。

（3）二手车的动力配置情况

二手车的动力配置情况主要包括排放标准、排量、变速箱、燃油类型等。

综上所述，结合附件“估价训练数据.txt”和“门店交易训练数据.txt”中各属性字段含义，初步选择的二手车保值率评估指标如下表 8 所示。

表 8 备选指标

类别	变量
基本信息	品牌、车系、车型、车辆颜色、国别、厂商类型、年款、载客人数
使用情况	里程、过户次数、注册日期、上牌日期
动力配置	国标码、排量、变速箱、燃油类型
其他属性	车辆所在城市

7.3 二手车保值率的 Logistic 模型

7.3.1 Logistic 回归算法

一般线性模型中，因变量 y 的值是有实际意义的，并假定 $y\sim N(\mu,\sigma^2)$。当 y 是二分类变量时，y 的取值为 0 或者 1，此时 y 是服从 Bernouli 分布的随机变量[311],即 $y\sim b(n,p)$。针对 0-1 变量，回归模型必须做出一些改进。设 p 表示 y=1 的概率，q 表示 y=0 的概率，q=1-p。概率 p 表示 y 取值为 1 的可能性的大小。假定在观察因变量 y 的同时，观察了 p 个解释变量$x_1,x_2,...,x_p$。与线性模型不同的是，我们所研究的不是因变量 y 的值与解释变量之间的关系，而是研究因变量 y 取 1 时的概率 p 与解释变量之间的关系。实际观测结果表明，概率 p 与解释变量之间并不是呈线性关系，而是呈“S"形曲线的关系。故一般用 logistic 曲线来描述 p 与解释变量 X 之间的关系。

$$P = p(y = 1 \mid x) = \frac{\exp(\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p)}{1 + \exp(\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p)} \tag{7.1}$$

对该式作 logit 变换：

$$\mathrm{logit}(y) = \ln(\frac{p}{1-p}) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p \tag{7.2}$$

式（7.2）称为 logistic 回归模型，其中$\beta_0,\beta_1,\cdots,\beta_p$为待估参数。

7.3.2 Logistic 回归模型构建

由于本文尝试研究保值率高低的影响因素，故将保值率进行排序，选取排序前 30%的定义为高保值率，记为 1，其他为低保值率，记为 0。对二手车保值率做 logistic 回归，指标如下:

x1—品牌、x2—车系、x3—车型、x4—车辆颜色、x5—国别、x6—厂商类型、x7—年款、x8—载客人数、x9—里程、x10—过户次数、x11—注册日期、x12—上牌日期、x13—国标码、x14—排量、x15—变速箱、x16—燃油类型、x17—车辆所在城市。

建立上述各变量对二手车保值率的逻辑回归模型，考虑到模型涉及诸多变量，本文试图建立模型选择的 AIC 和 BIC 标准，并综合模型的复杂程度和预测精度，选择最利于刻画二手车保值率影响因素的统计模型。由于 AIC 准则侧重于从预测的角度来选

择模型，而本文探讨的是“影响因素”而非“预测”，所以采取 AIC 准则作为特征变量的选择时并不是最适合的，而 BIC(贝叶斯准则）要更合适一些。BIC 准则下的模型回归结果如表 9 所示。

表 9 BIC 准则下的 Logistic 回归结果

	变量	回归系数	显著性	
	截距项	0.000641	3.25e-16	***
	品牌	-0.01923	<2e-16	***
	车系	-0.001299	<2e-16	***
	车辆颜色	-0.02178	0.0308	*
基本信息	国别	-0.08223	3.26e-16	***
	厂商类型	0.696	<2e-16	***
	年款	-0.1377	1.13e-09	***
	载客人数	0.03278	<2e-16	***
	里程	-0.1506	<2e-16	***
使用情况	过户次数	0.1833	2.33e-09	***
	注册日期	-0.09754	<2e-16	***
	排量	1.064	<2e-16	***
动力配置	变速箱	0.01375	4.76e-10	***
	燃油类型	-0.5267	1.12e-07	***

注:***:0.001 显著**:0.01 显著*:0.05 显著: 0.1 显著

模型构建好后需要对其进行评估，分类模型预测等价于用样本中的个体数据通过分类器来预测它所对应的目标变量的类别。当目标变量为二元变量时，就是通过分类器预测目标变量 y 的取值，即预测 y=1(正类)还是 y=0(负类)。混淆矩阵是检验分类模型预测效果的有效工具。具体如表 10 所示。

表 10 混淆矩阵

		预测值		总计
		0	1	
真实值	0	TN	FP	N
	1	FN	TP	P
	总计	N*	P*	N+P

其中，TP 表示预测到“真正类”的个数。即实际值为 y=1,预测值也为 y=1。

TN 表示预测到“真负类”的个数。即实际值为 y=0,预测值也为 y=0。

FP 表示预测到“假正类”的个数。即实际值为 y=0（负类),被错误的预测为 y=1（正类），故预测到的正类是“假正类”。

FN 表示预测到的“假负类”的个数。即实际值为 y=1(正类） ,被错误的预测为 y=0（负类），故预测到的负类是“假负类”。

常用的评价分类器的指标如表 11 所示:

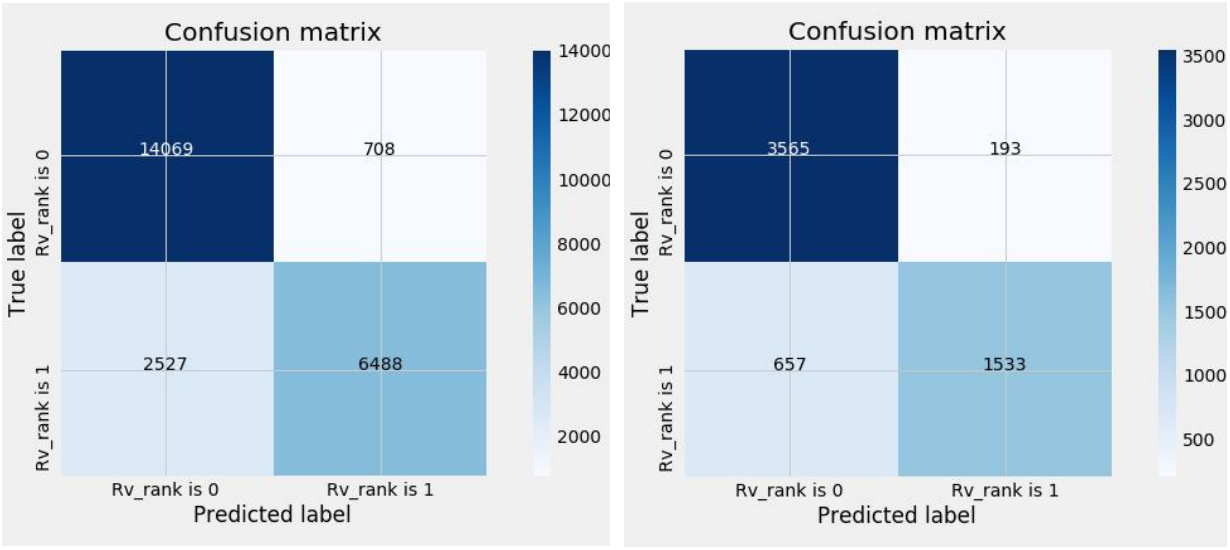
表 11 分类器性能评估指标

名称	公式	含义
准确率	TR=(TP+TN)/(P+N)	反映分类器整体的预测能力
敏感度	TPR=TP/P	反映分类器正确预测“正类”的能力
特异度	TN/N	反映分类器正确预测“负类”的能力
假正类率	FPR=FP/N	把实际为负类的个体错分为正类的比率

ROC 曲线能够对这一变化进行更加形象的描述。ROC 曲线全称是“受试者工作特征”曲线，他能较全面的考虑各种可能的阈值。特别是在比较多种不同的分类器的性能时，是一种非常有用的评价工具。

ROC 曲线采用假正类率（1-特异度）和敏感度两个指标，结合阈值的变化我们可以得到多对 TPR 和 FPR 的值，并以 FPR 为横坐标，TPR 为纵坐标，绘制出 ROC 曲线。该曲线下方的面积越大，其值越接近于 1，则表明分类器的效果越好。

本文对逻辑回归模型预测效果进行评估,分别对训练集与测试集绘制混淆矩阵图和 ROC 曲线图，进而计算出各分类检验指标值，如下图表所示。



（1）训练集混淆矩阵　　（2）测试集混淆矩阵

图 17 训练集与测试集 混淆矩阵

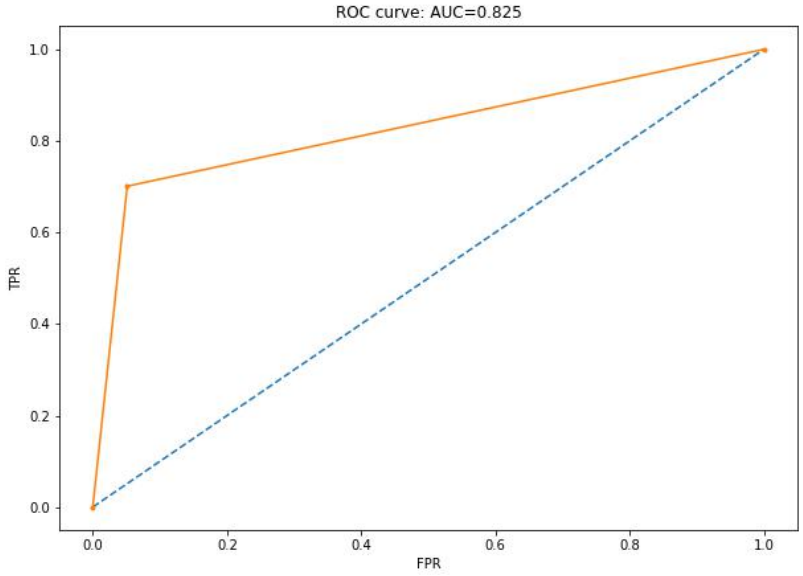


图 18 Logistic 回归 ROC 曲线

表 12 分类检验指标

检验指标	训练集	测试集
准确率	0.8640	0.8571
敏感度	0.7197	0.7000
特异度	0.9521	0.9486
假正类率	0.0479	0.0514

由表 12 和图 18 可以看出，该模型训练集准确率为 0.864，测试集的准确率为

0.8571，AUC=0.825，说明建立的 logistic 回归模型效果良好。因此，用 logistic 回归模型解释二手车保值率的高低与各影响因素之间的关系是合理的。

7.3.3 影响因素分析

根据表 9，BIC 准则下的模型回归结果可以看出，使用逐步回归和 BIC 准则剔除了 4 个不显著的变量，由剩下的 13 个变量可以得到回归方程为:

$$\begin{aligned} \mathrm{logit(y)} &= 0.00064 - 0.01923x_1 - 0.001299x_2 - 0.02178x_4 \\ &-0.08223x_5 + 0.696x_6 - 0.1377x_7 + 0.03278x_8 - 0.1506x_9 \\ &+0.1833x_{10} - 0.09754x_{11} + 1.064x_{14} + 0.01375x_{15} \end{aligned} \tag{7.3}$$

在控制其他因素不变时，可获得以下结论:

1、Logistic 回归模型选择出的重要变量排名前十的为:排量、厂商类型、过户次数、载客人数、变速箱、车系、品牌、车辆颜色、国别和注册日期。

2、基本信息、使用情况、动力配置方面均对二手车保值率的高低有着一定的影响，但是其他属性方面影响并不显著。根据常识可以印证:

（1）从基本属性来看，汽车的载客人数代表着座位数，而座位数与所要缴纳的交强险有关，交强险会按照汽车的座位数收取一定金额的保险费用。品牌个性是消费者赋予品牌人性化特征的集合，品牌个性的塑造主要包括两个方面:产品自身和非产品自身。品牌个性将消费者的自身利益及产品情感紧密连接起来，品牌个性可以改变个体的消费偏好，提高消费者对产品或者品牌的认可度、信任度和依赖度，具体而言，通过某品牌可以反映出消费者某方面的特质，因此品牌个性严重影响了消费者的购买方向和意图，如拥有复杂个性的群体更加倾向于具有多重个性的品牌，而不仅仅是具有单一特征的品牌。

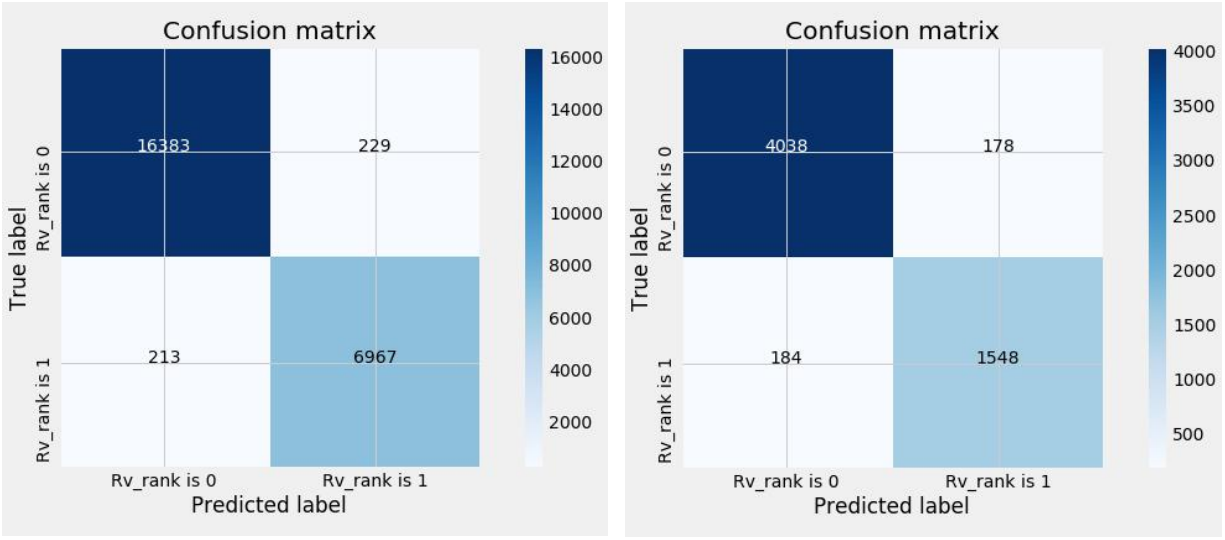
（2）从使用情况来看，里程对二手车的保值率有着显著的影响。一辆汽车的总里程根据汽车种类的不同而有所不同，以常见的家用轿车类的乘用车来说，正常寿命一般是 15-20 年，在正常的保养情况下，行驶里程大约是是 30-50 万公里;对常见的货柜商用车来说，正常的寿命大约为 10-15 年，40-80 万公里。一般以 5 万公里为一个阶段，每个阶段都需要进行比较大的保养维修。对无保养记录的超过 10 万公里里程车辆，短途试乘试驾感觉车况良好并不能保证此车车况在行驶一段时间后仍然保持良好,此车很可能正面临一个大修保养的临界点。因此,“里程”会对该车的保值率产生影响，里程越多，低保值率的概率就越大。

（3）从动力情况来看，汽车油耗成为评判一辆汽车经济性与发动机性能好坏的主要指标，一般情况下，汽车的排量越大，百公里油耗也会相应越高。因此，“排量”会对二手车的保值率的高低产生一定的影响。变速箱担负着汽车传动系的工作，其良好的动力性和燃油经济性能够确保汽车在不同的使用环境下正常行驶。变速箱的作用对于汽车而言举足轻重，“手动挡的汽车安全、省油”、“自动挡的汽车方便”等。

7.4 二手车保值率的 XGBoost 模型

7.4.1 XGBoost 模型构建

选取问题一中的 29741 条数据建立 XGBoost 算法模型，以探究二手车保值率高低与各变量之间的联系。首先划分训练集与测试集，随机选取百分之八十的数据作为训练集，剩下的百分之二十数据作为测试集。对模型进行评估，绘制混淆矩阵图、分类检验指标表和 ROC 曲线图，如下所示:



（1）训练集混淆矩阵　　（2）测试集混淆矩阵

图 19 训练集与测试集混淆矩阵

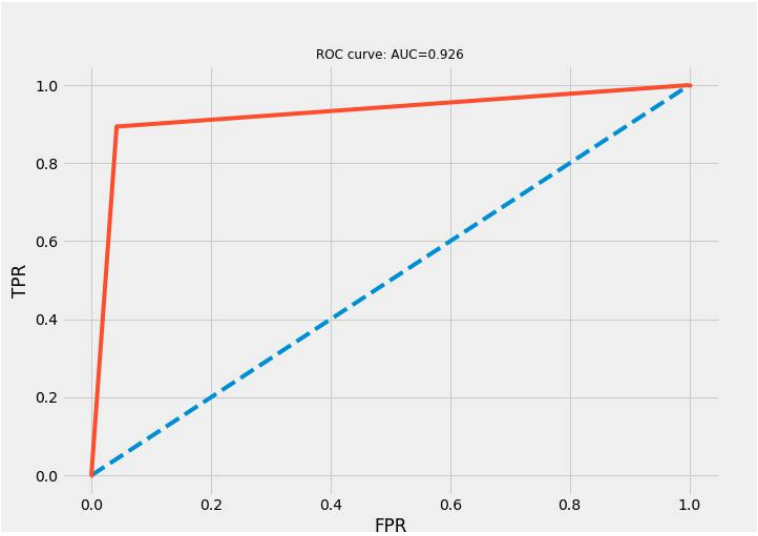


图 20 XGBoost 分类 ROC 曲线

表 13 分类检验指标

检验指标	训练集	测试集
准确率	0.9814	0.9391
敏感度	0.9703	0.8938
特异度	0.9862	0.9578
假正类率	0.0138	0.0422

由表 13 分类检验指标和图 20ROC 曲线示意图可知，准确率为 0.9391，AUC=0.926，说明建立的 XGBoost 回归模型效果良好。因此，用 XGBoost 模型解释二手车保值率的高低与各影响因素之间的关系是合理的。

7.4.2 影响因素分析

变量重要性程度反映了各变量在对二手车保值率的影响因素中的重要程度。如下图 21 变量重要性程度和图 22 变量贡献度所示:排在第一位的为注册日期。随后为上牌日期、厂商类型、国别、年款、品牌和燃油类型等。排名前五位的中，有两个变量反应的是二手车的使用情况，剩下的三个变量则反应了二手车基本信息这一因素。品牌和燃油类型则排在了第六位和第七位，变速箱则是排在了第十位。

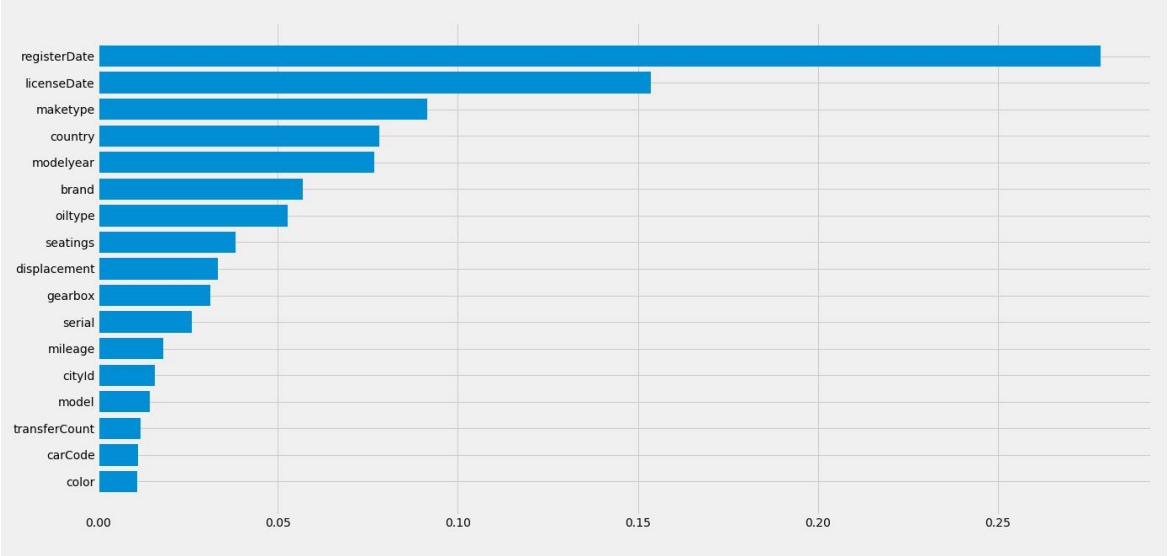


图 21 变量重要性程度

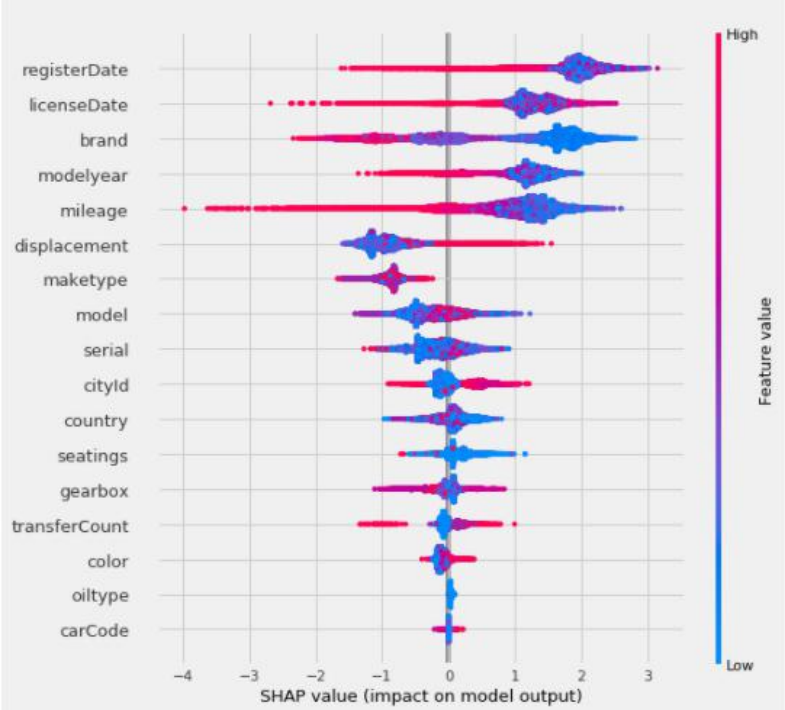


图 22 变量贡献度

7.5 小结

本问对二手车保值率的影响因素进行了探究。首先在问题一、二结论的基础上对二手车保值率产生影响的因素进行探索性分析，筛选出二手车保值率评估的备选指标，进而分析出: (1)从基本信息层面来看，载客人数、品牌、车型都会对保值率的高低产生一定的影响，例如汽车厂商变量，人们对品牌的偏爱会促使人们买特定品牌的汽车。

汽车座位数反映着载客量的多少，这也会影响着人们对于汽车的选择，进而对保值率产生影响。(2)从使用情况层面上来看，上牌时间和行驶里程对二手车保值率的高低有着重要的影响,逻辑回归和随机森林的特征重要性分析都印证了这一结论。(3)从动力配置情况来看，汽车排量、变速箱类型等对保值率的高低有着一定的影响，排量决定了汽车的油耗，这也是普通家庭在购车中需要考虑的因素。

8. 模型评价与推广

问题 2 要求挖掘出影响销售周期的关键因素将估价训练数据和门店交易数据进行融合，因为有 1/5 的数据没有交易，因此没有销售周期。本文将所有样本分为易交易和不易交易车辆，对于销售周期短的前 50%设置为易交易车辆，剩下的样本设置为不易交易车辆。对于关键因素的挖掘，主要通过建立预测车辆是否易交易的分类模型，再根据模型重要性排名来确定对是否易交易影响因素大的特征。另外，可以依据统计方法，对于每个类别特征，单独考虑与是否易交易的关系，查看每个类别易交易和不易交易的分布状况，若每个类别上的分布相似，则说明这个特征对是否易交易的影响不大。两种挖掘方式进行对比，对于类别特征，两种挖掘方式的结果相一致，没有出现相悖的情况。

对于两种方式的评判，基于模型的方法可以将分类特征和数值特征一起进行对比，而统计方法只能分开进行对比，且带有一定的主观性；当特征数量比较多时，基于统计的挖掘方法比较繁琐；基于统计的挖掘方法能针对于每个特征进行分析，提出针对性的建议和措施。结合两种方式的优缺点，本文利用两种方式进行挖掘，基于模型的方法为主，基于统计的挖掘方法为辅。

问题 3 从统计模型和算法模型两个方面对二手车保值率高低的影响因素进行探索，建立 logistic 回归模型和 XGBoost 模型，两个模型都取得了不错的预测效果（其中，Logistic 模型在测试集上的准确率为 0.8571，AUC=0.825；XGB 模型在测试集上的准确率为 0.9391，AUC=0.926）同时,XGBoost 模型结果显示: 注册日期、上牌时间、上牌日期、厂商类型、国别、年款、品牌和燃油类型是对二手车的保值率高低产生影响的重要指标。

参 考 文 献

[1] 李航.(2019).统计学习方法.清华大学出版社，北京

[2] 周志华.(2016).机器学习.清华大学出版社，北京

[3] 陈星星. 基于改进重置成本法的二手轿车价值评估研究[D].重庆理工大学,2021.

[4] 刘颖. 二手车保值率影响因素的研究及其应用[D].北京工业大学,2019.

[5] 张月. 北京二手车保值率的影响因素分析[D].天津财经大学,2019.

[6] 曹晓祎. 二手车保值率影响因素分析[D].贵州财经大学,2019.

[7] 武炜杰. 随机森林算法的应用与优化方法研究[D].江南大学,2021.