队伍编号	MCB2102360
赛道	B

信息流智能推荐算法中的序列评估问题

摘 要

随着移动互联网的普及和迅猛发展，面对海量的用户数据，资讯类服务平台如何通过算法将合适的内容推送给每一个用户，不仅满足用户对内容的偏好需求，还使得信息流获得最大的收益，那么信息流收益评估模型的建立就具有十分重要的理论和实践意义。

本文对历史序列的点击量和浏览时长进行评估，建立模型预测推荐序列的总点击收益和总时长收益，并据此计算。此外，本文根据候选的推荐序列算法评估框架，得到的推荐结果收益效果显著。具体本文解决了如下问题：

针对问题一，我们建立模型对收益指标进行细化，通过计算推荐序列与用户历史信息的一致性，得到用户对推荐的内容类别和类型浏览偏好。此外，我们计算用户对序列位置的偏好权重得到序列内容的不同排列组合对收益大小的影响。此外我们对收益模型进行了参数设置，资讯平台可以根据市场环境和内部效益偏好对参数进行调整。

针对问题二，需要对推荐序列进行收益预测。在对数据进行预处理后，我们通过三个误差指标对四个候选模型的预测效果进行比较，最终选取 GRU 模型和随机森林分别对推荐序列的总点击量和总浏览时长进行预测，较好地实现了问题需求，并对预测效果进行可视化处理。

针对问题三，面对工业界无法接受的算法复杂度问题，本文提出了一种逐步优化算法（Step-wise Optimization Algorithm, SOA）对成为最优序列概率较小的候选序列进行剪枝，降低时间复杂度并提高结果精准度。通过引入参数β确定剪枝序列的比例，并提出了近似率、优越性和时间性三个指标对参数β进行灵敏度分析；此外通过与其他算法进行比较分析，可以有效证明本文所提的算法的有效性。

基于上述三个问题的讨论，充分展现了本文所提出的模型具有较好的市场适应性。在保证结果准确率的前提下，极大降低了算法的时间复杂度，更易被工业界所接受。

关键词：推荐序列；序列收益；GRU 网络；随机森林；SOA 算法

目 录

一、问题重述 1
1.1 问题背景 1
1.2 问题重述 1
二、问题分析与技术路线 2
三、模型假设与符号说明 3
2.1 模型假设 3
2.2 符号说明 3
四、问题一模型的建立与求解 4
4.1 计算用户的位置偏好 4
4.2 计算推荐序列于用户历史信息的一致性 5
4.3 计算推荐序列的总收益 7
4.3.1 推荐序列的总点击收益 7
4.3.2 推荐序列的总时长收益 7
4.3.3 推荐序列总收益 8
4.4 问题一模型示例 8
五、问题二模型的建立与求解 9
5.1 数据预处理 9
5.2 模型的建立 10
5.2.1 GRU 网络 11
5.2.2 随机森林 12
5.3 预测结果 14
5.3.2 总点击量预测结果 14
5.3.3 总浏览时长预测结果 16
六、问题三模型的建立与求解 17
6.1 算法介绍 18
6.2 实验和参数分析 19
6.2.1 对参数 β 的灵敏度分析 20
6.2.2 算法性能的比较分析 24
七、评价与推广 26
参考文献 27
附录 28

一、问题重述

1.1 问题背景

传统媒介门户为了满足用户内容品质的需求，通常需要打造出具有深度内涵且独家的新闻报道。但随着移动互联网的普及和迅猛发展，互联网用户数量增势显著，随之而来的海量数据给用户和服务平台造成了巨大的影响。面对下沉市场的增量用户，他们的内容偏好需求因人而异，众口难调，只有从海量的内容中，通过算法将内容分发给受众，才能满足用户对内容的偏好。对于资讯类服务平台所面临的挑战就是如何利用这些数据为用户和自身创造价值，而解决此问题最有效的途径就是推荐算法[1,2]。

信息流作为推荐算法的主要场景，已经完全融入了人们的日常生活中。信息流产品具有诸多特点[3]，如：（1）能够提供海量信息，用户在使用时通过刷新能够产生源源不断地实时内容；（2）在合适的场景下，能够为用户推送更个性化的内容；（3）具有强用户粘性，利于广告曝光创造盈利。

信息流产品作为一种极具商业价值的产品形态，可以通过人工干预和机器学习算法将内容推送给用户，但是对于推荐效果的评估还需要进一步研究分析。排序学习（Learning to Rank，LTR）利用机器学习技术对推荐结果进行排序，是近几年非常热门的研究领域[4-7]。LTR 中常见的三种模型：Point Wise、Pair Wise 和 List Wise。Point Wise 方法仅以单个内容作为对象并进行打分排序，显然这种方法也具有极大的缺陷，该方法并没有考虑到一个序列中内容的内部依赖性，当推荐内容高度相似时，可能会引起回声室效应而影响用户的阅读体验；Pair Wise 方法没有聚焦于序列中内容的顺序，而是主要关注于两个序列间的排序；相比之下，List Wise 方法解决了需要推荐什么序列以及序列中的顺序问题[8]。

本文基于 List Wise 模型的思想，综合考虑推荐内容的点击量和浏览时长两个指标，提出了推荐序列收益评估的数学模型。同时对于不同排列组合的推荐序列，从计算性能角度，拟构建了基于逐步优化的剪枝算法框架。

1.2 问题重述

基于上述背景，本文根据题目所给的数据及要求，建立数学模型并设计相关算法进

行研究分析，主要解决了以下三个问题：

问题一：建立模型，对推荐序列中内容的总点击收益以及总时长收益进行评估，并基于这两个指标量化序列的综合收益。此外，阐明序列中不同排列组合对收益大小的影响。

问题二：基于问题一中的综合收益模型，预测测试集中推荐序列的总点击量和总时长。

问题三：考虑到计算性能，建立模型，对需要参与收益评估的候选序列集进行剪枝，降低时间复杂度，并最大可能地保证留存的候选序列中包含最优推荐序列。

二、问题分析与技术路线

在推荐系统中，将信息流传递到用户界面主要分为两个步骤：（1）通过人工干预和机器学习算法生成多条内容不同、排列顺序不同的推荐序列作为候选集；（2）对候选序列进行收益评估，主要评估的指标可根据资讯平台的效益偏好进行设置，包含点击量收益以及时长收益推荐过程如图 2. 1 所示。

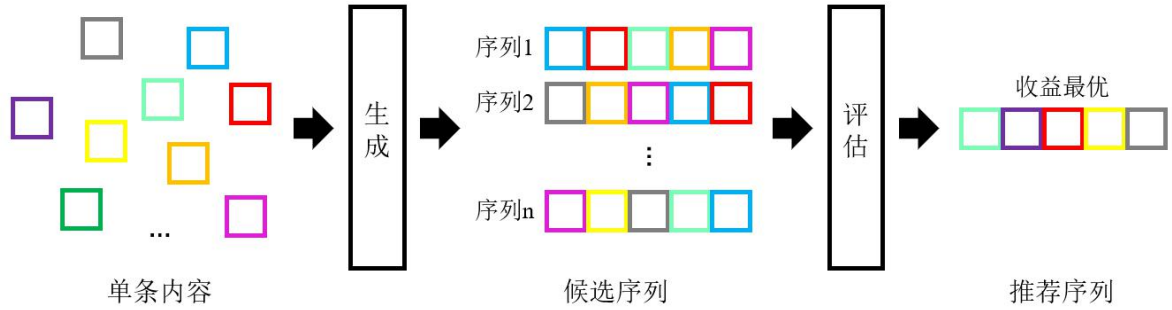


图 2. 1 信息流推荐过程

针对问题一：可知本问题主要针对“评估”步骤所提出。在推荐内容质量保持不变的情况下，对于序列评估模型来说，内容的排列顺序、用户的浏览偏好都会影响推荐序列的收益大小。对于问题一，我们将研究的收益指标进行细化，通过考虑推荐内容的类别标签和类型标签，计算推荐序列与用户历史信息的一致性，得到用户对推荐的内容浏览偏好。此外，我们将推荐序列不同排列组合对收益大小的影响转化为用户对推荐序列上的位置偏好。这种思维转变有利于以更低复杂度的方式计算推荐序列的收益，具体分析在问题三中得以展现。

针对问题二：基于问题一中的数学模型，对于预测推荐序列的总收益问题，我们需要首先对数据进行预处理，将内容的类别和类型标签进行标号，转换为计算机可识别的

形式。在建立回归模型时，通过均方根误差（RMSE）、平均绝对误差（MAE）和均方误差（MSE）三个指标，可以比较不同模型在预测点击收益和时长收益上的效果，最终确定哪种模型更适合用来进行预测收益指标。

针对问题三：当从 N 条候选内容中选取长度为 K 的推荐序列，可知在步骤一中可以生成 A_N^K 种不同排列组合的候选序列，但面对海量的用户数据，若每一次生成候选序列集后再进行评估，虽然能够找到最优的推荐序列，但对于计算性能耗费极大。在问题一中，我们计算了用户对推荐序列位置的偏好权重并进行排序，基于此我们提出了一种逐步优化算法（Step-wise Optimization Algorithm, SOA），在每一次迭代中对成为最优序列概率较小的候选序列进行剪枝，直至序列长度满足 K 值。我们提出了三个性能指标，对参数和算法分别进行灵敏度分析和对比分析，证明了本文的算法在保证准确率的前提下，极大的降低了时间复杂度。

全文技术路线如图 2.1 所示。

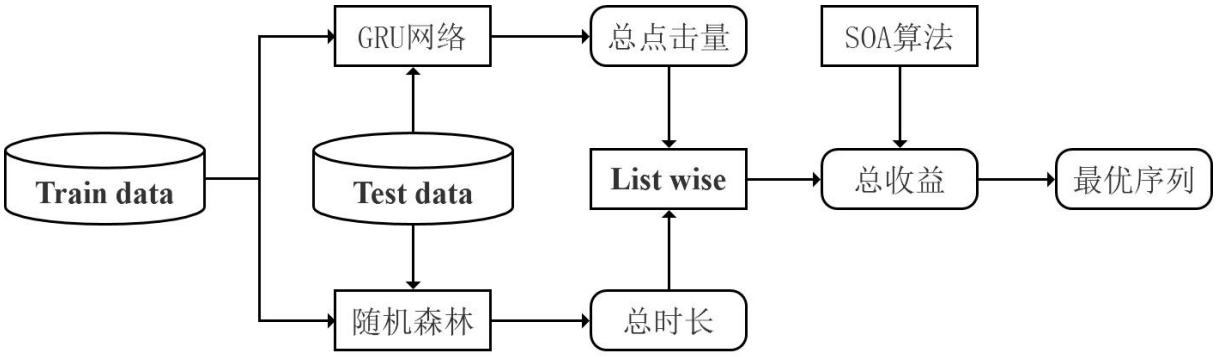


图 2.1 全文技术路线

三、模型假设与符号说明

2.1 模型假设

1、假设用户对推荐序列内容位置的偏好在短期内不会变化；

2、假设面对不同序列长度 K，用户的位置偏好权重向量不相关；

3、假设推荐的内容质量对本模型没有影响。

2.2 符号说明

符号	符号说明
i	在推荐序列的长度为K中的第i个位置$(i=1,2,...,K)$
LP_i^C	用户对第i个位置的点击偏好权重
LP_i^T	用户对第i个位置的时长偏好权重
CLP	推荐序列的总点击收益
TLP	推荐序列的总浏览时长收益
$profit$	推荐序列的总收益
α	资讯平台对点击收益和总浏览时长收益两者的重视程度
β	SOA 算法参数

四、问题一模型的建立与求解

4.1 计算用户的位置偏好

对于一个长度为K的推荐序列，用户对于内容的点击会有不同的位置偏好和习惯，比如有的用户可能习惯从头向后观看，有的用户习惯从中间开始观看。用户对推荐序列内容的位置偏好取决于自身的习惯，也取决于设备、网络等外界因素。如问题分析中所述，序列内容的不同排列顺序会影响收益的大小，那么确定每个用户的阅读位置偏好将有助于更准确地评估推荐序列的收益。

已有研究表明归一化折损累计增益（Normalized Discounted Cumulative Gain，NDCG）是一种有效的计算序列收益的方法[9]。其中 DCG 的主要思想是：推荐序列中内容的顺序很重要，但不同位置的贡献不同，一般来说，排在前面的内容影响更大，排在后面的内容影响较小（例如一个返回的网页，通常排在前面的内容会有更多人点击）。所以 DCG 增加排在前面的内容的影响，并减弱排在后面的内容的影响。根据 DCG 的得分大小，得到所有排列组合中的最高得分 IDCG（ideal DCG）。为了解决每个推荐序列长度不同而无法比较的问题，NDCG 对最后的结果进行了归一化处理。NDCG 的计算过程如下式所示：

$$DCG=\sum_{i=1}^{k}\frac{pro_i}{\log_2(i+1)} \tag{4-1}$$

$$NDCG_k = \frac{DCG_k}{IDCG} \tag{4-2}$$

其中， pro_i 为推荐序列中第 i 个内容的收益。但由于用户的偏好不同，这可能不是最优的序列收益计算方法。为了得到每个用户对推荐序列中每个内容的位置偏好，我们计算了每个用户在每个位置上的历史点击情况和浏览时长情况，并以此作为每个用户点击量和时长的位置偏好。

假设推荐序列的长度为 K，则用户对第 i 个位置的点击偏好权重 LP_i^C 和时长偏好权重 LP_i^T 的计算公式分别为 $(i = 1,2,...,K)$：

$$LP_i^C = \frac{\sum_{m=1}^{M} C_{mi}}{\sum_{i=1}^{K}\sum_{m=1}^{M} C_{mi}} \tag{4-3}$$

$$LP_i^T = \frac{\sum_{m=1}^{M} T_{mi}}{\sum_{i=1}^{K}\sum_{m=1}^{M} T_{mi}} \tag{4-4}$$

其中，M 为历史记录（train.txt）中该用户在推荐序列长度为 K 时的数量，C_{mi} 为第 m 条历史记录中第 i 个位置的内容点击状态，当 $C_{mi}=1$ 表示用户点击该内容，$C_{mi}=0$ 表示用户为点击该内容，T_{mi} 则为第 m 条历史记录中第 i 个位置的内容观看时长。

由此，我们可以得到每个用户在序列中不同位置上的点击偏好权重和时长偏好权重，为后续计算不同排列组合对序列的总收益做准备。

4.2 计算推荐序列于用户历史信息的一致性

在计算推荐序列的点击量和时长收益时，如果在计算序列中的点击量和时长时只采取简单加和或加权求和的方法，会导致那些相似内容高度集中的推荐序列获得较高的收益[10]。然而实际上，相似内容高度集中的推荐序列往往会带来较差的结果。因此我们提出用推荐序列与用户历史信息（train. txt）的一致性来计算点击量和时长的收益。该方法的主要思想是：若想推荐序列获得较高的收益，则推荐序列中各个内容的种类和类别在分布上应尽量于用户的已点击的历史信息保持一致，对于那些不一致的推荐序列，我们在计算点击收益和时长收益时可以对其进行惩罚。

我们将一用户历史记录中已点击过内容记为集合 $X = \{x_1, x_2, ..., x_P\}$，记 $Category(x_p)$ 和 $Type(x_p)$ 分别代表内容 x_p 的类别和类型（具体划分见 doc_info.txt），用 $Time(x_p)$ 代表内容的浏览时间。设 A_i 为推荐序列中第 i 个内容的类别，B_i 为推荐序列中第 i 个内容的类型。则在历史记录中第 i 个内容的类别点击量比例 $CP(A_i)$ 和类别浏览时长比例 $TP(A_i)$

计算公式分别为：

$$CP(A_i)=\frac{\left|\{x_p\left|Category(x_p)=A_i\}\right|\right.}{\left|X\right|} \tag{4-5}$$

$$TP(A_i)=\frac{\sum_{x_p\in\{x_p\left|Category(x_p)=A_i\}\right.} Time(x_p)}{\sum_{p=1}^{P} Time(x_p)} \tag{4-6}$$

其中$\left|X\right|$为集合X中的元素数量。同理，可以得到历史记录中第i个内容的类型点击量比例$CP(B_i)$和类型浏览时长比例$TP(B_i)$：

$$CP(B_i)=\frac{\left|\{x_p\left|Category(x_p)=B_i\}\right|\right.}{\left|X\right|} \tag{4-7}$$

$$TP(B_i)=\frac{\sum_{x_p\in\{x_p\left|Category(x_p)=B_i\}\right.} Time(x_p)}{\sum_{p=1}^{P} Time(x_p)} \tag{4-8}$$

但当面对数以千计的内容类别时，用户在浏览内容时有自己的类别和类型偏好，即不会浏览或点击到每个类别和类型，这将导致计算得到的上述四个指标都偏小，在当前推荐序列中区分度不够明显，故而将得到的结果进行归一化，其过程如下：

$$\overline{CP(A_i)}=\frac{CP(A_i)}{\sum_{i=1}^{K} CP(A_i)} \tag{4-9}$$

$$\overline{CP(B_i)}=\frac{CP(B_i)}{\sum_{i=1}^{K} CP(B_i)} \tag{4-10}$$

$$\overline{TP(A_i)}=\frac{TP(A_i)}{\sum_{i=1}^{K} TP(A_i)} \tag{4-11}$$

$$\overline{TP(B_i)}=\frac{TP(B_i)}{\sum_{i=1}^{K} TP(B_i)} \tag{4-12}$$

由此，可以得到推荐序列中每个内容的类别点击量比例U_i^{CPA}和浏览时长比例U_i^{TPA}于用户历史数据的一致性：

$$U_i^{CPA}=1-\left|\overline{CP(A_i)}-\frac{LCP(A_i)}{K}\right| \tag{4-13}$$

$$U_i^{TPA}=1-\left|\overline{TP(A_i)}-\frac{LTP(A_i)}{TotalTime}\right| \tag{4-14}$$

其中 $LCP(A_i)$ 为单条推荐序列中第 i 个内容的类别点击量比例，$LTP(A_i)$ 为在单条推荐序列中第 i 个内容的类别浏览时长比例，$TotalTime$ 为单条推荐序列的总浏览时长。同理，单条推荐序列中每个内容的类型点击量比例 U_i^{CPB} 和浏览时长比例 U_i^{TPB} 的计算公式如下：

$$U_i^{CPB}=1-\left|\overline{CP(B_i)}-\frac{LCP(B_i)}{k}\right| \tag{4-15}$$

$$U_i^{TPB}=1-\left|\overline{TP(B_i)}-\frac{LTP(B_i)}{TotalTime}\right| \tag{4-16}$$

4.3 计算推荐序列的总收益

4.3.1 推荐序列的总点击收益

基于前两节的分析，在得到用户的位置偏好和推荐序列与用户历史信息的一致性后，我们提出推荐序列的总点击收益的计算公式：

$$CLP=\sum_{i=1}^{K}LP_i^C\cdot(\overline{PUBC(A_i)}+\overline{PUBC(B_i)})\cdot(U_i^{CPA}+U_i^{CPB}) \tag{4-17}$$

$$\overline{PUBC(A_i)}=e^{\lambda_1\cdot PUBC(A_i)} \tag{4-18}$$

$$\overline{PUBC(B_i)}=e^{\lambda_2\cdot PUBC(B_i)} \tag{4-19}$$

通过对测试集的数据预处理，发现序列评估模型的建立涉及用户冷启动问题（具体分析见问题二），即存在训练集（train.txt）中未出现的新用户，我们引入 $PUBC(A_i)$ 表示对所有用户来说第 i 个内容的类别点击量比例以及 $PUBC(B_i)$ 表示对于所有用户第 i 个内容的类型点击量比例。其中 λ_1 和 λ_2 为控制参数，可以调节大众的偏好对当前用户的推荐序列点击收益的影响，当 $\lambda_1=\lambda_2=0$ 时，代表大众的偏好对当前用户的推荐序列点击收益没有影响，当 λ_1 和 λ_2 变大时，其影响也会变大。λ_1 和 λ_2 的大小取决于当前的总体环境，例如对于社会热点，可以通过人工调控的方式，将相关资讯推送给用户。

4.3.2 推荐序列的总时长收益

同理总点击收益，推荐序列的总浏览时长收益计算公式如下：

$$TLP=\sum_{i=1}^{K}LP_i^T\cdot(\overline{PUBT(A_i)}+\overline{PUBT(B_i)})\cdot(U_i^{TPA}+U_i^{TPB}) \tag{4-20}$$

$$\overline{PUBT(A_i)}=e^{\lambda_3 \cdot PUBT(A_i)} \tag{4-21}$$

$$\overline{PUBT(B_i)}=e^{\lambda_4 \cdot PUBT(B_i)} \tag{4-22}$$

同上分析，我们引入 $PUBT(A_i)$ 表示对于所有用户第 i 个内容的类别点击量比例以及 $PUBT(B_i)$ 表示对所有用户来说第 i 个内容的类型点击量比例。其中 λ_3 和 λ_4 为控制参数，可以调节大众的偏好对当前用户的推荐序列浏览时长收益的影响，其作用于 λ_1 和 λ_2 类似。

4.3.3 推荐序列总收益

综合推荐序列的总点击收益和总浏览收益，可以得到推荐序列的总收益模型：

$$profit=\alpha CLP+(1-\alpha)TLP \tag{4-23}$$

其中，α 为调节超参数，其范围 $\alpha \in [0,1]$。α 代表资讯平台对点击收益和总浏览时长收益两者的重视程度。当 $\alpha > 0.5$ 表明平台更重推荐序列的视点击收益，$\alpha = 0.5$ 表明两个效用相当，$\alpha < 0.5$ 表明公司更重视推荐序列的浏览时长收益。

至此，我们已经得到了计算推荐序列总收益的数学模型。

4.4 问题一模型示例

假设存在一个候选内容列表 $List=\{A,B,C,D,E,F\}$，现要从中选出长度为 $2(K=2)$ 的推荐序列，即可知共有 A_5^2 种不同排列组合方式的推荐序列，依据下列条件计算评估收益最大的序列。

假设在候选内容列表种，各内容的点击量和浏览时长的类别和类型在历史记录中占比如下表所示，其中设定内容 A 和 D 具有相同的类别。

表 4.1 问题一模型示例历史数据

	A	B	C	D	E	F
点击量类别	0.2	0.3	0.4	0.2	0.3	0.1
浏览时长类别	0.1	0.3	0.3	0.1	0.4	0.5
点击量类型	0.6	0.4	0.6	0.4	0.1	0.2
浏览时长类型	0.3	0.7	0.3	0.1	0.2	0.1

由于每个内容的类型和类别会重复，故每行相加会出现不为 1 的情况。此处不考虑大众的偏好对推荐序列收益的影响，即令 $\lambda_1=\lambda_2=\lambda_3=\lambda_4=0$。给定用户的位置偏好为 $LP^C=\{0.7,0.3\}$，$LP^T=\{0.6,0.4\}$。候选推荐序列中各内容预测的点击量和推荐时长如下

表（预测过程见问题二）：

表 4.2 问题一模型示例预测数据

	A	B	C	D	E	F
点击量	1	1	1	1	0	0
浏览时长	80	60	50	70	0	0

最终通过各方法求得的收益最大的推荐序列为：

表 4.2 问题一模型示例推荐序列

方法	推荐序列
Point wise	A、D
NDCG	A→D
本文方法	B→A

通过方法对比，可以显然看出先前的方法容易将相同类别的内容组成序列推送给用户，反而会影响用户的浏览体验，获得相反的效果；而本文所提出的方法总体上会获得更高的序列收益。

五、问题二模型的建立与求解

5.1 数据预处理

在模型建立前，我们先对数据进行预处理，改变原始数据的结构，便于后面模型的训练。首先，我们将每条内容的分类设置成计算机可识别的形式。因为各个类别之间存在着一定的联系，如“电视剧/内地剧”和“电影/港台电影”同属于影视，因此我们在转换数据格式时，将内容的类型用 0-1 表示，即 0 表示 news、1 表示 video；将内容的类别用两组数表示，这两组数分别表示一级类别和二级类别。表 5.1 给出了部分类别转换字典。

表 5.1 部分类别转换字典

内容类别	一级类别	二级类别
中国史	3	5
中国外交	4	0
乡村生活	5	0
买车	6	0

休闲活动/养花	7	0
休闲活动/垂钓	7	1
休闲活动/广场舞	7	2
体育/NBA	7	3
体育/中国篮球	8	1
体育/中国足球	8	2
体育/中国足球,游戏/其他	8	3
体育/中超	8	4

模型的便准输入序列格式为 X_train =（类型，一级类别，二级类别），Y_train =（用户是否点击，用户浏览时长）。表 5. 2 给出了推荐序列转变为标准输入序列的示例，其中原始推荐序列为：133669581685:1:19;508486431:1:238;133684825985:0:0。

表 5. 2 数据格式转换示例

ID	内容	X_train	Y_train
133669581685	video/农村/乡村生活	（1,15,1）	（1,19）
508486431	news/娱乐/内地明星	（0,25,4）	（1,238）
133684825985	video/搞笑/囧事	（1,32,21）	（0,0）

5.2 模型的建立

考虑到题目所给的数据量较大，我们随机选取了部分数据来比较四个候选模型的效果，四个候选模型为：随机森林、GRU 网络、卷积神经网络、支持向量机。我们把选取的部分数据按 7:3 分为训练集和测试集。为了更客观比较四个模型的效果，我们选取了三个衡量指标，分别为：均方根误差（RMSE），平均绝对误差（MAE），均方误差（MSE）。各模型预测总点击量和总浏览时长的效果如图 5. 1 和图 5. 2 所示（在展示各模型预测总浏览时长效果时，由于均方误差太大，为了便于表示，我们将均方误差进行了开方）。

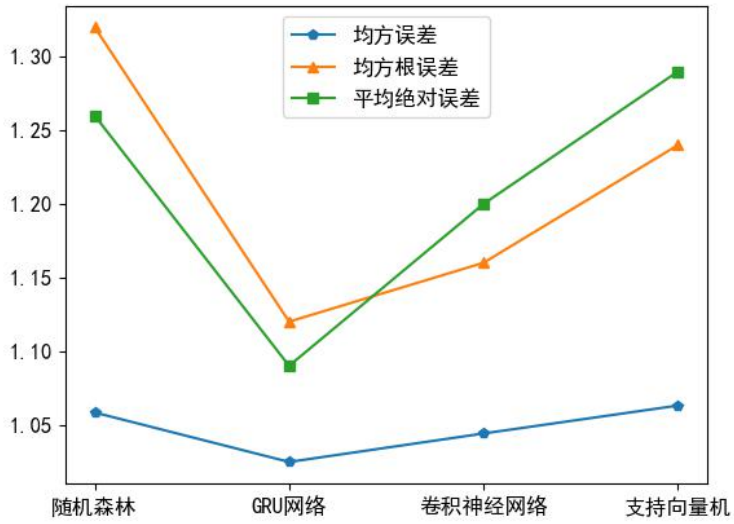


图 5.1 各模型预测总点击量误差效果

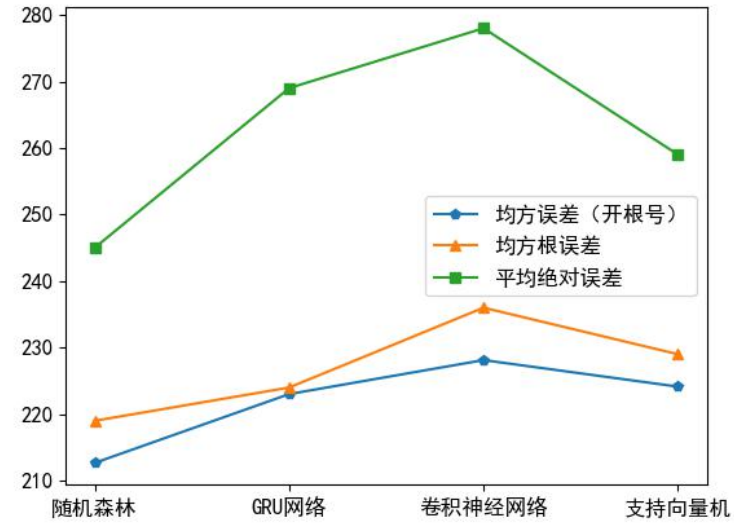


图 5.2 各模型预测总浏览时长误差效果

由图 5.1 和图 5.2 可知，在预测总点击量时，GRU 表现最好；在预测总浏览时长时，随机森林表现最好。于是我们利用 GRU 预测总点击量，用随机森林预测总浏览时长。

5.2.1 GRU 网络

GRU 在多种领域中被证明是一种有效的长短期记忆网络（LSTM）的有效变体，其结构是 LSTM 的简化和提升，目前已有研究将其应用于推荐序列的评估模型中[11]。在 LSTM 算法和 GRU 算法中，通过“门”结构来去除或增加“细胞状态”的信息，实现了对重要内容的保留和对不重要内容的去除。通过 Sigmoid 层输出一个 0 到 1 之间的概

率值，描述每个部分有多少量可以通过，0 表示“不允许任务变量通过”，1 表示“运行所有变量通过”。用于控制信息传递的叫做“遗忘门”，用于信息增加的叫做“信息增加门”，用于输出的叫做“输出门”。GRU 算法去除掉了细胞状态，使用隐藏公式来进行信息的传递，它只有两个门，更新门和重置门[12]。其结构如图 5. 3 所示。

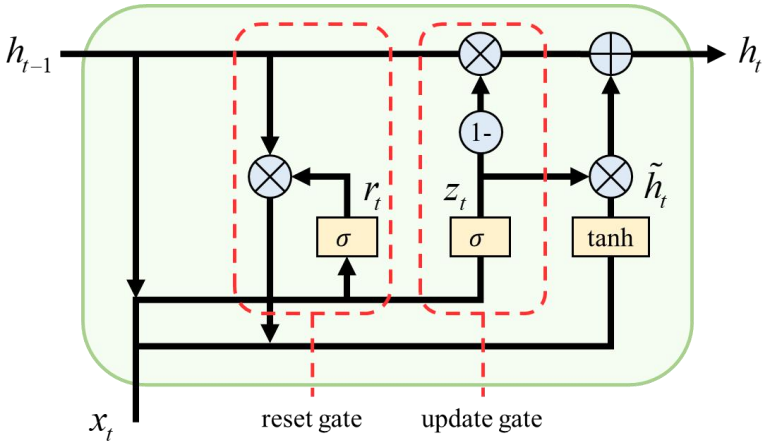


图 5. 3 GRU 门控循环单元结构

GRU 结构的主要计算式：

$$r_t = \sigma\left(W_r \cdot \left[h_{t-1}, x_t\right]\right) \tag{5-1}$$

$$z_t = \sigma\left(W_z \cdot \left[h_{t-1}, x_t\right]\right) \tag{5-2}$$

$$\tilde{h}_t = \tanh\left(W_h \cdot \left[r_t \odot h_{t-1}, x_t\right]\right) \tag{5-3}$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \tag{5-4}$$

其中，r_t、z_t 代表重置门和更新门在 t 时的输出；h_t 和 $\tilde{h}_t$ 代表 t 时间点的状态信息和候选状态信息。

5.2.2 随机森林

随机森林(Random forest)是机器学习中十分常见的分类算法，在回归问题上也具有良好的表现[13]。本文通过构造多棵独立的决策树并对结果取平均来解决过拟合问题，具有良好的泛化能力[14]。

对于随机森林算法而言，它是以 K 个决策树 $\{h(X, \theta_k), k = 1, 2, ..., K\}$ 为基本分类器，进行集成学习后得到的一个组合分类器。当输入待分类样本时，随机森林输出的分类结果由每个决策树的分类结果简单投票决定。这里的 $\{\theta_k, k = 1, 2, ..., K\}$ 是一个随机变量序列，它是由随机森林的两大随机化思想决定的：

（1）Bagging 思想：从原样本集 X 中有放回地随机抽取 K 个与原样本集同样大小的训练样本集 $\{T_k, k=1,2,...,K\}$，每个训练样本集 T_k 构造一个对应的决策树。

（2）特征子空间思想：在对决策树每个节点进行分裂时，从全部属性中等概率随机抽取一个属性子集（通常取 $\log_2(M)+1$ 个属性，M 为特征总数），再从这个子集中选择一个最优属性来分裂节点。

训练随机森林的过程就是训练各个决策树的过程，由于各个决策树的训练是相互独立的，因此随机森林的训练可以通过并行处理来实现，这将大大提高生成模型的效率。随机森林中第 k 个决策树 $h(X,\theta_k)$ 的训练过程如图 5.4 所示。

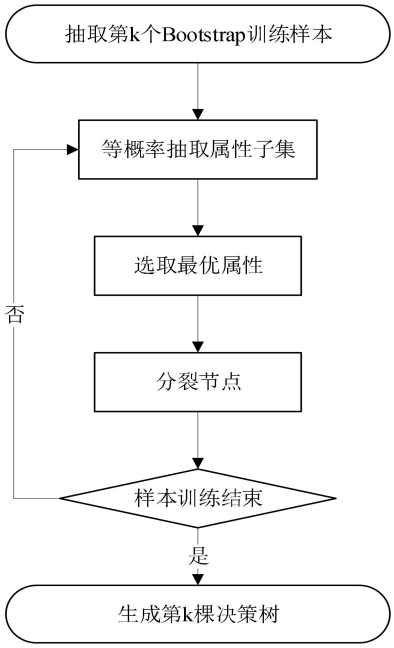


图 5.4 随机森林中单个决策树训练过程

将以同样的方式训练得到的 K 个决策树组合起来，就可以得到一个随机森林。当输入待预测的样本时，将每一棵决策树输出的结果取均值作为随机森林回归模型的结果。随机森林回归流程如图 5.5 所示。

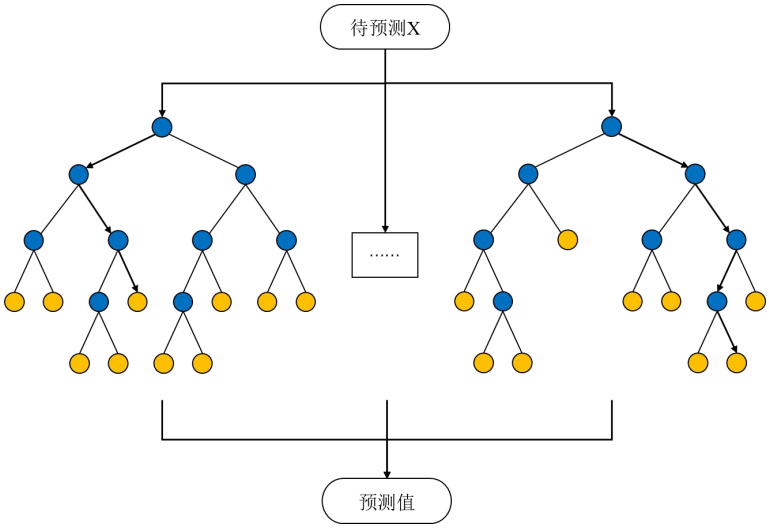


图 5.5 随机森林回归模型

综上，随机森林的算法描述如下：

随机森林算法描述

输入：随机抽取的样本集 $\{T_k, k=1,2,...,K\}$

输出：分类结果

Step 1：在生成每棵决策树时，随机有放回地从训练集中抽取 K 个训练样本，作为该决策树的训练集；

Step 2：在每一轮生成决策树的过程中，等概率随机抽取一个属性子集

Step 3：重复以上两步 K 次，即建立 K 个决策树

Step 4：通过投票表决结果，得到最终的输出结果

5.3 预测结果

5.3.2 总点击量预测结果

图 5.6 是训练集中某个用户所有历史记录总点击量的训练的结果。



图 5.6 某用户总点击量的训练结果

从图中可以看出，总体误差呈下降趋势，训练在 10 次循环之后，测试集的误差达到稳定状态，说明训练效果较好。

图 5.7 是每个用户总点击量训练结果在测试集上的误差分布。

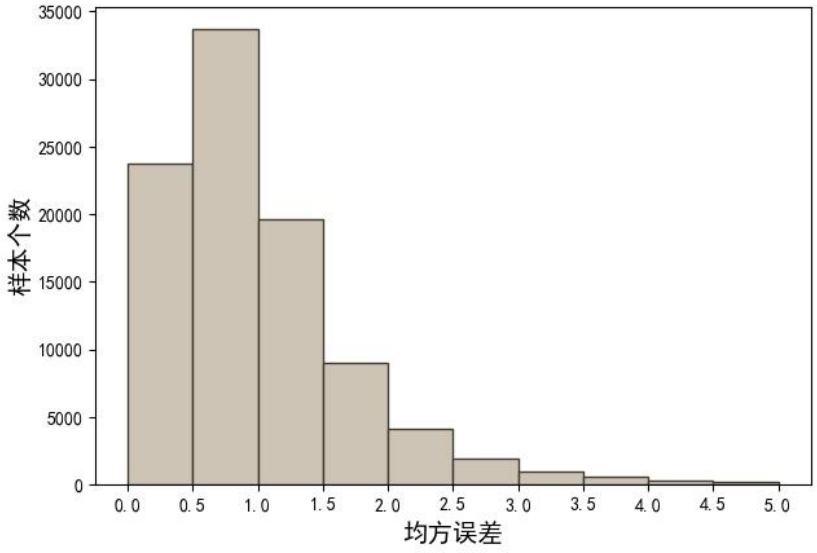


图 5.7 总点击量误差分布图

从误差分布图中可以看出总点击量预测的误差大多都集中在 0 到 2 之间，并且经过计算得到总点击量预测的平均误差为 1.0498。

图 5.8 为总点击量预测结果的分布图。

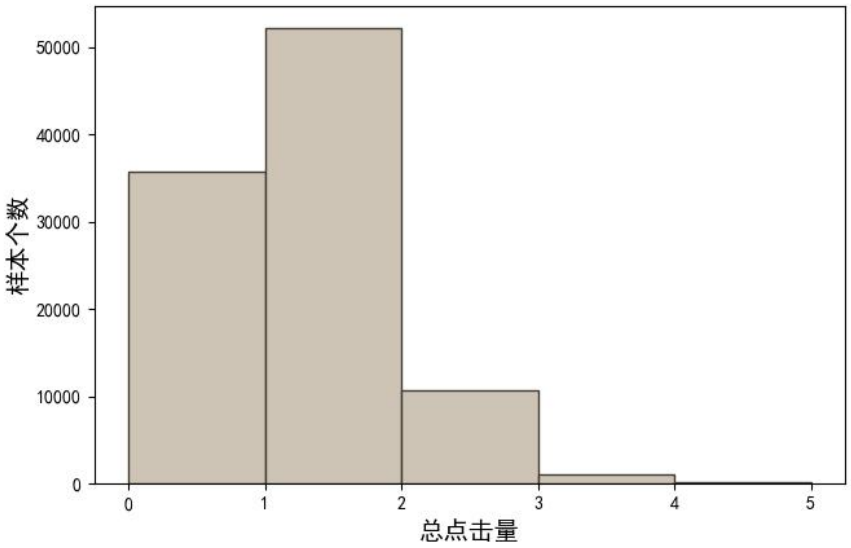


图 5.8 总点击量预测结果分布图

5.3.3 总浏览时长预测结果

图 5.9 是训练集中某个用户所有历史记录总浏览时长的训练后得到的随机森林可视化结果。

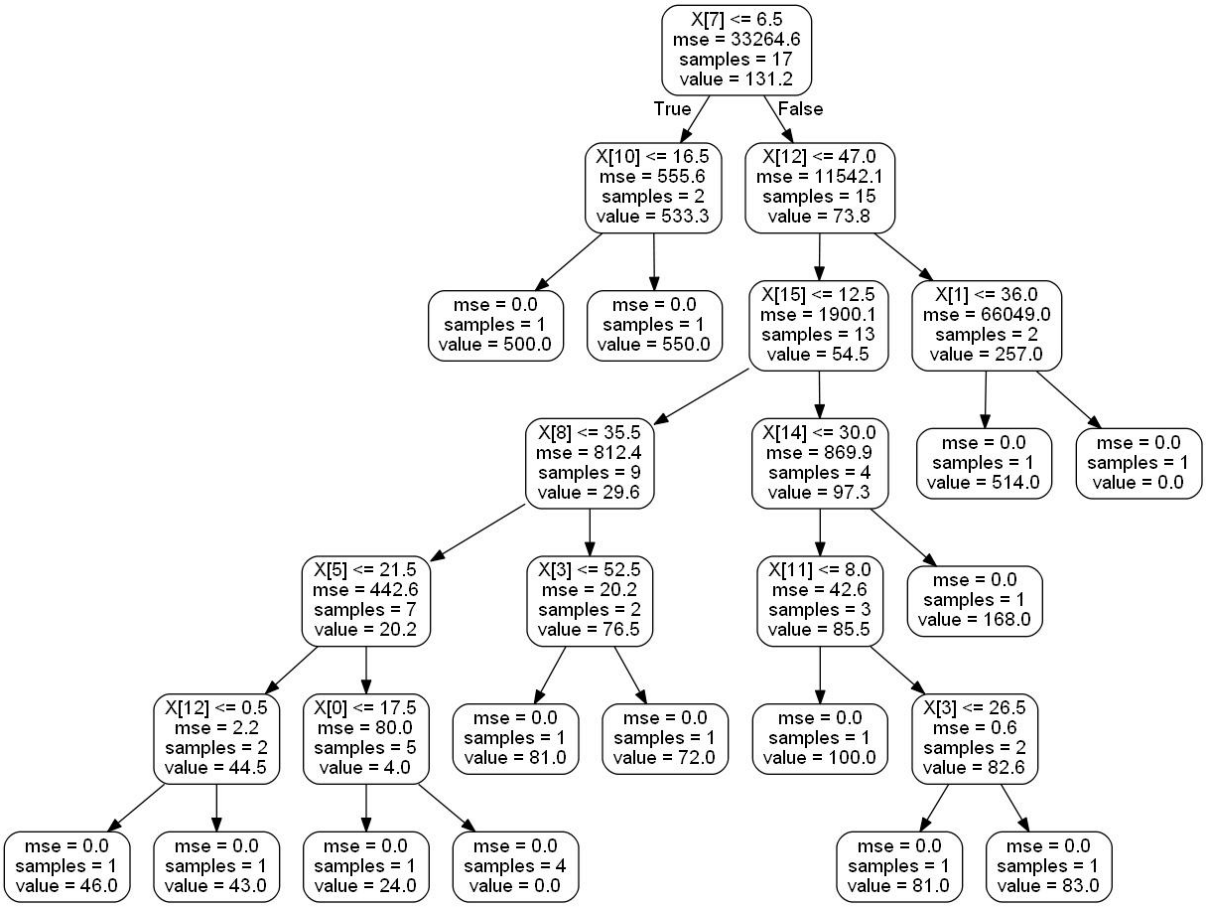


图 5.9 某个用户总浏览时长训练结果

其中，每个节点对应的是 X_train 中对应位置的数据，例如 X[10]为 X_train 中第 10 个位置的数据，从该图中可以看出每个位置对应数据的重要性以及该节点的均方误差。

图 5.10 是每个用户总浏览时长训练结果在测试集上的误差分布。

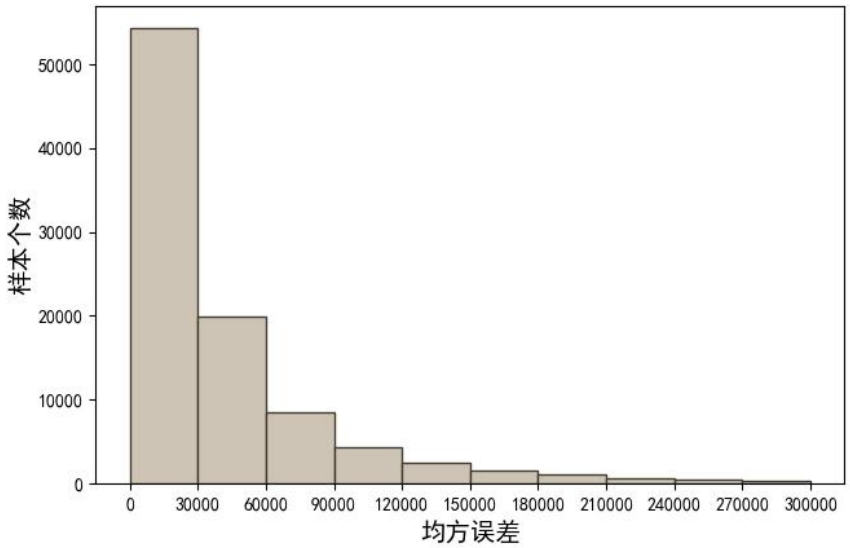


图 5.10 总浏览时长误差分布图

从误差分布图中可以看出总浏览时长预测的误差大多都集中在 0 到 120000 之间，并且经过计算得到总点击量预测的平均误差为 48025.32。

图 5.8 为总浏览时长预测结果的分布图。

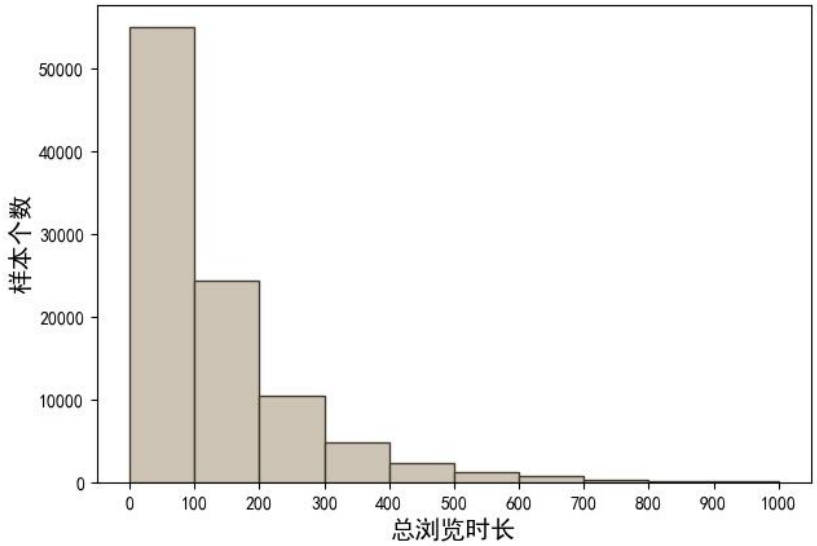


图 5.8 总浏览时长预测结果分布图

所有具体的预测结果见提交的附件。

六、问题三模型的建立与求解

6.1 算法介绍

假设有N条候选内容，要从中选取长度为K的推荐序列，若使用枚举法进行求解，可知需要计算A_N^K次，相应的算法的时间复杂度为$O(N!/(N-K)!)$，这对于工业界来说显然是很难以接受的。于是本文针对该问题，我们借鉴文献[9]的思想，提出了一种逐步优化算法（SOA），对成为最优序列概率较小的候选序列进行剪枝，降低时间复杂度，并在准确率和复杂度之间做出平衡。现给出逐步优化算法的过程：

***Step 1*：对位置偏好进行排序**

计算用户对第i个位置的点击量和浏览时长的总偏好权重$LP_i^C + LP_i^T$，对位置的总偏好权重按照从大到小的顺序进行排序，记序号集合$O = \{O_1, O_2, ..., O_K\}$，其中$O_i$表示第$i$个位置偏好的序号。例如当位置总偏好权重为0.3、0.1、0.5、0.4时，序号为3、4、1、2。通过位置总偏好权重的排序序号，在逐步将候选内容存放于推荐序列时，应尽量先满足偏好中序号靠前的位置，这样能使得到的候选序列集合中有更大可能性包含最优序列。

***Step 2*：初始化**

设$List = \{list_1, list_2, ..., list_Z\}$为推荐序列的候选集合，$list_z$为第$z$条候选序列（$z = 1, 2, ..., Z$）。在初始状态时，$z = 1$，$i = 1$，$list_z$为空集。

***Step 3*：计算收益**

对于第i次添加（对于长度为K的推荐序列，一共能添加K次内容），选择一条未被添加入$list_z$序列中候选内容，放入推荐序列中序号为O_i的位置上，并计算此时每个候选序列的总收益$profit_z$。当序列内容未满时，将缺少内容的位置的收益记为0，计算过程见问题一中的模型分析。

***Step 4*：剪枝**

令$Maxp$和$Minp$分别表示序列候选集中总收益的最大值和最小值，$Maxp = \max\{profit_z\}$，$Minp = \min\{profit_z\}$。在这一步，我们保留总收益在$\left[Minp + \beta(Maxp - Minp), Maxp\right]$之间的推荐序列。参数$\beta$作为SOA算法的输入，起平衡准确率复杂度的作用。直观的说，若β设置的较小，即代表在每次迭代中将会考虑从更多的推荐序列，当$\beta = 0$时，SOA算法将在每次迭代中考虑所有的可能结果，此时相当于枚举法。相反地，当$\beta = 1$时，每次迭代指挥保留总收益最高的序列，此时SOA算

法相当于贪心算法。具体对于 β 参数的设置，将在下一节进行讨论。

***Step 5*：判断结束**

当 $i=k$ 时，则算法结束，输出此时 *List* 中总收益最高的推荐序列作为最优序列；当 $i<k$ 时，则跳转到 ***Step 3***，将内容继续填补入序列的空余位置。

逐步优化算法的伪代码如下：

逐步优化算法 Step-wise Optimization Algorithm

输入：参数 β，序列长度 K（迭代次数），N 条候选内容集 $R=\{r_1,r_2,...,r_N\}$，候选序列集合 *List*，待添加的内容位置 i，位置总偏好权重 $LP_i^C+LP_i^T$

初始化：$list_z$ 为第 z 条候选序列，$z=1$，$i=1$，$list_z$ 为空集

$O_i \leftarrow LP_i^C+LP_i^T$ //对位置偏好权重进行排序

for $i=1$ **to** K **do**

$List_z[O_i] \leftarrow r_t$ //将未被添加入 $list_z$ 序列中的候选内容放在序号为 O_i 的位置上

$profit \leftarrow profit_z$ //计算每个候选序列的总收益

$Maxp \leftarrow \max\{profit_z\}$ //找出序列候选集中总收益的最大值

$Minp \leftarrow \min\{profit_z\}$ //找出序列候选集中总收益的最小值

$List \rightarrow profit \in [Minp+\beta(Maxp-Minp),Maxp]$ //保留总收益在该区间之间的序列

end for

6.2 实验和参数分析

我们从训练集（train. txt）中随机挑选 30 条候选内容作为算法分析的实验数据，候选内容如下表所示：

表 6.1 实验候选内容数据表

编号	内容 ID	用户是否点击	用户浏览时间
1	133669542676	1	148
2	133658378700	1	16
3	133650937891	1	85

4	133663959878	1	221
5	506898339	0	0
6	133658512070	1	101
7	133660220952	1	60
8	506770575	0	0
9	133673154438	1	102
10	133660292493	0	0
11	133660292493	1	120
12	508420199	0	0
13	133669581685	1	19
14	508486431	1	238
15	133684825985	0	0
16	507179898	1	55
17	133643001955	0	0
18	507228464	0	0
19	507164385	0	0
20	507110881	0	0
21	506498342	0	0
22	506924818	1	42
23	133680213699	0	0
24	507164377	1	25
25	507668079	0	0
26	507555242	0	0
27	133680576345	0	0
28	507250919	0	0
29	508896132	1	111
30	508870333	1	10

6.2.1 对参数 β 的灵敏度分析

为了探究参数 β 对算法效果的影响，我们提出了三个指标：近似率（Approximation rate）、优越性（Superiority）、时间性（Time）。下面对三个指标进行具体解释。

（1）算法结果近似率（Approximation rate）

我们用近似率的大小可以表示本文的 SOA 算法所求的序列与枚举法求出的最优序列之间的近似程度，计算公式如下：

$$Ar(\beta)=\frac{profit(\beta)}{profit(0)} \tag{6-1}$$

其中，$profit(\beta)$ 表示在 SOA 算法参数取值为 β 时最优推荐序列的总收益。$profit(0)$ 为参数取值为 0 时（枚举法）最优序列的总收益。

（2）算法优越性（Superiority）

优越性的大小可以衡量本文 SOA 算法的所求序列的收益相对于所有序列收益的优于程度。计算公式如下：

$$Sr(\beta)=\frac{Lower(profit(\beta))}{Count} \tag{6-2}$$

其中，$Lower(profit(\beta))$ 表示在参数 β 取值情况下，总收益低于求出的最优序列总收益的候选序列的数量。$Count$ 表示候选推荐序列的总数量。

（3）时间性（Time）

在这里，我们计算本文的 SOA 算法的相对时间，其中 $time(\beta)$ 表示在参数取值为 β 时算法的运行时间，$time(0)$ 表示在参数取值为 0 时（枚举法）算法的运行时间。

$$Time(\beta)=\frac{time(\beta)}{time(0)} \tag{6-3}$$

基于上述三个指标，我们通过实例数据对参数 β 进行灵敏度分析。选取表 6.1 中的前 20 条候选内容，令 $K=4$，即从 20 条候选内容中选择长度为 4 的最优推荐序列。为了使结果更具有一般性，我们将实验重复进行 100 次，并将实验结果取平均值，实验得到的三个指标结果如下：

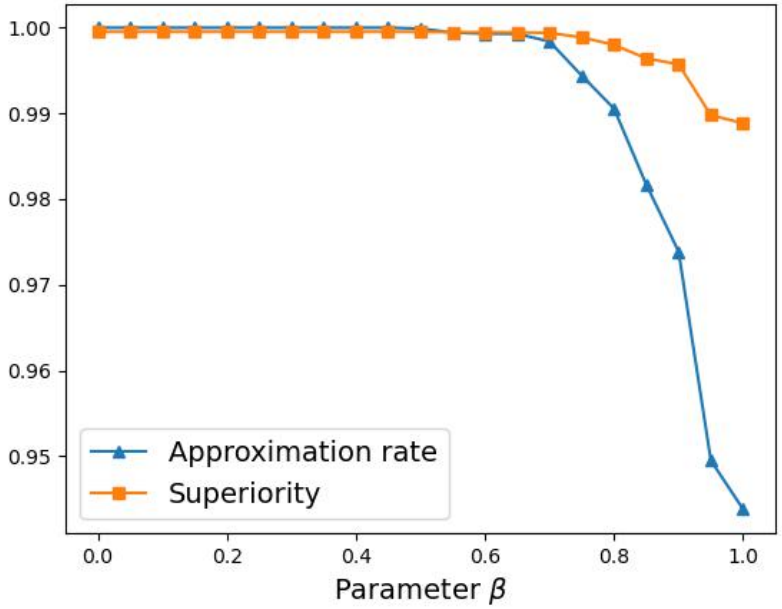


图 6. 1 近似率和优越性趋势图

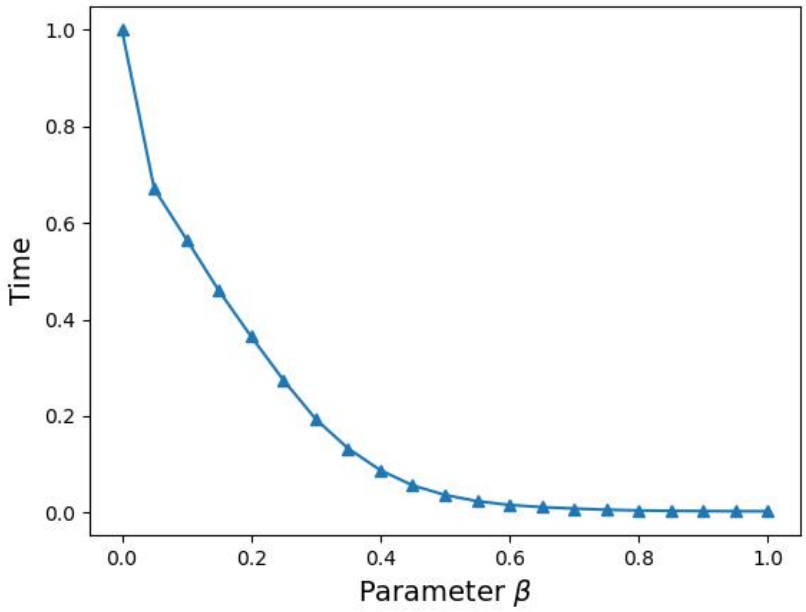


图 6. 2 时间性趋势图

根据指标的定义可知，近似率和优越性属于效益型指标，即 $Ar(\beta)$ 和 $Sr(\beta)$ 越接近于 1，表明在参数取值为 β 时，算法得到的推荐序列具有较高的表现，由图 6.1 可知，无论 β 取何值，$Ar(\beta)$ 和 $Sr(\beta)$ 都能保持一个较好的结果（均在 95%以上），但随着 β 的增加，$Ar(\beta)$ 指标有明显的下降，由算法步骤可知 β 的增加会导致候选序列集进行大量的剪枝，其中剪掉的可能会包含枚举法中的最优推荐序列。此外，时间性属于成本型指标，$Time(\beta)$ 越接近于 0 表明算法的时间复杂度越低，由图 6.2 可知，随着 β 的增加，对候选序列集会进行大量的剪枝操作，相应的时间性指标会迅速下降。

本文还讨论了参数 β 对候选序列集 $List$ 中搜索广度的影响，我们计算了每次剪枝迭

代后，保留下来的候选序列在原始的总候选序列中的占比，结果如图 6.3 所示：

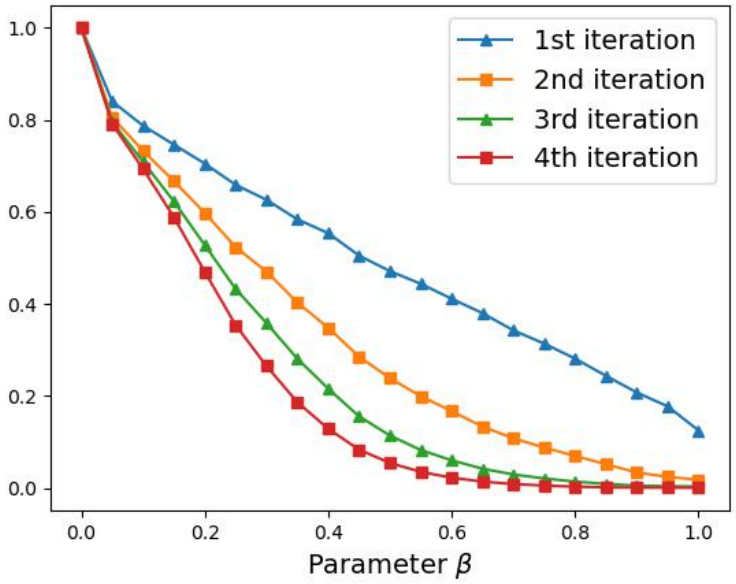


图 6. 3 剪枝迭代后留存序列的占比

由图 6. 3 可知，面对给定的参数 β 取值，候选序列集成比例减少；且随着 β 的增加，留存的候选序列中的数量下降速度增加。故图 6.3 同样可以印证图 6.2 中的趋势变化，即随着 β 的增加，算法时间显著下降，并且随着迭代次数的增加，留存序列的比例下降，这是因为随着迭代次数的增加，问题的解空间急剧增大，大于留存序列增加的幅度。

最后为了综合考虑上述三个指标选出最优参数 β 值，我们给出一个综合衡量指标 $\Delta effectiveness(\beta)/\Delta efficiency(\beta)$ ，其中 $\Delta effectiveness(\beta)=Ar(\beta)-Ar(\beta+0.05)$ 或 $\Delta effectiveness(\beta)=Sr(\beta)-Sr(\beta+0.05)$，$\Delta efficiency(\beta)=Time(\beta)-Time(\beta+0.05)$。经实例计算，综合衡量指标结果如图 6.4 所示：

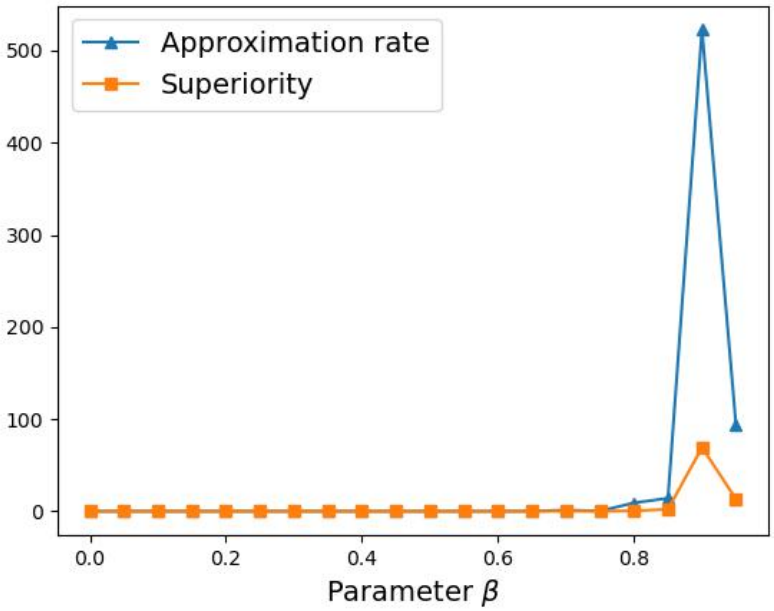


图 6. 4 综合衡量指标趋势图

由图可知，当 $\beta = 0.9$ 时，综合衡量指标在近似率和优越性上同时取得最优效果，但同时要注意到的是，图 6.1 中已指出 $Ar\left(0.9\right) = 97.3\%$，即可能出现算法计算的最有序列不一定是枚举法中的最优序列，但是本文的 SOA 算法可以在准确率和复杂度上做出一个平衡，即我们在极大程度的降低时间复杂度的情况下，能够给出一个较为准确的最优序列（即获得最高收益的序列）。

6.2.2 算法性能的比较分析

为了对比所提出的 SOA 算法在解决寻找最优推荐序列问题上的优势，本文选取了几个对照算法，分别为贪婪算法[15]、模拟退火算法[16]、遗传算法[17]和随机选取。

（1）给定 K 值

根据表 6.1 中的候选内容，令 $K = 4$，$N = 21,22,...,30$，比较当序列长度为定值、候选内容集数量变化时，不同算法在寻找最优推荐序列收益与真实最优序列收益值的近似率。结果如下图所示：

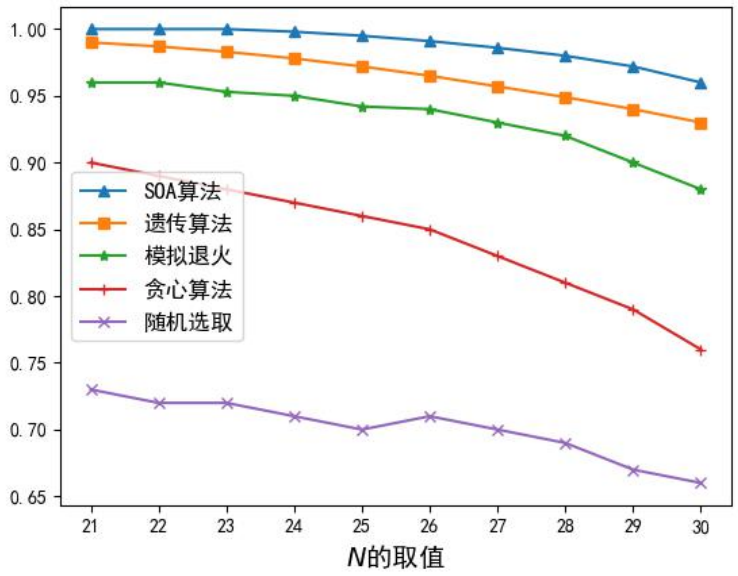


图 6.5 候选内容数量变化时不同算法的性能比较

随着 N 不断增加，候选序列的排列组合数呈阶乘级增长，相应的需要比较和剪枝的序列收益也随之增加，不同算法的整体近似率都会呈现下降趋势。但由图 6.5 可知，本文的 SOA 算法的近似率始终保持在一个较高的水平（95%以上），且远远优于其他算法。

（2）给定 N 值

类似的，根据表 6.1 中的候选内容，令 $N=30$，$K=4,5,...,13$，比较当候选内容集数量为定值，改变推荐序列长度，不同算法在寻找最优推荐序列收益与真实最优序列收益值的近似率。结果如下图所示：

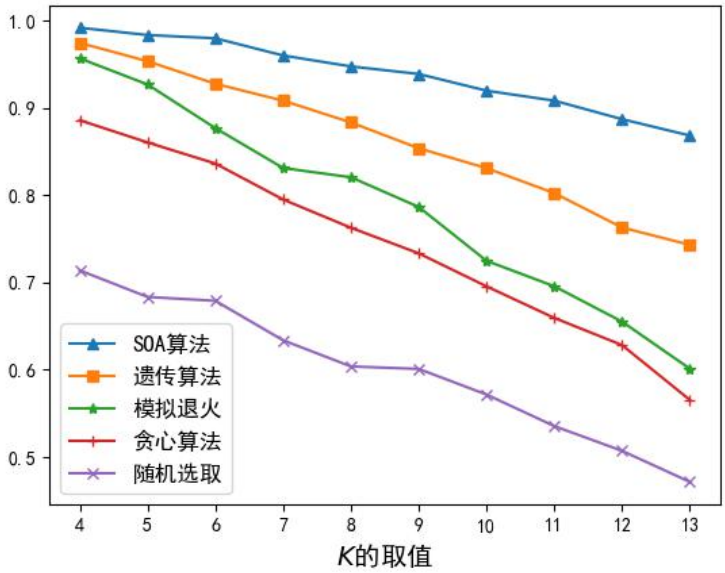


图 6.5 序列长度变化时不同算法的性能比较

当 K 值越小时，SOA 算法迭代的次数越少，相应的在最后一次迭代后，候选序列集 *List* 中留存的序列里越有可能包含真实的最优序列。同样由图 6.5 可知，随着 K 值的增加，留存的候选序列占比越少，收益结果的近似率相应的降低，但相比于其他算法的近似率，本文的 SOA 算法仍能始终保持在最高的性能水平。

七、评价与推广

7.1 模型评价

基于以上分析，本文较好地解决了题目所提的三个问题，并且通过实例研究，验证了本文模型和算法相较于其他模型而言具有显著的优越性。**针对问题一**，本文的数学模型综合考虑了用户对内容类别和类型的偏好，从历史数据角度出发，通过计算用户对序列中位置的偏好权重，解决了不同排列组合对收益大小的影响问题。**针对问题二**，本文选取 GRU 模型和随机森林分别对推荐序列的点击量和浏览时长进行预测，较好地实现了问题需求，并对预测效果进行了可视化处理。**针对问题三**，本文提出了一种逐步优化算法对候选序列进行剪枝，以更低的时间复杂度可以得到更为精确的最优推荐序列。此外，本文还给出了模型中的市场参数设置，充分展现了本文模型具有较好的市场适应性，更易被工业界所接受。

针对本文的工作，我们还可以对模型和算法进行推广，如问题三中的逐步优化算法可以将其应用于微博热搜排名、在线评论列表排名等大数据应用场景中。

但由于时间精力有限，本文还存在一些不足之处，如当 K 值发生变化时，如何考虑位置偏好权重之间的相关性；用户对在不同时间点对推荐内容是否有不同的偏好；此外预测值基于历史数据，训练集中的历史数据的时间跨度较短，且测试集中还存在用户冷启动问题，那么如何实现较为精准的预测仍是丞待解决的问题，这些都还需要进一步的研究分析[18]。

7.2 模型推广

针对本文的工作，我们还可以对模型和算法进行推广，如问题三中的逐步优化算法可以将其应用于微博热搜排名、在线评论列表排名等大数据应用场景中。

参考文献

[1] Xue F. Facebook news feed ads: a social impact theory perspective[J]. Journal of Research in Interactive Marketing, 2019, 13 (4): 529-546.

[2] Dallmann A, Zoller D, Hotho A. A Case Study on Sampling Strategies for Evaluating Neural Sequential Item Recommendation Models[C]. Fifteenth ACM Conference on Recommender Systems, 2021: 505-514.

[3] 杨娟. 移动互联网时代的信息流广告研究[D].武汉大学,2019.

[4] 李金忠, 刘关俊, 闫春钢, 等.排序学习研究进展与展望[J]. 自动化学报, 2018, 44 (08): 1345-1369.

[5] 黄震华, 张佳雯, 田春岐, 等.基于排序学习的推荐算法研究综述[J]. 软件学报, 2016, 27 (03): 691-713.

[6] 倪鸿志. 面向推荐系统的机器学习算法研究[D].电子科技大学,2020.

[7] Anelli V W, Deldjoo Y, Di Noia T, et al. How to put users in control of their data in federated top-N recommendation with learning to rank[C]. Proceedings of the 36th Annual ACM Symposium on Applied Computing, 2021: 1359-1362.

[8] 程凡, 李龙澍.基于 Listwise 的新型排序算法[J]. 计算机工程, 2011, 37 (23): 165-167.

[9] Wang Y, Wang L, Li Y, et al. A theoretical analysis of NDCG ranking measures[C]. Proceedings of the 26th Annual Conference on Learning Theory (COLT 2013), 2013: 6.

[10] Zhang Z, Chen G, Zhang J, et al.Providing Consistent Opinions from Online Reviews: A Heuristic Stepwise Optimization Approach[J].INFORMS Journal on Computing, 2016, 28 (2): 236-250.

[11] Huang J, Zhao W X, Dou H, et al. Improving sequential recommendation with knowledge-enhanced memory networks[C].The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval, 2018: 505-514.

[12] Dey R, Salem F M. Gate-variants of gated recurrent unit (GRU) neural networks[C]. 2017 IEEE 60th International Midwest Symposium on Circuits and Systems (MWSCAS), 2017: 1597-1600.

[13] 王宇恒. 推荐系统中随机森林算法的优化与应用[D].浙江大学,2016.

[14] Liaw A, Wiener M.Classification and regression by random forest[J]. R news, 2002, 2 (3): 18-22.

[15] Benouaret I, Amer-Yahia S, Roy S B. An Efficient Greedy Algorithm for Sequence Recommendation[C].International Conference on Database and Expert Systems Applications,2019: 314-326.

[16] Ye Z, Xiao K, Ge Y, et al. Applying simulated annealing and parallel computing to the mobile sequential recommendation[J].IEEE Transactions on Knowledge Data Engineering, 2018, 31 (2): 243-256.

[17] Mirjalili S. Genetic algorithm, Evolutionary algorithms and neural networks. Springer, 2019: 43-55.

[18] 黄立威, 江碧涛, 吕守业, 等.基于深度学习的推荐系统研究综述[J].计算机学报, 2018, 41 (07): 1619-1647.