队伍编号	MCB2302926
赛道	B

基于 ARIMA 与 LSTM 时间序列的电商产品需求量预测

摘　要

可靠的用户需求量预测，对电商平台各商家对仓库、商品的管理和决策非常重要。本文对于商家、仓库、产品在时间序列上的需求量进行分析及预测，针对不同情况得到不同情况下的需求量预测情况。

针对问题一，本文首先对于数据进行预处理，对于附件 1 中的商家、仓库、产品的编号进行组合合并成 **1996** 种，如 29-1-915 为一个组合并在后文统称组合，通过可视化图表发现**“双 12”购物节**和**春节时间段**各商品的需求量出现明显与平时期间异常的波动，因此对于这部分时间进行剔除，预测所采用的需求量数据从 2023 年 2 月 1 日开始到 2023 年 5 月 15 日。针对预处理之后的数据，本文采用 **ARIMA 时间序列**和 **LSTM** 两种方法对组合 2023 年 5 月 16 日到 5 月 30 日的需求量进行预测，其中 ARIMA 时间序列本文通过 python 语言设置循环语句用 **AIC 准则**选取最小的 AIC 得到所需的 p、d、q 值进行预测，LSTM 采用 MATLAB 编程实现 LSTM 时间序列预测，两个方法算出来的平均 **1-wmape** 分别为：**0.7628**、**0.8344**。通过 1-wmape 的值对两种方法进行赋权相加得到最终结果。对于聚类本文使用 **K--means 聚类**按照不同的聚类标准，将 1996 个组合分别聚成 **4 类**和 **5 类**，并运用**主成分分析法（PCA）**降维实现可视化效果。

针对问题二，本文同样对于附件 5 中提供的新维度的数据进行组合，附件 5 中的新组合共有 **210** 个，再将附件 5 中的新组合按照出现的时间分为 **5 类**，其中 4 月 1 日到 4 月 5 日出现的组合为一类，以此类推，其中每组分别含有 **66、29、57、42、16** 个组合，再分别对每组的组合与附件 1 中的组合计算 **Spearman 相关系数**，找到相关性最高的组合且 **P 值小于 0.05**，如附件 5 中的组合 14-21-239 对应附件 1 中的组合 35-53-1423，其 Spearman 相关系数为 **0.8685** 且 P 值为 **3.83E-13** 远小于 0.05，每个附件 5 中的组合都在附件 1 中找到与之对应的相关性最强的组合，再将附件 5 中每个组合的数据带入问题一中已经训练完的 LSTM 和 ARIMA 时间序列方程中得到附件 5 中新组合在 2023 年 5 月 15 日到 2023 年 5 月 30 的需求量预测值，预测结果详见附录。

针对问题三，本文对于附件 6 数据进行组合共有 1957 个组合，再通过对于数据的可视化处理发现用户在 11 月 1 日到 11 月 11 日的需求量出现先上升后下降在上升的整体趋势，结合各店商在 “双 11”的促销安排，可以大致将“双 11”购物节分为三个阶段：**开门红、品类日&主题日、高峰期&狂欢日**。本文对于“618”期间的个组合预测分为两步，即正常预测与引入**购物节因子**（品类因子、地区因子），因此首先对于“618”期间各组合的需求量通过 ARIMA 时间序列与 LSTM 赋权相加进行如平时期间相同的预测，第二步再计算各一级分类商品在“双 11”期间的品类因子，如宠物生活在“双 11”中每天的**品类因子**即为 **1.0482，1.4386，1.8240，1.4737** 等等，再计算各地区在“双 11”期间的地区因子，如东北地区在“双 11”中每天的**地区因子**为 **2.3006，2.0367，1.6779，1.6252** 等等，通过“双 11”购物节的购物节因子按照分成的三个阶段进行线性插值得到“618”期间的品类因子和地区因子。通过 ARIMA 时间序列和 LSTM 赋权相加的预测结果结合两种因子的约束条件，得到“618”期间需求量预测值，预测结果详见附录。

关键词：ARIMA 时间序列　LSTM　购物节因子　Spearman 相关系数　K-means 聚类

目录

基于 ARIMA 与 LSTM 时间序列的电商产品需求量预测 1
摘　要 1
一、 问题重述 4
1.1 问题背景 4
1.2 问题提出 4
二、 问题分析 4
2.1 问题一的分析 4
2.2 问题二的分析 5
2.3 问题三的分析 5
三、 模型假设 6
四、 符号说明 6
五、 问题一模型的建立与求解 7
5.1 数据预处理 7
5.1.1 对附件一中商家、仓库、产品进行组合 7
5.1.2 预测所需时间区间筛选 7
5.1.3 各商家各仓库各商品的筛选 8
5.2 问题一预测模型的建立与求解 9
5.2.1 ARIMA 时间序列模型的建立与求解 9
5.2.2 LSTM 模型的建立与求解 13
5.2.3 最终结果的计算 16
5.3 问题一分类模型的建立与求解 17
5.3.1 聚类指标的选取 17
5.3.2 K-means 聚类及主成分分析模型的建立与求解 17
六、 问题二模型的建立与求解 22
6.1 数据预处理 22
6.1.1 对附件 5 中新出现的商家、仓库、产品进行组合 22
6.1.2 针对新组合出现时间进行分类 22
6.2 相关性分析，寻找相似时间序列 23
6.3 通过相似序列所得公式预测未来需求量 24
七、 问题三模型的建立与求解 25
7.1 数据预处理 25
7.1.1 对附件一中商家、仓库、产品进行组合 25
7.1.2 双 11 购物节整体数据的可视化展示及描述性统计 25
7.2 双 11 购物节活动分析 26
7.2.1 “双 11”购物节时间区间分析 26
7.2.2 双 11 购物节产品品类数据分析 26
7.2.3 双 11 购物节地区购物数据分析 27
7.3 以双 11 购物节预测 618 购物节各组合需求量 28
7.3.1 “618”购物节时间区间划分 28
7.3.2 未加因子的时间序列预测 28
7.3.3 “618”期间需求量预测——加入地区因子 29
7.3.4 “618”期间需求量预测——在地区因子的约束下加入品类因子 29
八、 模型的评价、改进与推广 30

8.1 模型的优点 30
8.2 模型的缺点 30
8.3 模型的改进 30
九、 参考文献 31
附录 32

一、 问题重述

1.1 问题背景

电商平台拥有上千个商家，商品货物会被放在配套仓库。大数据智能供应链可以明显降低库存成本，并且商品可以尽快履约。

需求预测往往是供应链决策的基础，此时需要根据历史一段时间的商品需求预测未来商品需求，一般企业会根据历史情况分析出需求量序列的数理特征，对相似需求量序列进行归类，并根据分类结果进行预测。不过，实际任务中，部分商品和仓库的调整和购物节等不规律性，也给需求量预测提高了难度。需要找到一般历史规律，进行精准预测。

库存优化方面，企业往往会选择定期盘点库存策略，即库存商品小于库存下限企业会对库存进行补货至库存上限，其中还需要计算盘点周期和提前期。库存策略需要在满足用户订单，防止缺货和库存过多提升的库存成本进行取舍。库存优化目标分别为：减少库存总成本，满足用户需求，降低库存周转所需要的天数。

1.2 问题提出

附件一为各商家在各仓库的各商品在 2022 年 12 月 1 日到 2023 年 5 月 15 日的需求量表；附件二、三、四分别为商品、商家、仓库的信息表；附件五为新增商品在 4 月 1 日至 5 月 15 日的需求量表；附件六为附件一维度的促销期间商品的需求量表。

针对问题一，通过附件 1 到 4 的数据，预测出各商家个仓库的各种商品在 2023 年 5 月 16 日到 2023 年 5 月 30 日的需求量，并且对模型进行评价，另外对于对商品进行聚类，使同一类别在需求上最相似。结果填入结果表 1。

针对问题二，附件五中给出了商家+仓库+商品的新维度，新出现的预测维度通过附件 1 中的数据进行参考，找到相似序列完成新的维度的预测值。结果填入结果表 2。

针对问题三，结果附件六中去年双 11 的需求量数据，参考双 11 数据，预测数 2023 年 6 月 1 日至 2023 年 6 月 20 日的预测值。结果填入结果表 3。

二、 问题分析

2.1 问题一的分析

针对问题一，需要首先对附件中数据进行预处理，本文选择将附件 1 中的商家、仓库、产品三个编码进行合并作为组合，并将需求量波动强烈的“双 12”和春节期间的数据当做异常值去除，为保证需求量的精准预测并且将长期需求量为 0 的组合进行剔除。本文对剩下的组合采用 ARIMA 时间序列预测与 LSTM 时间序列预测相结合的方法进行预测，并通过 1-wmape 指标对其进行评价，通过该评价指标的值对两种预测方法进行赋权，将两种方法相结合得出预测结果。

对于聚类问题，本文从两个方向选择聚类指标：第一方面是各组合的需求量序列的实力特征指标，第二方面是各组合本身的性质特征（附件 2-4 中商家、仓库、产品的信息）。运用主成分分析法对多维指标进行降维处理，再通过降维数据采用 k-means 聚类方法，进行聚类，得到聚类结果。

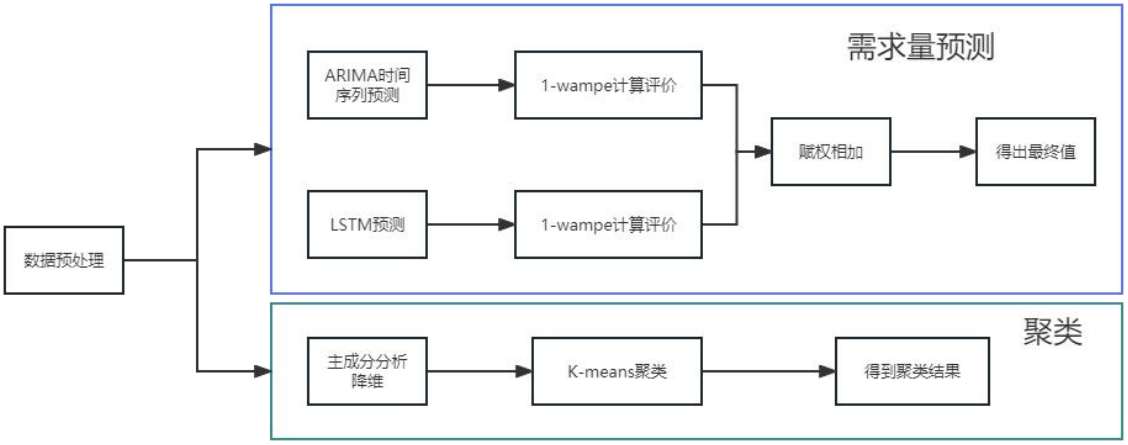


图 1：问题一分析的流程图

2.2 问题二的分析

针对问题二，本文首先对于附件 5 中的数据如问题一一样进行上、仓库、产品三个编码进行合并作为新组合，并将附件 5 中的组合按照出现时间分为 5 类，如 4 月 1 日-4 月 5 日出现的组合作为 1 类，通过分别对 5 类新组合和附件 1 中组合在共有的时间序列上的需求量进行 Spearman 相关系数的计算，对附件 5 中每一个新组合找到附件 1 中对应的组合使得这两个组合之间 Spearman 相关系数最大并且 p 值小于 0.05.再利用附件 1 中的组合在问题一中已得到的 ARIMA 时间序列模型得到的方程和 LSTM 得到的训练结果带入附件 5 中给的数据，对附件 5 中新组合进行预测得到结果。

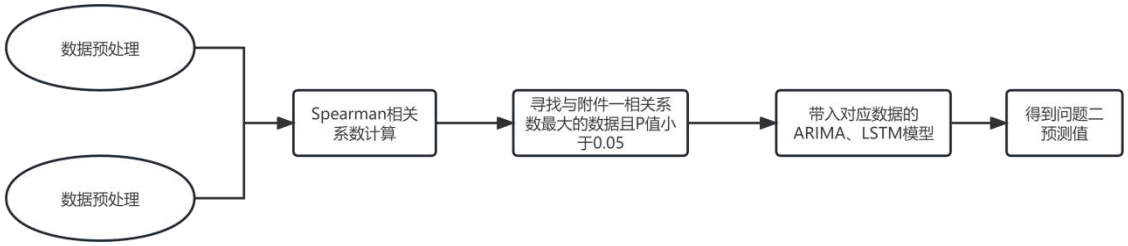


图 2：问题二分析的流程图

2.3 问题三的分析

针对问题三，首先对于双 11 期间的每天商品的需求量及进行可视化展示，根据各电商平台“双 11”促销时间表和可视化结果，把“双 11”期间分为三个阶段：开门红、品类日&主题日、狂欢日&高峰期；并针对不同一级分类的商品计算“双 11 期间”的品类因子，针对不同地区的商品计算“双 11”期间的地区因子。本文对于“618”期间各组合的需求量预测分为两步：第一步是通过 ARIMA 时间序列和 LSTM 赋权方法（同问题一）进行 6 月 1 日至 6 月 20 日无购物节的需求情况预测，第二步则是将“双 11”中的品类因子和地区因子引入到“618”期间的各组合预测中，通过这两步得到“618”期间各组合的需求量预测情况。

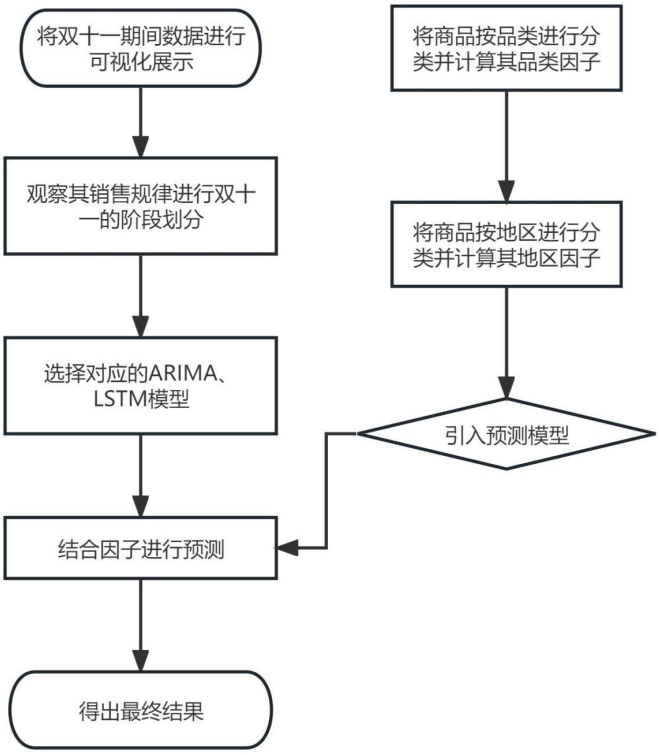


图 3：问题三分析的流程图

三、 模型假设

1.假设一：不计附件以外其他因素对各类商品、商家、仓库的信息的影响。
2.假设二：附件所给数据真实有效且能够全面反映真实情况，不存在数据漏记重复记录等数据收集问题。
3.假设三：数据是有关联的，学习数据可反映预测数据的潜在规律，不存在不同时段之间出货量完全不相关的情况。

四、 符号说明

符号	说明
w_{ARIMA}	ARIMA 时间序列预测值权重
w_{LSTM}	LSTM 预测值权重
$demand_{i,d}^{11}$	在“双 11”期间第 i 个组合在第 d 天的需求量
$demand_{i,d}$	第 i 个组合在 2023 年 2 月 1 日开始第 d 天的需求量
$DQfactor_{L,d}$	第 L 个地区在 618 期间第 d 天的地区因子
$PLfactor_{n,d}$	第 n 种一级分类商品在第 d 天的品类因子
$r_{i,d}$	第 i 个组合在 2023 年 2 月 1 日之后的第 d 天有无出货量（0-1 变量）
…	…

五、 问题一模型的建立与求解

5.1 数据预处理

5.1.1 对附件一中商家、仓库、产品进行组合

题目中提供了商家、仓库、产品三个维度，并且每个维度都有各自的编码，本文为了明确指标，首先对于附件一中的数据将商家、仓库、产品编码进行整合，将一个商家的一个仓库中的一种商品的数字编号进行组合形成一个新的编码，新的组合编码中包含商家、仓库和产品的编码信息，下文中将一个商家的一个仓库中的一种商品简称为组合，具体的组合编码方式如下表所示：

表 1 ：编码组合表

商家编码	仓库编码	产品编码	组合编码
seller_19	wh_30	product_448	19-30-448
seller_11	wh_1	product_148	11-1-148
seller_28	wh_45	product_818	28-45-818

通过表 1 方式组合，遍历附件 1 中所有商家、仓库、产品共有 1996 种组合方式。

5.1.2 预测所需时间区间筛选

通过整合从 2022 年 12 月 1 日至 2023 年 5 月 15 日每日需求量的整体数据如下图所示：

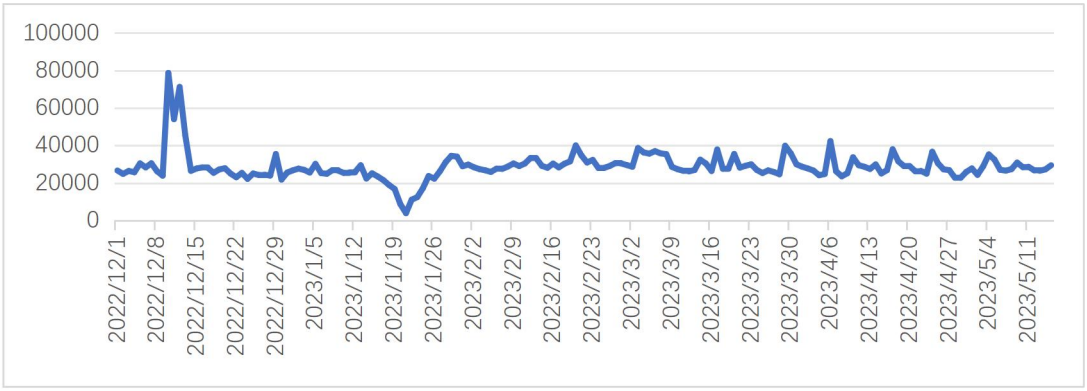
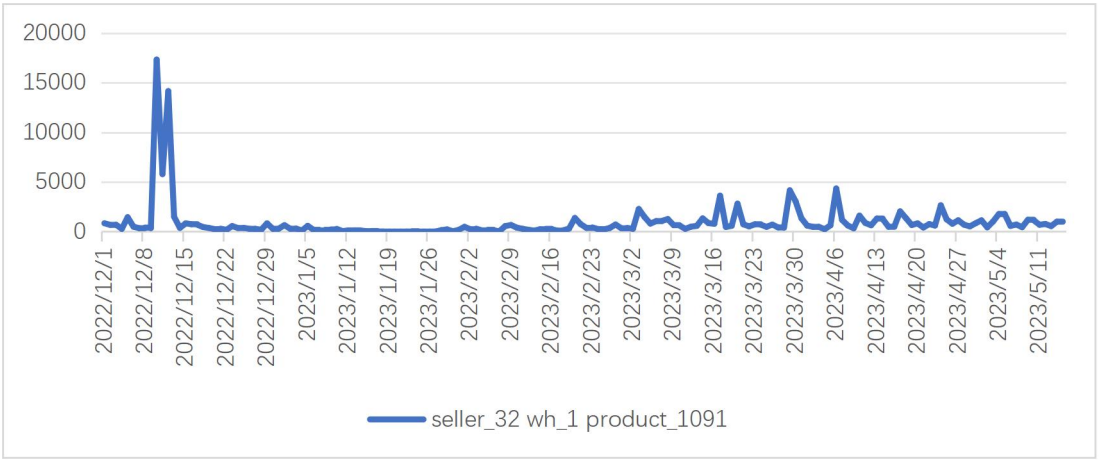


图 4：单日总需求量折线图



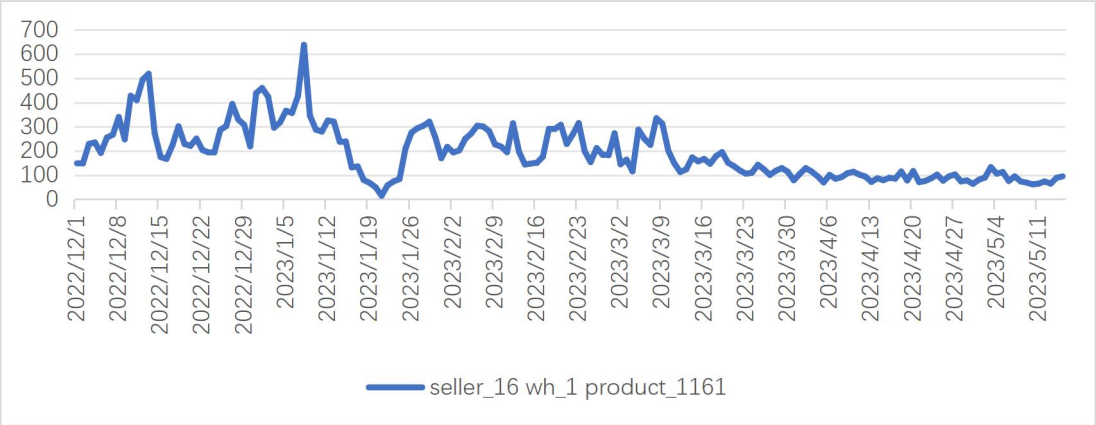


图 5：seller_32 wh_1 product_1091 和 seller_16 wh_1 product_1161 单日需求量折线图

通过图 4 可以看出，由于 12 月具有双 12 购物节日，1 月份具有春节，这两个因素，导致单日总需求量在 12 月和 1 月相比 2 月份到 5 月份具有明显波动，微观方面，通过图 5 中 seller_32 wh_1 product_1091 和 seller_16 wh_1 product_1161 这两个商家仓库的商品需求量图也可以明显看出在双 12 以及春节期间，需求量波动相比普通日期波动较大，对于正常日期的预测的参考价值过小，因此本文对于 2023 年 5 月 16 至 2023 年 5 月 30 日的商品需求量预测采用 2023 年 2 月 1 日至 2023 年 5 月 15 日的需求量数据来进行预测。

5.1.3 各商家各仓库各商品的筛选

通过对于附件 1 中的数据进行查看，发现附件 1 中的数据存在大量为 0 的值，如果某商家某仓库某商品长期需求量为 0，那么对于该维度的本商品来说，对于他的需求量预测会受到大部分数为 0 的影响，导致预测结果较差，因此本文在预测 2023 年 2 月 1 日至 2023 年 5 月 15 日的需求量前，先通过下式计算各商家各仓库各商品的需求天数：

$$Sday_i = \sum_{d=1}^{104} r_{i,d} \, (i = 1,2,\cdots,1996) \tag{1}$$

$$XQrate_i = 1 - \frac{Sday_i}{104} \, (i = 1,2,\cdots,1996) \tag{2}$$

其中，$r_{i,d}$ 是 0-1 变量，1 表示第 i 个组合第 d 天是有需求，0 表示第 i 个组合第 d 天没有需求，$Sday_i$ 表示第 i 个组合从 2023 年 2 月 1 日到 2023 年 5 月 15 日共有多少天有需求，$XQrate_i$ 表示第 i 个组合后从 2023 年 2 月 1 日到 2023 年 5 月 15 日有需求的天数占总天数（104 天）的比例。计算结果如下图所示：

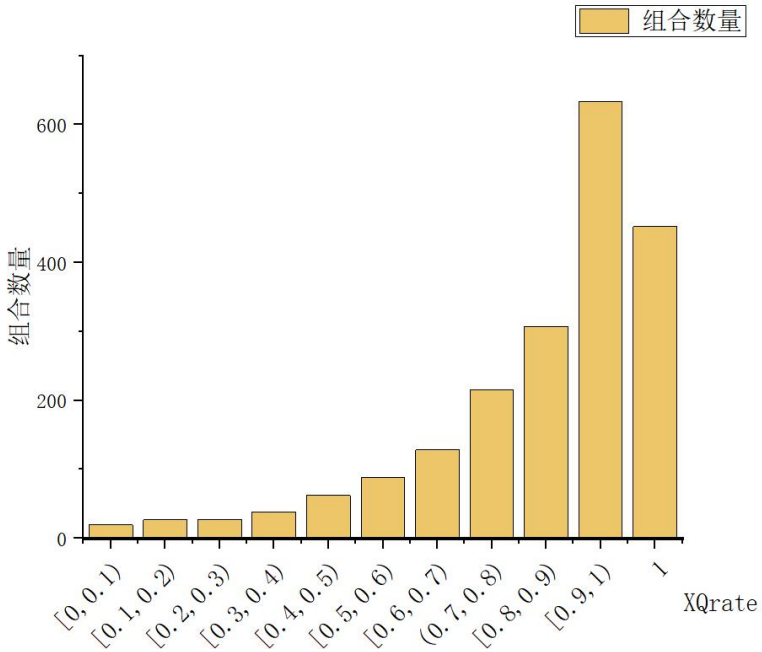


图 6：XQrate 各区间组合数量柱状图

通过(1)和(2)的计算可以得到 1996 个组合的 *XQ*rate ，为了防止有的组合需求天数大部分为 0 进而影响需求量预测，因此本文选择剔除 *XQ*rate 小于 50%的组合。从而删除了 173 个组合，组合数从 1996 变为 1823。

5.2 问题一预测模型的建立与求解

5.2.1 ARIMA 时间序列模型的建立与求解

(1) ARIMA 模型介绍

由于本题中提供的数据是以时间为序列的需求量数据，并且观察每种组合的需求量变化情况，可以发现其大部分呈周期性波动或平缓趋势等特点，因此本文对于附件 1 中组合未来 15 天的需求量预测首先考虑 ARIMA 时间序列预测。

ARIMA（p，d，q）模型又称差分整合移动平均自回归模型，是计量经济学常用的建模方法。MA 为移动平均模型，AR 是自回归模型，I 表示单整阶数。ARIMA 算法适用于平稳的或者是差分后平稳的序列，善于捕捉周期性，季节性波动的规律。其公式如下：

$$\left(1-\sum_{i=1}^{p}\alpha_i L^i\right)(1-L)^d y_t = \alpha_0 + (1+\sum_{i=1}^{q}\beta_i L^i)\varepsilon_t \tag{3}$$

其中，$\left(1-\sum_{i=1}^{p}\alpha_i L^i\right)$ 为季节性 AR(P)，$(1-L)^d$为非季节性差分，$(1+\sum_{i=1}^{q}\beta_i L^i)\varepsilon_t$ 为非季节性 MA(p)。该模型可简化为 ARIMA(p,d,q)。

(2) 以组合 23-1-559 为例进行展示阐述

① 时间序列图分析并确定所包含的变动成分

首先将 23-1-559 组合的出货量数据进行可视化展示：

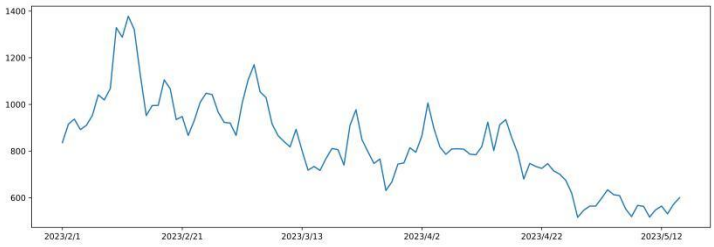


图 7：23-1-559 组合在 2023 年 2 月 1 日到 2023 年的需求量折线图

观察图 7 可以看出 23-1-559 组合的需求量有近似线性向下的长期趋势变动（T），且在不同年份中曲线的波动规律相似，因此数据表现出很强的季节性变动（S）；每年的销量伴随着时间的变化也存在着明显的循环变动（C），在数据中也会存在由于其他原因生成的不规则变动（I）。销售数据的季节波动变化不大，因此可使用叠加模型。

② 时间序列季节性分解

且通过图 7 可以看出，随着时间的推移各品类的波动没有显著下降的趋势，时间序列的波动保持稳定，因此本文选择叠加模型：

$$Y=T+S+C+I \tag{4}$$

其中，Y 表示各组合每天的需求量的最终变动，T 表示长期趋势变动，S 表示季节变动，C 表示循环变动，I 表示不规则变动。

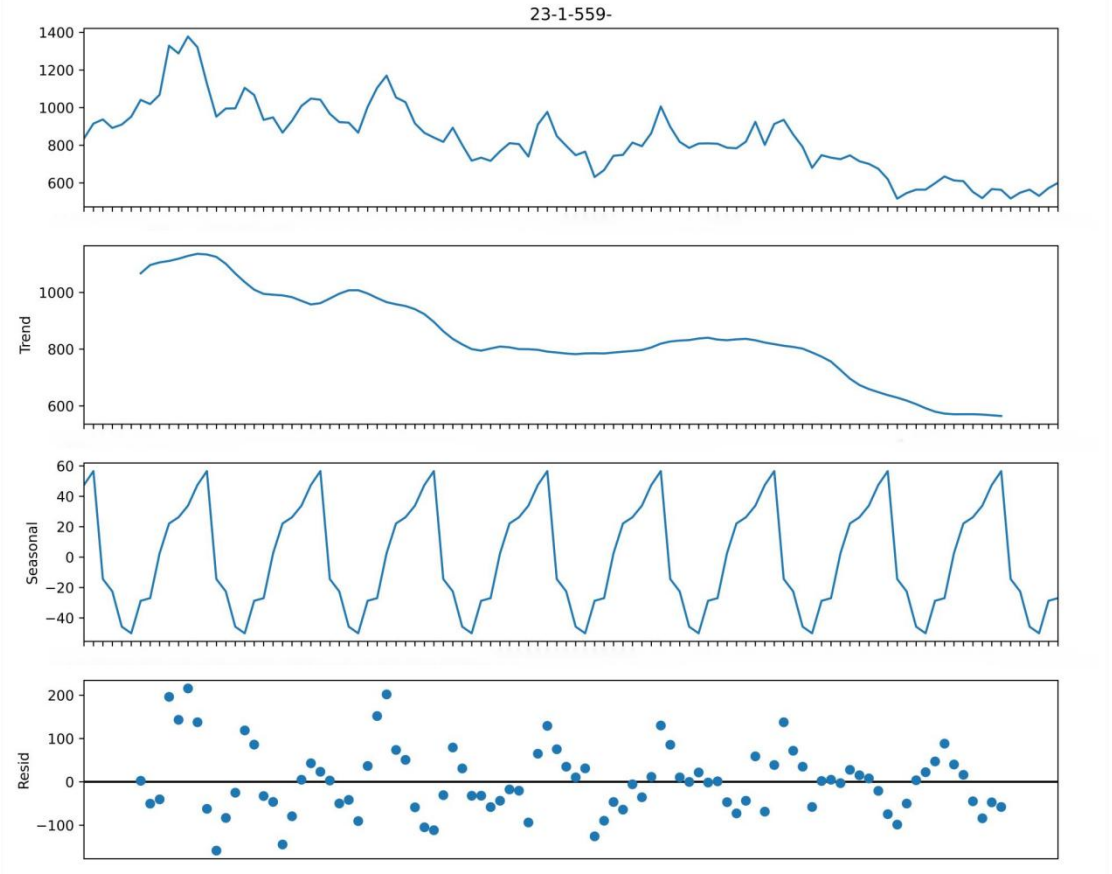


图 8：23-1-559 组合在 2023 年 2 月 1 日到 2023 年 5 月 15 日叠加模型时序图

对时间序列数据而言，数据是否具有平稳性对研究结果起着至关重要的作用。将

所给数据看成关于时间的函数，如果时间序列不平稳，则预测值会偏离基本值且预测误差增大。因此，通过一阶差分将时间序列数据平稳化，可以减轻预测值偏离正常值的影响。此时作一个统计学上的假设检验问题，令原假设 H_0 为时间序列数据不平稳，则备择假设 H_1 为时间序列数据平稳。通过增广迪基—富勒检验，可以发现 p 值由 0.38 降至 0 附近，取显著性水平 α 为 0.05，可知由原数据的“接受原假设”（即时间序列不平稳）经过一阶差分变为“拒绝原假设”（即时间序列平稳），同时一阶差分后有 5%临界值（critical value）大于检验统计量观测值。下图展示了时间序列原始数据和一阶差分后数据，易见平稳性。

③ ARIMA 时间序列预测

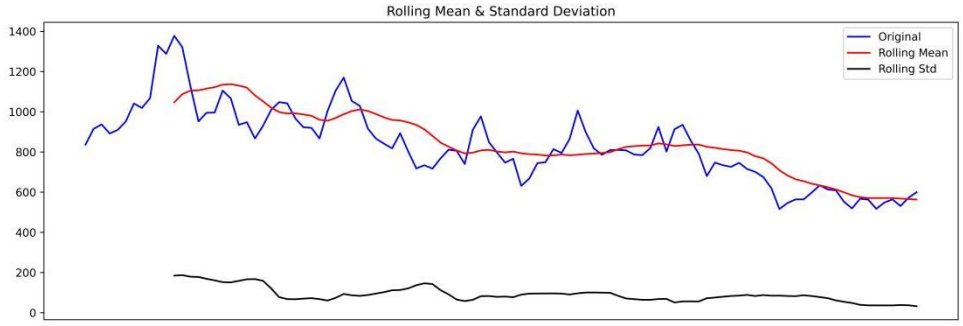


图 9：23-1-559 组合原始数据的滑动平均值及标准差

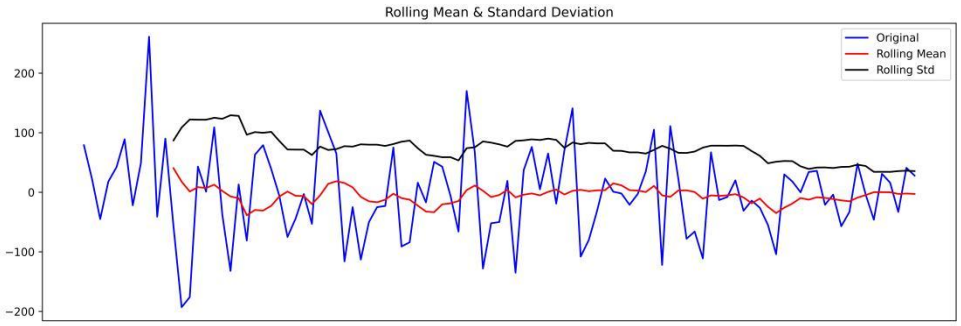


图 10：23-1-559 组合数据经一阶差分后的滑动平均值及标准差

从图 11 和图 12 可以看出适合 23-1-559 组合的 ARIMA 预测参数值。自相关系数（ACF）能够说明时间序列与序列间隔之间的相关性，图中可见随时间间隔增大，自相关系数呈现单调递减的趋势。偏自相关系数（PACF）能够说明时间序列与个体时间间隔之间的相关性。图中显示，首个时间间隔在置信区间之外并且可能是最重要的间隔，它极可能引导了自相关系数图的发展，即后一个时间间隔随前一个时间间隔而变化减小的趋势。从一阶差分后平稳化数据的可视化图中，我们选定 ARIMA 的三个参数分别为 $p=2$，$d=1$，$q=2$，并通过后续进行该组合数据的预测计算预测算法的精度及后续操作。

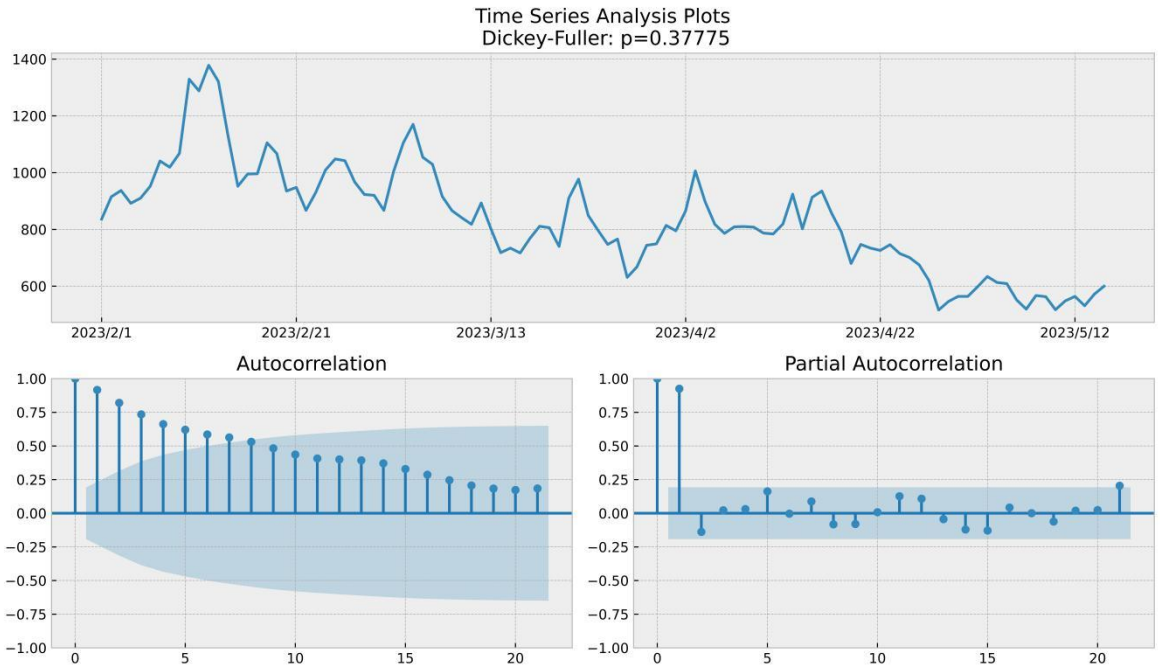


图 11：23-1-559 组合原始数据的时间序列分析图（ACF、PACF）

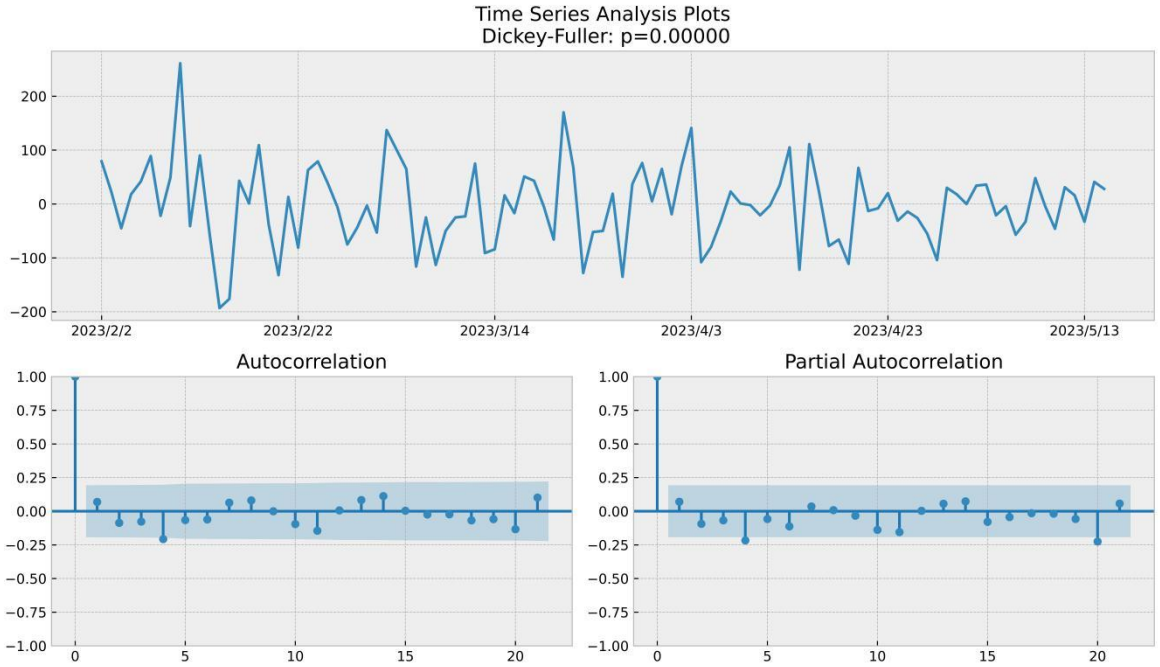


图 12：23-1-559 组合数据经一阶差分后的时间序列分析图（ACF、PACF）

将 23-1-559 组合的后十五天已知数据划分为测试集，其余数据划分为训练集，通过观察后十五天预测值与真实值的差距可以估计出该算法的预测精度。图 13 可以看出 23-1-559 组合的 ARIMA 预测效果较好，预测值与真实值差别不大。利用题目所给出的 1-wmape 可算出该指为 0.9481。该指标说明在该组合的训练过程中，ARIMA 保证了数据的预测精度，是一种较好的算法，因此可以推广到整个数据集的预测中来。

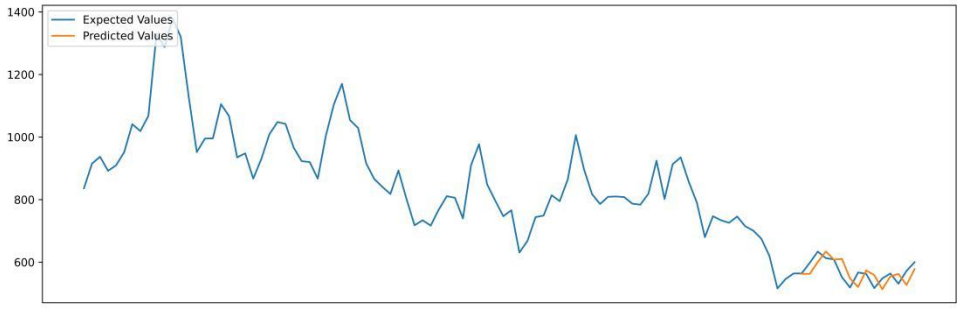


图 13：23-1-559 组合数据经 ARIMA 预测后其预测值与真实值的偏差可视化

对已处理过的数据同时进行一阶差分，目的是将数据集中所有时间序列数据进行平稳化处理，以便满足 ARIMA 模型的应用条件。此时选取每一种组合（商家-商品-仓库）所有已知数据训练，而 ARIMA 模型的三个参数的选取是通过变量选择的 AIC 准则取各自参数的极小值，即将各个组合 AIC 的最小值所对应的三个参数设置为预测算法对应的参数值。这种变量选择的方法极大减轻了计算机运行大规模数据的负担，提高了运算效率（若根据各自组合的自相关系数图与偏自相关系数图选取所对应的 p、q 值，人力算力难以支持，且计算效率过于低下）。通过计算机训练结果得出各组合出货量的现有规律，进而遍历计算各自后 15 天（即 2023 年 6 月 1 日~2023 年 6 月 15 日）的预测值。下面对于 ARIMA 时间序列的部分预测值进行展示，具体数据详见附录：

表 2：ARIMA 时间序列预测结果表

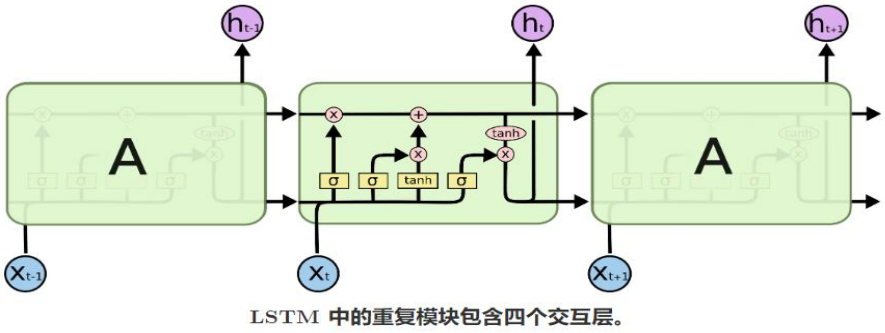
组合	date	qty	组合	date	qty
14-1-1590	2023/5/16	15.308	23-1-559	2023/5/16	599.128
14-1-1590	2023/5/17	16.642	23-1-559	2023/5/17	576.931
14-1-1590	2023/5/18	17.449	23-1-559	2023/5/18	584.326
14-1-1590	2023/5/19	17.349	23-1-559	2023/5/19	574.588
14-1-1590	2023/5/20	16.777	23-1-559	2023/5/20	589.346
14-1-1590	2023/5/21	16.245	23-1-559	2023/5/21	588.602
14-1-1590	2023/5/22	16.063	23-1-559	2023/5/22	606.633
…	…	…	…	…	…

对于所有组合中拆分出的测试集运用题目中所给的 1-wmape 进行计算，得到所有组合的 1-wmape 平均值为 0.7628，可以看出 ARIMA 时间序列模型的预测结果较好，对 ARIMA 时间序列的结果进行保留。

5.2.2 LSTM 模型的建立与求解

(1) LSTM 模型介绍

在预测问题中，LSTM 预测也是一种常用的预测方法，全称 Long Short Term Memory (长短期记忆) 是一种特殊的递归神经网络 。这种网络与一般的前馈神经网络不同，LSTM 可以利用时间序列对输入进行分析；而本题数据所提供的数据恰好具有时间序列等特点，因此适用于 LSTM 模型进行预测。

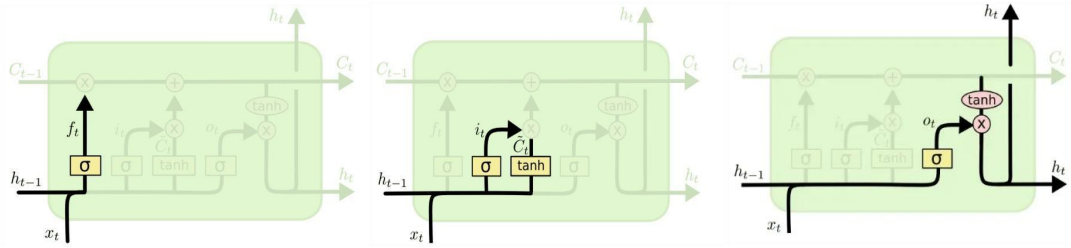


LSTM 中的重复模块包含四个交互层。

图 14：LSTM 结构

LSTM 的关键是单元状态，即图 14 中 LSTM 单元上方从左贯穿到右的水平线，它像是传送带一样，将信息从上一个单元传递到下一个单元，和其他部分只有很少的线性的相互作用。

LSTM 通过不同的“门”来控制抛弃或者增加信息，从而实现遗忘或记忆的功能，模拟神经网络。“门”是一种使信息选择性通过的结构，由一个 Sigmoid 函数和一个点乘操作组成。Sigmoid 函数为生物学中常用的 S 型函数，其值域在[0,1]区间，当“门”输出为 0 时代表此信息完全丢弃，为 1 时代表完全通过。一个 LSTM 单元有三个这样的门，分别是遗忘门、输入门、输出门。其具体模块及其公式如图 15。简单来说，LSTM 中的三个门就是通过三个[0,1]之间的函数来有选择的过滤旧的信息，从而加入新的信息。



$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] \; + \; b_f\right) \qquad i_t = \sigma\left(W_i \cdot [h_{t-1}, x_t] \; + \; b_i\right)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] \; + \; b_C) \qquad o_t = \sigma\left(W_o \; [h_{t-1}, x_t] \; + \; b_o\right)$$

$$h_t = o_t * \tanh\left(C_t\right)$$

图 15：遗忘门、输入门、输出门

（2）通过 LSTM 对数据进行预测

本文通过 MATLAB 编程实现 LSTM 来对数据进行预测，由于各个商品都有其对应的商家、种类及其所在仓库、销售时间等数据，因此我们将商品的商家、种类、仓库及其销售时间视为输入，而商品的销售数量视为输出，从而利用 LSTM 神经网络对商品数据数据进行训练，最终将训练得到的模型对商品的销售量进行预测。

我们首先对已有数据来进行训练集，验证集及其测试集的划分，规定训练集为 70%，验证集与测试集均为 15%。随后使用 MATLAB 建立 LSTM 算法利用训练集进行神经网络的训练得到最终的 LSTM 预测模型。

LSTM 模型共分为 8 个层，可学习参数总数 3.4K 个，如图 15 其中 sequenceinput 层为序列的输入有四个维度，对应商家、仓库、商品种类与销售时间，lstm-1 与 lstm-2 层为 16 个隐藏单元进行神经网络模型的构建，relu 层可以增强模型的非线性能力与加速模型的训练，使模型更加稳健，dropout-1 与 dropout-2 层代表着将已有数据进行 20% 的遗忘丢弃并进行新数据的优化训练，使模型更加的吻合。随后通过 fc 全连接层将输入特征映射到输出结果，完成 LSTM 模型的构建，最后通过 regressionoutput 层进行回

归输出至此预测完成。

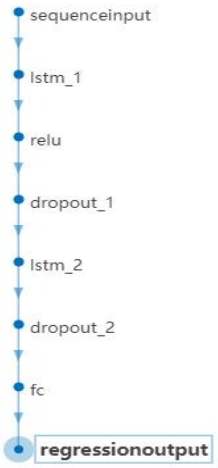


图 16：TrainNetwork 使用分析

在模型的迭代过程中由，图 17 可得 LSTM 模型的 RSME 的数值最终稳定在 0.8 左右，在评价神经网络的性能指标中通常认为 RSME 的值在 0.1-1 之间则认为此神经网络性能较为优良，因此我们可以认为此神经网络的拟合效果较好，得到的模型较为准确。

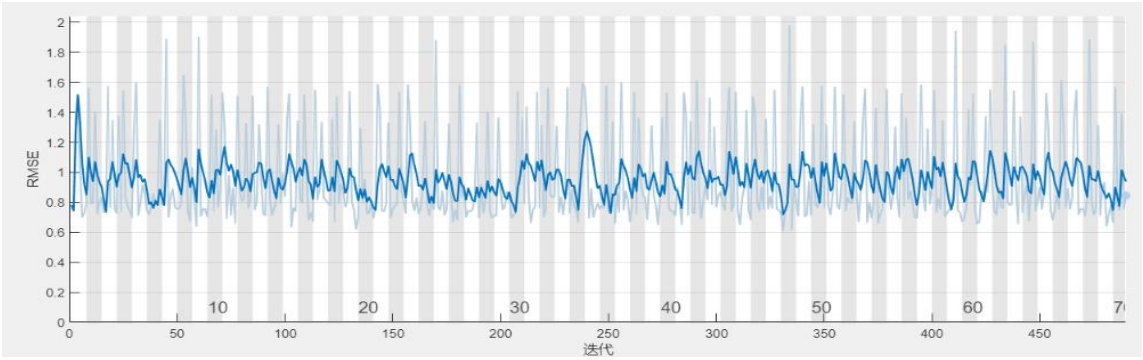


图 17：LSTM 的 RMSE 数值

在神经网络中 Loss 函数的大小常用来度量模型的预测值与真实值之间的差距，由图 18 可得在模型不断的迭代过程中，Loss 函数的数值最终稳定在 0.5 附近，此数值大小适中，意味着模型差别并没有过大，又没有出现模型的过拟合现象，由此方面也可认为模型较为准确。

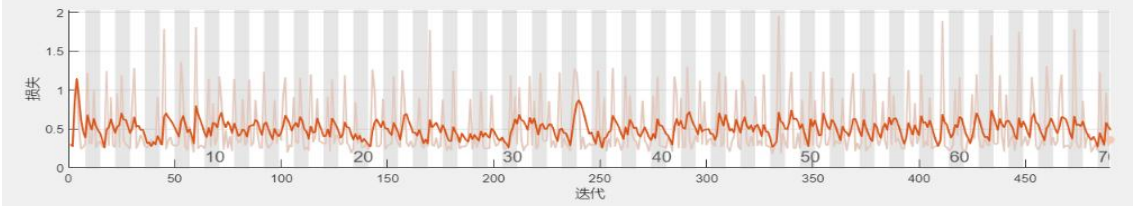


图 18：LSTM 的 Loss 函数数值

为了进一步验证模型的准确性与可推广性，我们将已有数据代入训练出来的模型进行图表可视化分型并进行 1-wmape 的指标评估。

首先我们利用 EXCEL 表格处理，得到销售厂家、仓库、产品分类与销售时间的一一对应关系将原始数据代入，得出预测的销售量并进行画图（此处为图标清晰只展示），观察图 19 可得实际量与预测量之间的数据差别不大，可认为模型与实际情况符合较好。

随后我们利用 MATLAB 编程计算 1-wmape 的数值，得到 1-wmape 的值为 0.8334，此结果也可认为此模型可用来预测从而得到较好的预测结果。

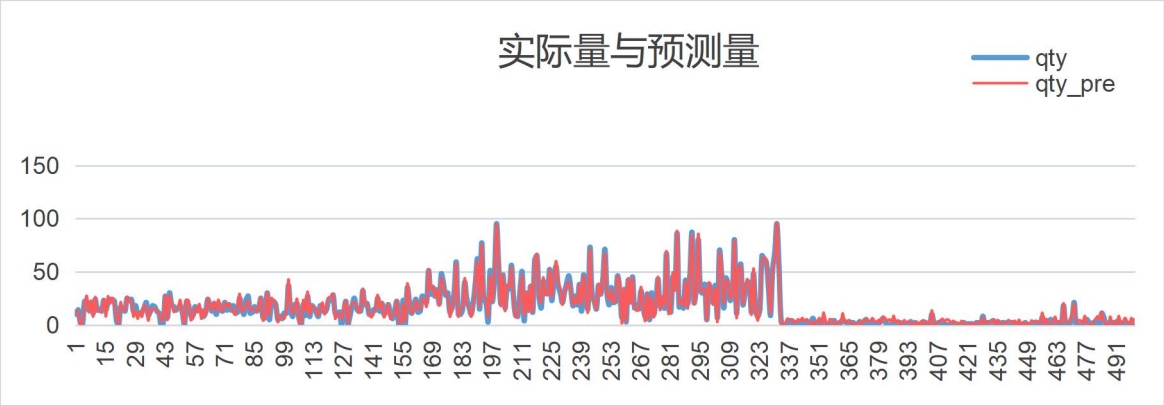


图 19：实际量与预测量

5.2.3 最终结果的计算

通过 ARIMA 时间序列与 LSTM 的预测结果以及对应的 1-wmape 值，可以看出两个预测方法的效果都较好，本文为了使得预测效果误差更小，选择结合两种预测方法，对两种方法进行赋权相加，得到一个结合两种法法的预测结果，具体权重分配公式和预测公式如下所示：

$$\frac{(1-wmape)_{ARIMA}}{(1-wmape)_{LSTM}}=\frac{w_{ARIMA}}{w_{LSTM}} \tag{1}$$

$$w_{ARIMA}+w_{LSTM}=1$$

$$demand_{i,d}^{forecast}=w_{ARIMA}demand_{i,d}^{forecast_{ARIMA}}+w_{LSTM}demand_{i,d}^{forecast_{LSTM}}$$

其中 $(1-wampe)_{ARIMA}$ 表示通过 ARIMA 时间序列预测的 1-wmape 值，$(1-wampe)_{LSTM}$ 表示通过 LSTM 预测的 1-wmape 值，w_{ARIMA} 表示 ARIMA 时间序列预测占最终预测结果的权重，w_{LSTM} 表示 LSTM 方法预测占最终于测结果的权重。经过计算 w_{ARIMA} 和 w_{LSTM} 分别为 0.4776 和 0.5224。

并且通过上式的计算得到第一问的最终结果，如下表所示：

表 3：第一问需求量预测表

seller_no	product_no	warehouse_no	date	forecast_qty
seller_10	product_1664	wh_13	2023/5/16	14.56673
seller_10	product_1664	wh_24	2023/5/16	10.763414
seller_10	product_1914	wh_1	2023/5/16	1.13137227
seller_10	product_1915	wh_1	2023/5/16	1.93917593
seller_10	product_1916	wh_1	2023/5/16	19.615963
seller_10	product_1917	wh_1	2023/5/16	1.77282535

5.3 问题一分类模型的建立与求解

5.3.1 聚类指标的选取

本文对于附件 1 中的组合，通过他们时间序列的数理特征，及附件 1 各组合对应的附件 2、3、4 中的商家、仓库、产品的具体信息进行指标选取，因此指标分为两类：（1）时间序列数理特征指标，（2）组合自身性质指标（通过自身商家、仓库、产品的信息进行选取）具体指标选取如下所示：

(1) 各组合的时间序列数理特征指标：

- 各组合平日期间的需求量的平均值（$\overline{demand_i^{normal}}$）

$$\overline{demand_i^{normal}} = \frac{\sum_{d=1}^{104} demand_{i,d}}{104} (i = 1,2,\cdots,1823) \tag{1}$$

其中 $\overline{demand_i^{normal}}$ 表示第 i 个组合在平时期间的需求量平均值，$demand_{i,d}$ 表示第 i 个组合在从 2023 年 2 月 1 日开始第 d 天的需求量。这个指标可以反映不同组合每天的平均需求情况，需求情况是反映商品的重要属性，所以本文选择该指标作为组合聚类的指标。

- 各组合平日期间的需求量方差（$Vardemand_i^{normal}$）

$$Vardemand_i^{normal} = \frac{\sum_{d=1}^{104} (demand_{i,d} - \overline{demand_i^{normal}})}{104} (i = 1,2,\cdots,1823) \tag{2}$$

其中 $Vardemand_i^{normal}$ 表示第 i 个组合在平时期间的需求量的方差。这个指标可以反映各组合商品在不同时间的需求量波动情况，这个指标越高说明该组合商品的需求量越不稳定，波动越大，它可以反映组合在时间序列上需求量波动的数理特征，因此本文选该指标作为组合聚类的指标

此外各组合时间序列数理特征指标选取还包括：25%分位点、50%分位点、75%分位点、极大值（max）。

(2) 各组合自身性质指标：

将附件 1~附件 4 中的数据合并，并将所有特征指标数字化（即将字符型数据和时间型数据均转化为数值型），此时包含的关于商品、商家、仓库的信息非常齐全，达到了 18 个变量。

5.3.2 K-means 聚类及主成分分析模型的建立与求解

(1) K-means 聚类模型介绍

根据问题提示，需要对商家、仓库、商品形成的时间序列进行分类以便使得同类别在需求上的特征是相似的。由于并未给定分类标签及分类数目，以此判断此种分类可以采用无监督学习中的聚类分析。由于类的数目并未确定，因此需要通过动态变化选取最优类别数，此处采用动态聚类中最常见的 K-means 聚类模型进行分析。

该算法本质是迭代求解。首先预将数据分为 K 类，随机选取 K 个对象作为初始聚类中心（初始种子），再计算每个对象与各聚类中心之间的统计距离，把每个对象分配给距离它最近的聚类中心，即聚为一类。每分配一个样本，聚类的聚类中心会根据聚类中现有的对象被重新计算。迭代的最终目标是没有对象被重新分配给不同的类，没有聚类中心再发生变化，且此时误差平方和（SSE）局部最小。

在计算距离时，常见的统计距离如下：

$$Minkowski距离:d_{ij}(q)=\left(\sum_{k=1}^{p}\left|X_{ik}-X_{jk}\right|^{q}\right)^{\frac{1}{q}} \tag{5}$$

$$Euclidean距离:d_{ij}(q)=\left(\sum_{k=1}^{p}\left|X_{ik}-X_{jk}\right|^{2}\right)^{\frac{1}{2}} \tag{6}$$

$$Chebyshev距离:d_{ij}(\infty)=\max_{1\le k\le p}\left|X_{ik}-X_{jk}\right| \tag{7}$$

$$Jeffrey距离:d_{ij}(J)=\left(\sum_{k=1}^{p}\left|\sqrt{X_{ik}}-\sqrt{X_{jk}}\right|^{2}\right)^{\frac{1}{2}} \tag{8}$$

$$Lance距离:d_{ij}(L)=\frac{1}{p}\sum_{k=1}^{p}\frac{\left|X_{ik}-X_{jk}\right|}{X_{ik}+X_{jk}} \tag{9}$$

(2) 主成分分析方法介绍

利用降维的思想，将原始多个自变量通过线性组合转化为较少数量的新自变量组。几何本质是在坐标系下的线性变换，将数据变换到新坐标系下，实现数据的重新分散。具体实施步骤为：计算自变量矩阵的协方差阵 S，进而计算该矩阵的特征值 $\lambda_1,.....,\lambda_n$ 与对应的特征向量 $\varphi_1,.....,\varphi_n$，通过如下公式进行数据的投影：

$$newDimension_{i,p}=\sum_{k=1}^{n}\lambda_i Dimension_{i,k} \tag{10}$$

其中 *Dimension* 表示原样本中对应维度的值，通过去除近似为 0 的特征值，选取剩余特征值对应的特征向量与自变量的线性组合为主成分的个数及类型。

(3) 通过各组合的时间序列数理特征指标进行分类

对数据进行特征提取，所需要的有效数理特征指标有均值、标准差、25%分位点、50%分位点、75%分位点、极大值。提取成功后需要统一量纲，即进行数据标准化。通过遍历依次计算出初始种子数在 $[2,19]$ 整数区间内取值时各类的距离平方和，此处的距离选用 $Euclidean距离:d_{ij}(q)=\left(\sum_{k=1}^{p}\left|X_{ik}-X_{jk}\right|^{2}\right)^{\frac{1}{2}}$。进而采用手肘图（碎石图）寻找前后变化差异最大的拐点，并将该点对应的数值记为 K-means 聚类的最好类数，该数据集取 k=4 时最为合适。

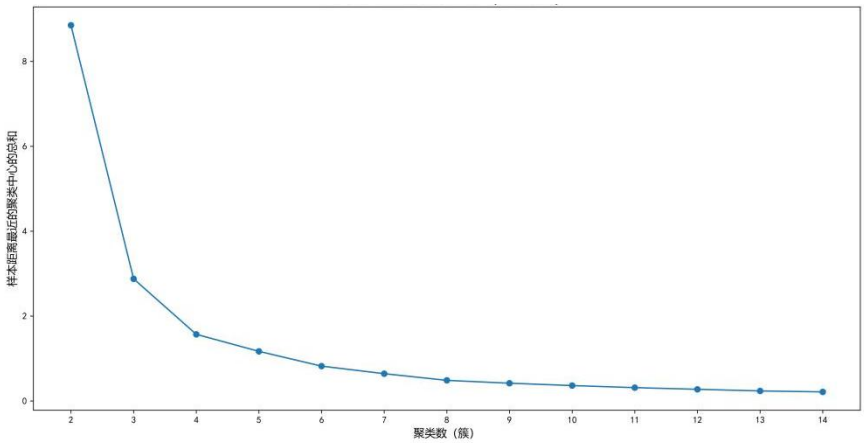


图 20：数理特征指标下 K-means 聚类的手肘图

由于变量数太多，因此难以在二维平面图上区分各个类别的形状，因此利用主成分分析（PCA）进行数据降维。选取最优主成分的标准是使得累积方差贡献度超过一定标准，此时选取标准为 90%，此处累积方差贡献度的数学表达式如下：

$$\frac{\sum_{i=1}^{p}\lambda_i}{\sum_{i=1}^{n}\lambda_i} \geq 90\% \tag{11}$$

从图 20 可见超过 90%的第一个数目为 1，即将所有变量降维至一维，拥有一个主成分 PC1。进一步计算 PC1 的组合系数（即自变量线性组合之后的系数，或特征值对应的特征向量），利用热力图展示各变量所占权重，可见 max 值影响 PC1 最显著。

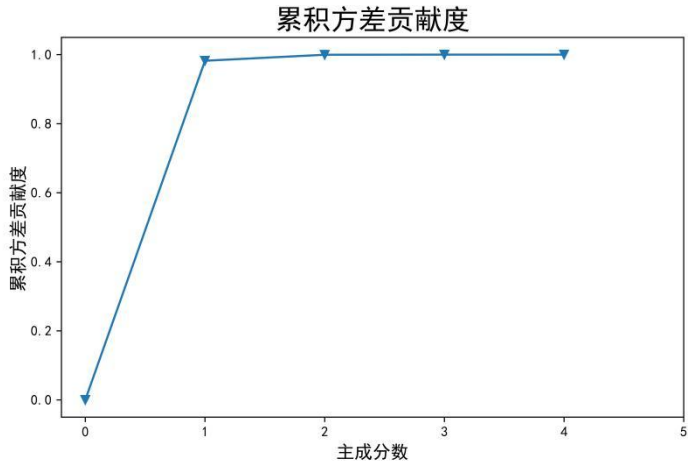


图 21：数理特征指标下主成分分析的累积方差贡献度变化图示



图 22：数理特征指标下 PC1 的特征向量图示（自变量线性组合系数）

从图 23 可见按照各有效数理指标聚成 4 类时，确实能够将原数据区分开来，但是各类的数据量差异较大，聚类效果欠佳，多数数据集中为长条状。因此接下来采用各组合自身性质指标的 K-means 聚类分析，对比二者的效果好坏。

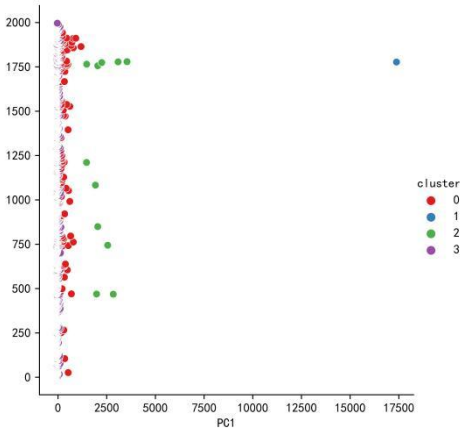


图 23：数理特征指标下聚类（聚类数为 4）的效果图

(4) 通过各组合自身性质指标进行分类

对数据所有特征进行数字化处理，将字符型等、时间型数据全部转换为数值型数据。数据类型统一后需要进行量纲的统一，即进行数据标准化。因$[2,19]$整数区间内的手肘图（碎石图）趋势变化不够显著，因此扩大横坐标范围，通过遍历依次计算出初始种子数在$[2,29]$整数区间内取值时各类的距离平方和，此处的距离选用$Euclidean$距离：$d_{ij}(q)=\left(\sum_{k=1}^{p}\left|X_{ik}-X_{jk}\right|^{2}\right)^{\frac{1}{2}}$。仍然寻找前后变化差异最大的拐点，并将该点对应的数值记为 K-means 聚类的最好类数，该数据集取 k=5 时最为合适。

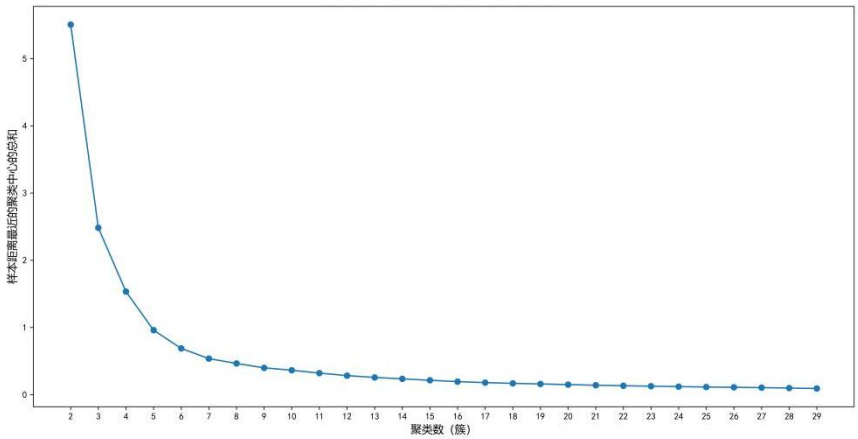


图 24：自身性质指标下 K-means 聚类的手肘图

自身性质指标含有 18 个变量，因此仍然需要利用主成分分析（PCA）进行数据降维。选取最优主成分的标准是使得累积方差贡献度超过一定标准，此时选取标准为 80%，对应的主成分数为 2，即将原始变量经过线性组合后构成 PC1,PC2 两个新的变量。

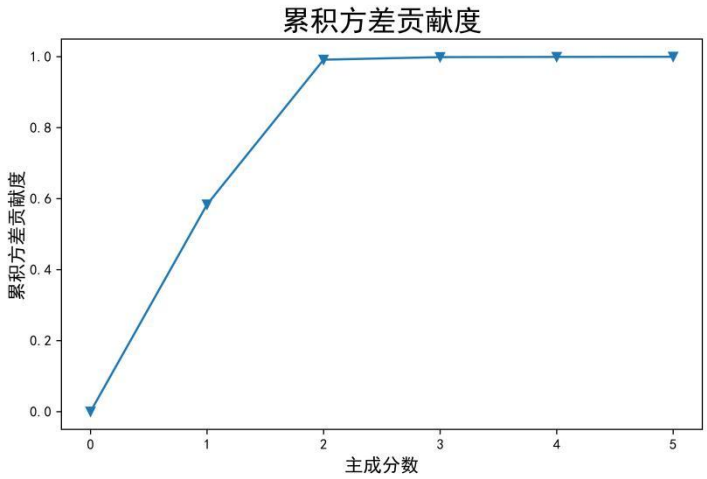


图 25：自身性质指标下 K-means 聚类的手肘图

进一步计算 PC1，PC2 的组合系数（即自变量线性组合之后的系数，或特征值对应的特征向量），利用热力图展示各变量所占权重，可见仓库编码（warehouse_no）值对第一主成分 PC1 影响最显著，出货量极大值（max）对第二主成分 PC2 影响最显著，该主成分的影响因素及其效果与上述数理特征指标下主成分分析效果近似。

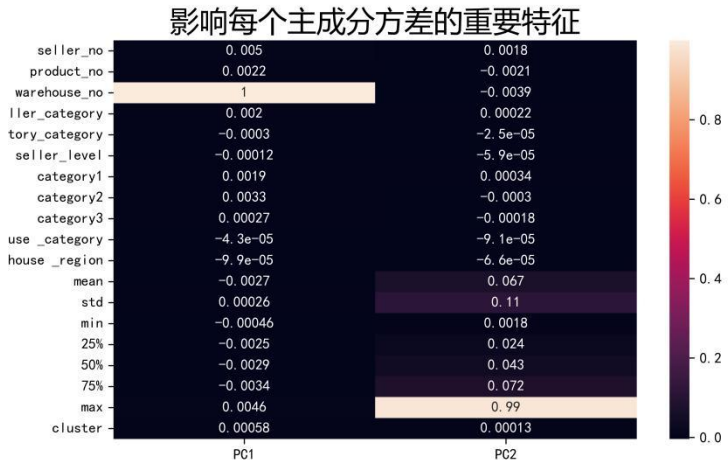


图 26：自身性质指标下 PC1，PC2 的特征向量图示（自变量线性组合系数）

从图 27 可见按照自身性质指标聚成 5 类时，确实能够将原数据区分开来，而且第一主成分（PC1）的聚类效果非常好，数据分散情况及类别区分情况均有较优的效果；然而第二主成分（PC2）仍然是长条状分布，聚类效果欠佳，与上述计算的特征向量结果类似，PC2 下聚类效果图与上述各数理特征指标下的聚类效果图类似，可视化与数学运算效果达成一致。虽然 PC2 的聚类效果较差，但观察总体聚类效果图 28 可见，按自身性质指标聚类聚成 5 类时，原数据分类情况较为合理，分类界限明显。具体聚类效果图如下所示：

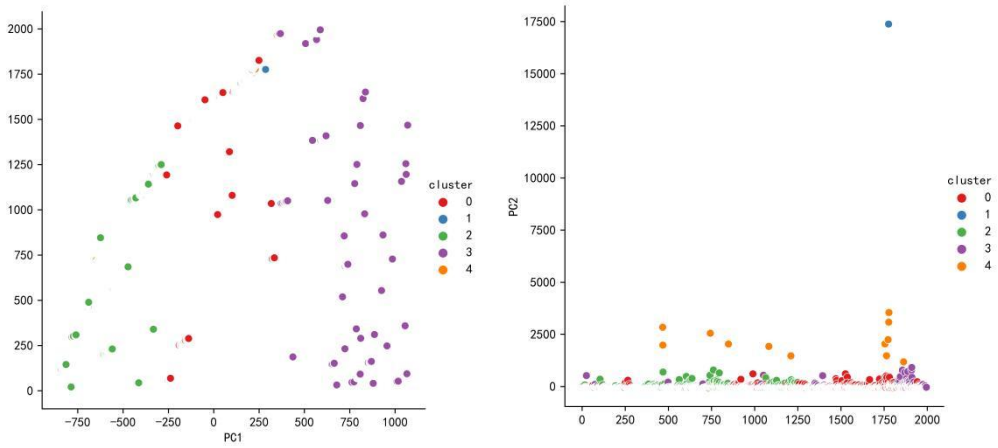


图 27：自身性质指标 PC1，PC2 下的聚类（聚类数为 5）效果图

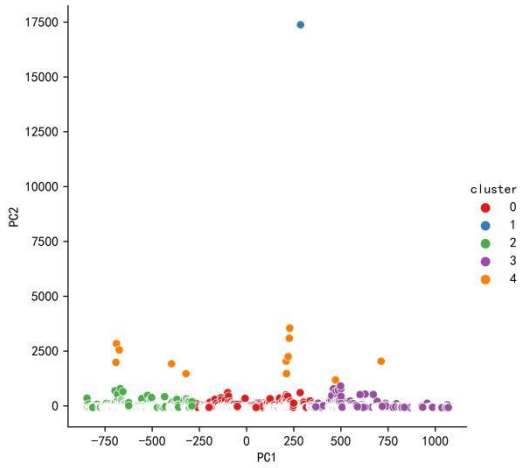


图 28：自身性质指标聚类（聚类数为 5）效果图

六、 问题二模型的建立与求解

6.1 数据预处理

6.1.1 对附件 5 中新出现的商家、仓库、产品进行组合

通过观察附件 5 中数据可以发现，附件 5 中给出的都为新的商家、仓库、产品的的组合，因此本文首先对附件 5 中出现的商家、仓库、产品的新维度，对他们进行组合。通过组合可以发现，新出现的组合共有 210 种。

6.1.2 针对新组合出现时间进行分类

通过观察附件 5，可以发现新维度的组合出现时间并不相同，最早出新的新维度的组合为 4 月 1 日，最晚出现的为 4 月 23 日，中间相差 22 天，因此本文选择将新出现的组合按照出现的时间指标进行分类，其中 4 月 1 日至 4 月 5 日出现的新组合为一类，4 月 6 日至 4 月 10 日出现的新组合为一类，以此类推到 4 月 21 日至 4 月 23 日出现的新组合为一类截止，具体每类的数量如下图所示：

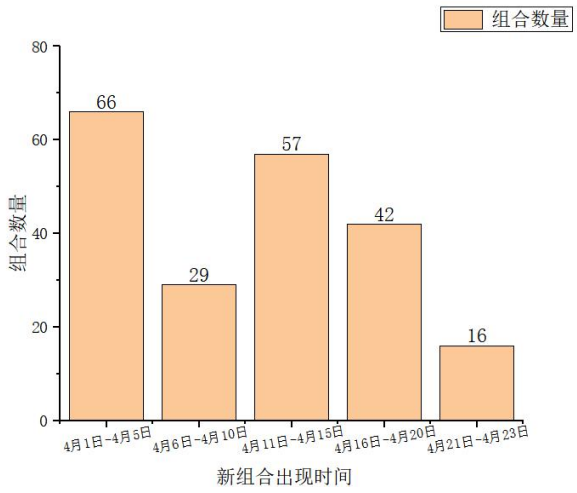


图 29：新组合出现时间区间图

通过图 29，可以得到一共将附件 5 中新出现的组合分为 5 组，本文对于每一组时间区间内的组合，将仅保留在该组合下共有的时间区间的需求量，以 4 月 21 日-4 月 23 日这一组为例，由于这一组所有组合都含有 4 月 23 日及 4 月 23 日之后的需求量数据，因此本文选择保留 4 月 23 日及 4 月 23 日之后的需求量，具体步骤见下表：

表 4：4 月 21 日-4 月 23 日出现的组合未经处理数据表

组合	4 月 21 日	4 月 22 日	4 月 23 日	4 月 24 日	4 月 25 日	4 月 26 日	4 月 27 日	…
15-1-894			1	10	10	10	14	…
15-47-868			1	2	0	1	0	…
⋮			⋮	⋮	⋮	⋮	⋮	…
23-1-2063		1	4	2	1	5	5	…
⋮		⋮	⋮	⋮	⋮	⋮	⋮	…
26-1-2182	13	14	21	7	13	11	10	…
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	…

表 5：4 月 21 日-4 月 23 日出现的组合经处理数据表

组合	4 月 23 日	4 月 24 日	4 月 25 日	4 月 26 日	4 月 27 日	4 月 28 日	4 月 29 日	…
15-1-894	1	10	10	10	14	15	21	…
15-47-868	1	2	0	1	0	0	1	…
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	…
23-1-2063	4	2	1	5	5	2	3	…
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	…
26-1-2182	21	7	13	11	10	8	13	…
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	…

通过表 4 和表 5 的转化可以观察得出，每个时间区间的组合

6.2 相关性分析，寻找相似时间序列

本文对于新维度的组合 2023 年 5 月 16 日至 2023 年 5 月 30 日需求量的预测方法是通过附件 5 新组合在附件 1 中寻找相关性最强的组合，对于新维度组合的预测采用相关性最强的组合应用问题一中针对该组合已确定的时间序列（p,d,q）和公式带入新维度组合的数据进行未来 15 天的需求量运算。

本文需要在附件一中找到附件 5 中与新维度组合相关性最强的组合，相关性的计

算方法如下，由于 pearson 相关系数需要数据满足正态分布及线性关系，要求较高，本题提供的数据并不满足要求，因此本文选择使用 spearman 相关系数进行相关性分析及假设检验。

根据各组合间的矩阵散点图可以看出部分组合间存在线性相关关系，因此我们求出各组合（附件五中新维度组合＋附件一中组合）之间的相关系数进行具体分析。对于相关性分析本文选用 spearman 对各组合进行相关性分析，spearman 相关系数如下述公式，斯皮尔曼相关系数定义：X 和 Y 为两组数据，其 spearman 相关系数[1]：

$$r_s = 1 - \frac{6\sum_{i=1}^{n} d_i^2}{n(n^2-1)} \tag{12}$$

其中，d_i为X_i和Y_i之间的等级差。

通过分析不同组合每天需求量之间的 spearman 相关系数来衡量不同组合销售量之间的关系，一般情况下，若不同组合需求量的相关性显著，则说明两种组合的需求量的波动趋势相关性强，具有较强相关性。具体个组合之间的 spearman 相关系数表太大，由于本文篇幅有限，所以不在正文中展示，详情见附录。

本文对于附件 5 中新维度组合与附件 1 中组合之间 spearman 相关系数最大的值和组合名称进行展示，这里也仅展示部分数据，详细数据见附录：

表 6：附件五与附件一组合最高 Spearman 相关系数及 p 值表

附件五组合	附件一组合	Spearman 相关系数	P 值
14-21-239	35-53-1423	0.8685	3.83E-13
14-1-239	35-1-1423	0.8511	3.48E-12
19-24-408	29-1-915	0.9036	1.079E-13
19-24-414	23-34-587	0.8806	1.40E-10
…	…	…	…

通过表 6 可以看出，附件五中的新维度组合可以在附件一中找到相对应的组合，使得它们两的 Spearman 相关系数大且 P 值小于 0.05 符合原假设，这样的两两组合之间存在很强的相关性，因而本文选择利用问题一中已经得出的附件一中组合的时间序列模型相应的 p、d、q，来对附件 5 中新维度的组合进行 5 月 16 日至 5 月 30 日需求量的预测。

6.3 通过相似序列所得公式预测未来需求量

通过表 6 可以看出本文从附件 1 中找了附件 5 的相似序列，这样相对应的两组数据的波动情况都大致相似，因此本文选择直接将附件 5 中给的数据带入附件 1 中训练得到的网络和 ARIMA 得到的方程中，并通过两种预测方法的赋权相加得到最终的结果，下面展示部分结果，具体结果详见附件：

表 7：问题二预测结果表

seller_no	product_no	warehouse_no	date	forecast_qty
seller_20	wh_1	product_2248	2023.5.16	2.152145
seller_20	wh_1	product_2248	2023.5.17	2.1507
seller_20	wh_1	product_2248	2023.5.18	2.149246
seller_20	wh_1	product_2248	2023.5.19	2.147781
seller_20	wh_1	product_2248	2023.5.20	2.146306
seller_20	wh_1	product_2248	2023.5.21	2.14482
seller_20	wh_1	product_2248	2023.5.22	2.143325

七、 问题三模型的建立与求解

7.1 数据预处理

7.1.1 对附件一中商家、仓库、产品进行组合

附件 6 中也提供了商家、仓库、产品三个维度，本文对于附件 6 中三个维度的编号运用问题一中一样的的数据预处理方法进行整合，将三个维度的编码进行组合，形成新组合编码，通过遍历附件 6 所有商家、仓库、产品组合之后得到了 1957 个组合数。

7.1.2 双 11 购物节整体数据的可视化展示及描述性统计

首先对于附件 6 中双 11 购物节的数据进行每天需求量的可视化展示：

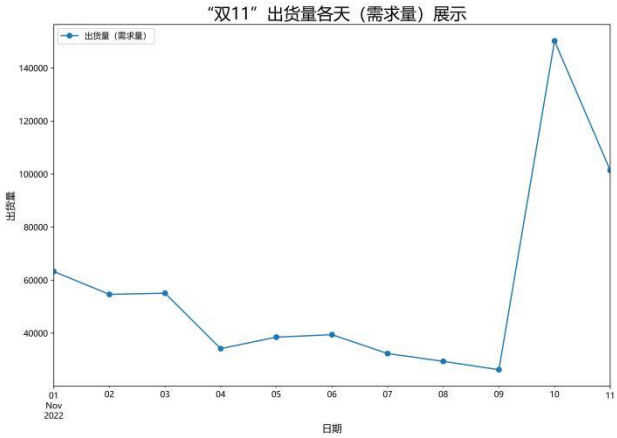


图 30：双 11 期间各天总出货量图

通过图 30 可以看出在双 11 购物节中开始时间段和结尾段时间的用户需求量比较高，而且双 11 购物节期间，用户整体的需求量数据较平日具有显著的提升。在双 11 期间单日平均用户需求量和平日期间单日平均用户需求量分别用下式计算：

$$\overline{demand^{11}}=\frac{\sum_{d=1}^{11}\sum_{i=1}^{1957}demd_{i,d}^{11}}{11} \tag{13}$$

$$\overline{demand^{normal}}=\frac{\sum_{d=1}^{104}\sum_{i=1}^{1996}demand_{i,d}}{104} \tag{14}$$

其中，$\overline{demand^{11}}$ 表示在双 11 期间所有产品的需求量每天的平均值，$\overline{demand}$ 表示平日期间所有产品的需求量每天的平均值，$demand_{i,d}$ 表示平日期间附件 1 中第 i 个组合在从 2023 年 2 月 1 日开始第 d 天的需求量，$demand_{i,d}^{11}$ 表示双 11 期间附件 6 中第 i 个组合从 2022 年 11 月 1 日开始第 d 天的需求量。

通过计算可以得到在双 11 期间，平均每天的总需求量为 59951.91，平日期间的平均每天的总需求量为 29513.94，通过对比可以发现双 11 期间比平时期间的平均每天的总需求量大 30437.97，高出 103 个百分点。可以看出双 11 期间用户需求量较平日是有显著增长的。

7.2 双 11 购物节活动分析

7.2.1 “双 11”购物节时间区间分析

通过数据预处理部分的数据可视化展示可以发现在双 11 期间，用户需求量在时间维度上出现了两头高中间低的现象，通过查寻 2022 年各电商在双 11 期间的促销手段，发现大部分电商（包括天猫、京东等头部电商）都实行了在双 11 开始阶段进行开门红促销，中间时间段进行主题日或者是品类日的促销，双 11 尾期进行狂欢日，该时间段用户需求量达到高峰。具体双 11 的电商促销时间安排如下表所示图所示：

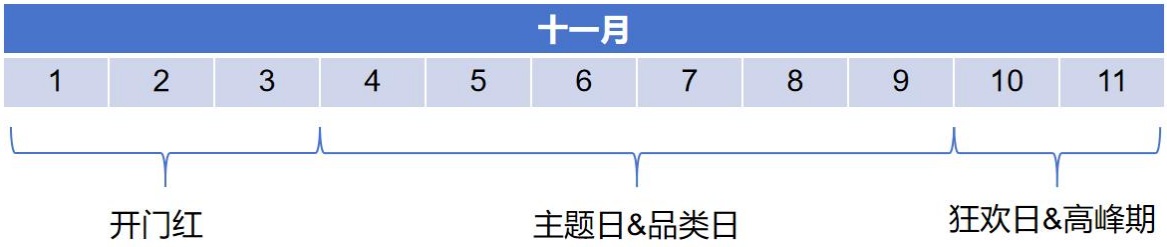


图 31：双 11 期间电商促销时间安排图

本文对于 618 期间各组合的需求量预测将采用平日期间的时间序列预测结合购物节因子来进行预测，其中购物节因子将包括品类因子和地区因子两种，其中品类因子反映各一级分类商品在购物节各阶段的用户需求量变化情况，地区因子则是各仓库所在区域在购物节的用户需求量的变化情况。各因子具体分析见下文。

7.2.2 双 11 购物节产品品类数据分析

通过前文的分析可知，在购物节中间会出现品类日和主题日这样的促销安排，因此在该时间内各品类商品在不同时间进行促销活动，因此本文针对这种情况，计算各个一级分类商品在 11 月 1 日至 11 月 11 日的每天的品类因子，品类因子的定义为当前这一天该一级分类商品相较平时每天的平均需求量的比值，该因子可以反映双 11 购物节中每一天各个一级分类商品跟平时期间的用户需求量的变动情况，具体计算方式如下：

$$PLfactor_{n,d}=\frac{demand_{n,d}^{11}}{\overline{demand_{n}^{normal}}}(n=1,2,\cdots,20)(d=1,2,\cdots,11) \tag{15}$$

其中，$PL\text{factor}_{n,d}$ 表示第 n 种一级分类商品在 11 月 1 号开始的第 d 天的品类因子的值，$demand_{n,d}^{11}$ 表示第 n 种一级分类商品在 11 月 1 好开始的第 d 天的总需求量，$\overline{demand_{n}^{normal}}$ 表示第 n 种一级分类商品在平时期间的用户需求量的平均值。

通过上式计算可以得到双 11 期间各个一级分类的商品的品类因子，各一级分类的商品的品类因子如下表所示，由于篇幅原因，正文中仅展示部分数据，详细数据查看附录：

表 8：各一级分类商品的品类因子表

category1	11 月 1 日	11 月 2 日	11 月 3 日	11 月 4 日	…
宠物生活	1.0482	1.4386	1.8240	1.4737	…
厨具	0.8518	0.7524	0.6734	0.5822	…
传统滋补	0.4951	1.3257	1.2712	1.0195	…
电脑、办公	2.3265	1.7551	1.6159	1.3387	…
服饰内衣	0.1065	0.2561	0.2992	0.1180	…
个人护理	1.8693	2.6090	2.0469	1.8612	…

家具	0.6208	0.9660	1.2386	0.9448	…
家庭清洁/纸品	1.6518	2.5583	1.6367	1.5360	…
家用电器	1.3301	1.2310	1.2143	0.9418	…
家装建材	5.0749	3.3452	3.6962	1.3148	…
酒类	0.2813	0.4219	0.4219	0.7032	…
美妆护肤	1.1084	1.3942	1.2576	1.2041	…
生活日用	0.4505	0.2527	0.3516	0.3735	…
食品饮料	0.8675	1.1730	1.1108	1.0581	…
手机通讯	0.9952	1.3853	1.0511	1.0160	…
数码	0.0449	0.2007	0.1797	0.1722	…
玩具乐器	0.5345	0.9761	0.7669	0.5810	…
鲜花/奢侈品	0.6877	1.4533	1.1159	1.4143	…
运动户外	2.6388	2.6388	3.1045	3.3373	…
珠宝首饰	0.5837	0.8491	0.6235	0.5307	…

并对各一级分类的商品的品类因子进行可视化展示：

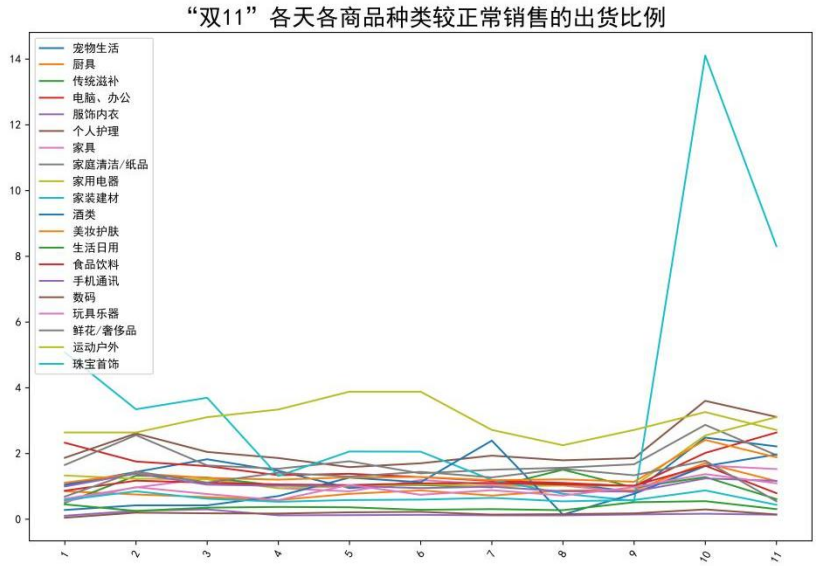


图 32：双 11 各以及一级分类商品的品类因子折线图

通过图 32 可以发现家装建材的用户需求量在“双 11”的高峰期间的品类因子遥遥领先，因此可以得到在“双 11”期间家装建材的用户需求量上升明显，并且大部分一级分类商品在“双 11”期间的用户需求量都有显著提升，不过可以发现珠宝首饰、服饰内衣、生活用品、数码在“双 11”期间的品类因子小于 1，说明在“双 11”期间该品类上平较平日的需求量更小。

7.2.3 双 11 购物节地区购物数据分析

考虑到不同地区的经济发展水平不同可能导致“双 11”期间不同地区的需求量变动量有明显不同，因此本文选择将“双 11”期间的不同地区（如华北、东北等）的用户需求量变化率进行计算作为地区因子，地区因子的定义为当前这一天该地区商品总需求量相较平时每天的该地区商品总需求量的比值，该因子可以反映双 11 购物节中每一天各地区总商品需求量跟平时期间的该地区商品的总需求量的变动情况，具体计算方式如下：

$$DQfactor_{L,d}=\frac{demand_{L,d}^{11}}{\overline{demand_{L}^{normal}}}(L=1,2,\cdots,7)(d=1,2,\cdots,11) \tag{16}$$

其中，$DQfactor_{L,d}$ 表示第 L 个地区在 11 月 1 日开始的第 d 天的地区因子的值，$demand_{L,d}^{11}$ 表示第 L 个地区在 11 月 1 日开始的第 d 天的总需求量，$\overline{demand_{L}^{normal}}$ 表示第 L 个地区在平时期间的每日总需求量的平均值。

通过上式计算可以得到“双 11”期间各个地区的地区因子，各地区的地区因子如下表所示，由于篇幅原因，正文中仅展示部分数据，详细数据查看附录：

表 9：各地区的地区因子表

地区	11 月 1 日	11 月 2 日	11 月 3 日	11 月 4 日	…
东北	2.3006	2.0367	1.6779	1.6252	…
华北	1.4904	1.4258	1.6094	0.9431	…
华东	2.4849	2.0429	2.1116	1.2753	…
华南	1.9157	1.7179	1.9149	0.9034	…
华中	2.0827	1.7761	1.1685	1.0380	…
西北	0.8746	1.3068	1.1201	0.7709	…
西南	1.2588	1.3499	1.3741	0.9189	…

由表 9 中可以得到，西北地区在“双 11”购物节活动中需求量变化波动最小，可能因为经济因素或者文化因素等导致西北地区用户的需求量受“双 11”购物节的影响较小，其中西南的变动相对来说也比较小，而东北、华北、华东、华南、华中等地区在“双 11”购物节期间中，需求量增长较大，其中华东和华南地区在 11 月 10 日的地区因子分别达到了 5.79158999 和 5.604607694，较平时用户需求量有显著提升。

7.3 以双 11 购物节预测 618 购物节各组合需求量

7.3.1 “618”购物节时间区间划分

针对“双 11”购物节的时间区间分析，可以发现“双 11”购物节中将时间分为开门红、主题日&品类日、狂欢日&高峰期这三个阶段。因此本文结合“双 11”的促销方案结合线上整合的各大电商“618”购物节期间的促销方案，本文将“618”活动仍大致分为 3 个阶段，因此本文通过 618 各电商的促销时间安排并结合双 11 期间电商促销时间安排图，整理出 618 期间的电商促销时间安排图，如下图所示：



图 33：618 期间电商促销时间安排图

由于“618”购物节较“双 11”购物节的活动周期更长，因此本文选择将“双 11”期间 3 个阶段的品类因子和地区因子的按照“618”购物节的时间安排表从 11 月 1 日到 11 月 11 日等比例延长至从 6 月 1 日到 6 月 20 日。

7.3.2 未加因子的时间序列预测

本文中首先对于 6 月 1 日至 6 月 20 日的各组合需求量通过 ARIMA 和 LSTM 的赋权相加的预测方式进行预测（与问题一方法相同），通过该方法得到未经加入品类

因子和地区因子前的 6 月 1 日至 6 月 20 日各组合需求量的预测结果。部分结果如下表所示：

7.3.3 “618”期间需求量预测——加入地区因子

首先考虑地区因子，对于 6 月 1 日至 6 月 20 日每天各地区的需求量预测值引入地区因子，得到受地区因子影响后的各地区“618”需求量的预测值，具体计算方法如下所示：

$$demand_{L,d}^{618} = DQfactor_{L,d} \cdot demand_{L,d} (L = 1,2,\cdots,7)(d = 1,2,\cdots,20) \tag{17}$$

其中 $demand_{L,d}^{618}$ 表示第 L 个地区在 6 月 1 日开始第 d 天受地区因子影响后预测的需求量，$DQfactor_{L,d}$ 表示第 L 个地区在 6 月 1 日开始第 d 天的地区因子，其取值为“双 11”购物节中地区因子的等比例延长，$demand_{L,d}$ 表示第 L 个地区在 6 月 1 日开始第 d 天的需求量预测值。

7.3.4 “618”期间需求量预测——在地区因子的约束下加入品类因子

再次考虑品类因子，对于 6 月 1 日至 6 月 20 日每天各地区的需求量预测值引入品类因子，得到受品类因子影响后的各一级分类的“618”需求量的预测值，具体计算方法如下所示：

$$demand_{\mathrm{n},d}^{618} = PLfactor_{\mathrm{n},d} \cdot demand_{\mathrm{n},d} (\mathrm{n} = 1,2,\cdots,20)(d = 1,2,\cdots,20) \tag{18}$$

其中 $demand_{n,d}^{618}$ 表示第 n 种一级分类商品在 6 月 1 日开始第 d 天受品类因子影响后预测的需求量，$DQfactor_{n,d}$ 表示第 n 种一级分类商品在 6 月 1 日开始第 d 天的品类因子，其取值为“双 11”购物节中品类因子的等比例延长，$demand_{n,d}$ 表示第 n 种一级分类商品在 6 月 1 日开始第 d 天的需求量预测值。

本文优先对地区因子进行了计算，在地区因子的约束下引入品类因子，即先预测出 6 月 1 日到 6 月 20 日各地区引入地区因子后的预测值，再在此预测值的约束下分配各地区一级品类商品的需求量预测值，再两个因子的共同作用下进行对具体组合需求量预测值的确定，具体约束条件如下所示：

$$\sum_{i=i_n}^{i_{n+1}-1} demand_{i,d} = demand_{n,d}^{618} (i = 1,2,\cdots,1957)(d = 1,2,\cdots,20)(n = 1,2,\cdots,20) \tag{19}$$

$$\sum_{i=i_L}^{i_{L+1}-1} demand_{i,d} = demand_{L,d}^{618} (i = 1,2,\cdots,1957)(d = 1,2,\cdots,20)(L = 1,2,\cdots,7) \tag{20}$$

其中 i_n 表示第 n 种一级分类商品里第一个组合，$i_{n+1}-1$ 表示第 n+1 种一级分类商品的第一个组合-1 就是第 n 种 1 级分类商品的最后一个组合，i_L 表示第 L 个地区里第一个组合，$i_{L+1}-1$ 表示第 L+1 个地区里的第一个组合-1 就是第 L 个地区里的最后一个组合。

通过约束条件的约束因子作用加入到预测结果中，得到每个组合在“618”购物节期间的具体预测结果，下表展示部分预测结果，详细预测结果详见附录：

表 10：“618”购物节需求量购物节

seller_no	product_no	warehouse_no	date	forecast_qty
seller_14	product_1590	wh_1	2023/6/1	14.3250593
seller_14	product_1590	wh_1	2023/6/2	19.38036707
seller_14	product_1590	wh_1	2023/6/3	18.33895445
seller_14	product_1590	wh_1	2023/6/4	17.44757764
seller_14	product_1590	wh_1	2023/6/5	17.27689709

seller_14	product_1590	wh_1	2023/6/6	17.1190136
seller_14	product_1590	wh_1	2023/6/7	17.55279767
…	…	…	…	…

八、 模型的评价、改进与推广

8.1 模型的优点

1、在数据预处理方面注意到双十二与春节期间的数据异常并进行剔除，保证模型训练结果更加贴合实际。

2、本文中的预测均采用 ARIMA 与 LSTM 等多模型进行数据的加权预测，使预测数据更加精确。

3、对商品的聚类时综合考虑了多种方面的聚类效果，增加了聚类的准确性。利用主成分分析使得聚类效果更加直观。

4、对新商品进行预测时没有盲目带入已有模型，而是与已有商品进行销售量的相关性分析，随后带入相关性最强的商品对应的时间序列模型中，保证了新商品与时间序列模型的吻合性。

5、本文问题三中对商品销售量进行预测时，考虑到不同的商品与地区会有不同的优惠政策影响商品出售，对此本文引入了“品类因子”与“地区因子”进行结合预测。

8.2 模型的缺点

1、LSTM 模型运行耗时较长，在并行处理上存在劣势。

2、K-means 聚类的 k 值不好选择，在聚类数的选择上主观性较强，且在迭代过程中得到的仅是局部最优解。

3、所选择的预测算法对噪声值和异常点较为敏感。

8.3 模型的改进

1、 可引入更多的预测模型（如随机森林、XGBoost 等）进行赋权处理，提高整体的预测能力。

2、 对聚类算法进行改进或更换更优的算法（如 GMM 等），减少聚类数选取的主观性带来的影响。

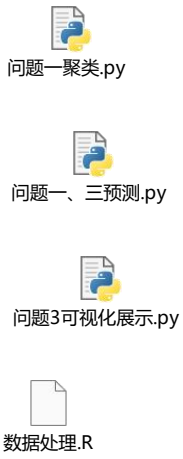
九、 参考文献

[1]许力琴,周晴,刘霞.科技论文“Spearman 相关”表达中存在的问题分析与建议[J].编辑学报,2019,31(04):398-400.DOI:10.16811/j.cnki.1001-4314.2019.04.012.
[2]孙明浩,段雨琪,郑良等.ARIMA、ARIMAX、NGO-LSTM 模型在山东省聊城市结核病发病数预测中的应用[J/OL].中国防痨杂志
[3]孙学波,刘宁,王元杰等.时间序列 ARIMA 模型在煤矿地音监测系统中的应用[J].煤炭工程,2023,55(10):111-117.
[4]蔡庙辉,吴昌子,邬洪江等.基于 CNN-LSTM 的垃圾焚烧炉烟气浓度预测方法[J/OL].化学工业与工程:1-9[2023-11-03].
[5]胡雅群,哈米提,许子凯.基于 K-means 聚类的城市轨道站点周边共享单车需求预测方法研究[J].交通工程,2023,23(05):82-90+98.
[6]周群星,胡昊,吕春茂等.不同品种榛子加工榛子露适宜性评价[J/OL].现代食品科技:1-10[2023-11-03].

附录

附录 1

介绍：支撑材料的文件列表



附录 2

介绍：该代码由 Python 语言编写，为时间序列分析自定义检验函数

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
from datetime import datetime
pd.options.display.float_format = '{:.2f}'.format
from itertools import combinations
from sklearn.metrics import mean_absolute_error
from sklearn.metrics import mean_squared_error
from statsmodels.tsa.stattools import adfuller
from statsmodels.tsa.stattools import acf, pacf
from statsmodels.tsa.arima_model import ARIMA as ARIMA
import statsmodels.api as sm
import statsmodels.tsa.api as smt
df=pd.read_excel('E:/competition/附件 1label.xlsx')
df=df.T
df=df.set_axis(df.iloc[0],axis=1,inplace= False)
df=df.drop(df.index[0])
df
def test_stationarity(timeseries):
    #Determing rolling statistics
    MA = timeseries.rolling(window=12).mean()
    MSTD = timeseries.rolling(window=12).std()
```

```
    #Plot rolling statistics:
    plt.figure(figsize=(15,5))
    orig = plt.plot(timeseries, color='blue',label='Original')
    mean = plt.plot(MA, color='red', label='Rolling Mean')
    std = plt.plot(MSTD, color='black', label = 'Rolling Std')
    plt.legend(loc='best')
    plt.title('Rolling Mean & Standard Deviation')
    #plt.show(block=False)
    #Perform Dickey-Fuller test:
    print('Results of Dickey-Fuller Test:')
    dftest = adfuller(timeseries, autolag='AIC')
    dfoutput = pd.Series(dftest[0:4], index=['Test Statistic','p-value','#Lags
                    Used','Number of Observations Used'])
    for key,value in dftest[4].items():
        dfoutput['Critical Value (%s)'%key] = value
print(dfoutput)
def tsplot(y, lags=None, figsize=(12, 7), style='bmh'):
    if not isinstance(y, pd.Series):
        y = pd.Series(y)
    with plt.style.context(style):
        fig = plt.figure(figsize=figsize)
        layout = (2, 2)
        ts_ax = plt.subplot2grid(layout, (0, 0), colspan=2)
        acf_ax = plt.subplot2grid(layout, (1, 0))
        pacf_ax = plt.subplot2grid(layout, (1, 1))
        y.plot(ax=ts_ax)
        p_value = sm.tsa.stattools.adfuller(y)[1]
        ts_ax.set_title('Time Series Analysis Plots\n Dickey-Fuller:
                        p={0:.5f}'.format(p_value))
        smt.graphics.plot_acf(y, lags=lags, ax=acf_ax)
        smt.graphics.plot_pacf(y, lags=lags, ax=pacf_ax)
        plt.tight_layout()
```

附录 3

介绍：该代码由 Python 语言编写，选取一列数据作为例子进行 ARIMA 预测并检验其预测精度，确定是否可以推广

```
plt.figure(figsize = (15,5))
df.iloc[:,1].plot()
plt.savefig('E:/competition/选取其中一列各天出货量（需求量）展示.jpg',dpi=1150)
from pylab import rcParams
import statsmodels.api as sm
rcParams['figure.figsize'] = 11, 9
#plt.figure(figsize = (30,12))
dec = sm.tsa.seasonal_decompose(df.iloc[:,1],period = 12, model = 'Additive').plot()
```

```
plt.xticks([])
plt.savefig('E:/competition/观察该例子列季节性变化、发展趋势.jpg',dpi=1150)
from pylab import rcParams
import statsmodels.api as sm
rcParams['figure.figsize'] = 11, 9
test_stationarity(df.iloc[:,1])
plt.xticks(rotation=270)
plt.savefig('E:/competition/观察该例子列均值、标准误.jpg',dpi=1150)
from pylab import rcParams
import statsmodels.api as sm
rcParams['figure.figsize'] = 11, 9
data_diff1 = df.iloc[:,1].diff()
data_diff1 = data_diff1.dropna()
dec = sm.tsa.seasonal_decompose(data_diff1,period = 12).plot()
plt.xticks([])
plt.savefig('E:/competition/观察该例子一阶差分后趋势、季节性变化.jpg',dpi=1150)
plt.show()
test_stationarity(data_diff1)
plt.xticks([])
plt.savefig('E:/competition/观察该例子列一阶差分后均值、标准误.jpg',dpi=1150)
tsplot(df.iloc[:,1])
plt.savefig('E:/competition/该例子列时间序列分析，选定自相关系数、偏自相关系数.jpg',dpi=1150)
tsplot(data_diff1)
plt.savefig('E:/competition/该例子列一阶差分后时间序列分析，选定自相关系数、偏自相关系数.jpg',dpi=1150)
import plotly.express as px
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score
from statsmodels.tsa.stattools import adfuller
from statsmodels.tsa.arima.model import ARIMA
from sklearn.preprocessing import MinMaxScaler
from statsmodels.graphics.tsaplots import plot_acf,plot_pacf
from statsmodels.stats.diagnostic import acorr_ljungbox
model = ARIMA(df.iloc[:,1].astype(float),order = (2,1,0))
model_fit = model.fit()
print(model_fit.summary())
size = int(len(df) - 15)
train, test = df.iloc[:,1][0:size], df.iloc[:,1][size:len(df)]
print('\t ARIMA MODEL : In- Sample Forecasting \n')
history = [x for x in train]
predictions = []
for t in range(len(test)):
    model = ARIMA(history, order=(2,1,0))
```

```
        model_fit = model.fit()
        output = model_fit.forecast()
        yhat = output[0]
        predictions.append(float(yhat))
        obs = test[t]
        history.append(obs)
print('predicted = %f, expected = %f' % (yhat, obs))
predictions_series = pd.Series(predictions, index = test.index)
fig,ax = plt.subplots(nrows = 1,ncols = 1,figsize = (15,5))
plt.subplot(1,1,1)
plt.plot(df.iloc[:,1],label = 'Expected Values')
plt.plot(predictions_series,label = 'Predicted Values');
plt.legend(loc="upper left")
plt.xticks([])
plt.savefig('E:/competition/该例子列经过 arima 预测后的可视化（预测值与真实值的差距很小）.jpg',dpi=1150)
wmape = sum(abs(test-predictions).values)/sum(test)
print('1-wmape:%.4f'%(1-wmape))    #预测准确率很高
```

附录 4

介绍：该代码由 Python 语言编写，对原始数据进行遍历 ARIMA 预测并检验其预测精度，输出每一列数据的预测精度值(1-wmape）

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib.font_manager as mfm
font_path=r'C:/Windows/Fonts/msyh.ttc'
prop = mfm.FontProperties(fname = font_path)
import seaborn as sns
import plotly.express as px
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score
from statsmodels.tsa.stattools import adfuller
from statsmodels.tsa.arima.model import ARIMA
from sklearn.preprocessing import MinMaxScaler
from statsmodels.graphics.tsaplots import plot_acf,plot_pacf
from statsmodels.stats.diagnostic import acorr_ljungbox
import plotly.express as px
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score
from statsmodels.tsa.stattools import adfuller
from statsmodels.tsa.arima.model import ARIMA
from sklearn.preprocessing import MinMaxScaler
from statsmodels.graphics.tsaplots import plot_acf,plot_pacf
```

```
from statsmodels.stats.diagnostic import acorr_ljungbox
error=[]
for i in range(0,len(df.columns)):
data=df.iloc[:,i]
#对处理后的数据归一化，打印归一化后的图
#scaler=MinMaxScaler()
#scaled_data=pd.DataFrame(scaler.fit_transform(data.values.reshape(-1,1)))
#通过 AIC 确定 ARIMA 参数，打印原始数据和差分后数据的自相关系数图和偏自相关系数图，打印确定参数后的协差图
aic_values={}
for p in range(4):
for q in range(4):
try:
model=ARIMA(scaled_data,order=(p,1,q))
result=model.fit()
aic_values[(p,1,q)]=result.aic
except:
continue
min_aic=min(aic_values,key=aic_values.get)
#print("min aic:",min_aic)
size = int(len(df) - 15)
train, test = df.iloc[:,i][0:size], df.iloc[:,i][size:len(df)]
#print('\t ARIMA MODEL : In- Sample Forecasting \n')
history = [x for x in train]
predictions = []
for t in range(len(test)):
model = ARIMA(history, order=min_aic)
model.initialize_approximate_diffuse()
model_fit = model.fit()
output = model_fit.forecast()
yhat = output[0]
predictions.append(float(yhat))
obs = test[t]
history.append(obs)
#print('predicted = %f, expected = %f' % (yhat, obs))
wmape = sum(abs(test-predictions).values)/(sum(test)+0.001)
#print('1-wmape:%.4f'%(1-wmape))
error.append(1-wmape)
print(error)
```

附录 5

介绍：该代码是 Python 语言编写的，用于问题一对 6.1~6.15 的预测

```
start_date='20230516'
end_date='20230530'
```

```
date=pd.date_range(start=start_date,end=end_date,freq='D')
d=[]
predict=[]
for i in range(0,len(df.columns)):
    data=df.iloc[:,i]
    #对处理后的数据归一化，打印归一化后的图
    #scaler=MinMaxScaler()
    #scaled_data=pd.DataFrame(scaler.fit_transform(data.values.reshape(-1,1)))
    #通过 AIC 确定 ARIMA 参数，打印原始数据和差分后数据的自相关系数图和偏自相关系数图，打印确定参数后的协差图
    aic_values={}
    for p in range(4):
        for q in range(4):
            try:
                model=ARIMA(scaled_data,order=(p,1,q))
                result=model.fit()
                aic_values[(p,1,q)]=result.aic
            except:
                continue
    min_aic=min(aic_values,key=aic_values.get)
    model=ARIMA(data.astype(float),order=min_aic)
    model.initialize_approximate_diffuse()
    result=model.fit()
    predictions=result.forecast(15)
    for v,time in zip(predictions.values.reshape(-1,1),date):
        predict.append(v)
        d.append(time)
result=pd.DataFrame({'qty':predict,"date":d})
print(result)
result.to_excel('E:/competition/结果 1 预测.xlsx')
zhibiao=pd.DataFrame(error)
zhibiao
zhibiao.to_excel('E:/competition/结果一训练集评价指标 1.xlsx')
```

附录 6

介绍：该代码是 Python 语言编写的，用于对数据的各项变量（指标）数字化

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib.font_manager as mfm
font_path=r'C:/Windows/Fonts/msyh.ttc'
prop = mfm.FontProperties(fname = font_path)
import seaborn as sns
import plotly.express as px
```

```
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score
from statsmodels.tsa.stattools import adfuller
from statsmodels.tsa.arima.model import ARIMA
from sklearn.preprocessing import MinMaxScaler
from statsmodels.graphics.tsaplots import plot_acf,plot_pacf
from statsmodels.stats.diagnostic import acorr_ljungbox
df=pd.read_csv('E:/competition/附件 1-4(合并).csv')
df.head()
columns=['seller_no','product_no','warehouse_no','category3']
for col in columns:
    df[col]=[int(i.split('_')[1]) for i in df[col].values]
df=df.drop(['Unnamed: 0'],axis=1)
df=df.sort_values(by='date').reset_index(drop=True)
df['date']=pd.to_datetime(df['date'])
df
print(df['seller_category'].unique())
print(df['inventory_category'].unique())
print(df['seller_level'].unique())
print(df['category1'].unique())
print(df['category2'].unique())
print(df['category3'].unique())
print(df['warehouse _category'].unique())
print(df['warehouse _region'].unique())
df.replace({
    "category1": {"宠物生活": "1", "美妆护肤": "2", "食品饮料": "3", "家用电器":"4", "电脑、办公": "5", "厨具": "6", "手机通讯": "7", "珠宝首饰": "8", "个人护理":"9", "家装建材": "10", "家庭清洁/纸品":"11", "酒类":"12", "家具": "13", "生活日用":"14", "数码": "15", "鲜花/奢侈品":"16", "玩具乐器":"17", "服饰内衣": "18", "传统滋补":"19","运动户外":"20"},
    "category2": { "猫狗主粮": "1", "面部护肤":"2", "进口食品": "3", "环境电器":"4", "文具": "5", "外设产品": "6", "水具":"7", "手机配件":"8", "游戏设备":"9", "休闲食品":"10", "时尚饰品":"11", "粮油调味":"12", "个护健康":"13", "餐具":"14", "身体护理":"15", "口腔护理":"16", "电工电料":"17", "茗茶":"18", "家庭环境清洁":"19","洋酒":"20", "猫狗医疗保健":"21", "衣物清洁":"22", "电脑整机":"23", "香水彩妆":"24", "烹饪锅具":"25", "发饰":"26", "床类":"27","厨房储物":"28", "厨房卫浴":"29", "洗发护发":"30", "桌类":"31", "沙发类":"32", "家电配件":"33", "猫狗零食":"34", "日用杂货":"35","影音娱乐": "36", "家装软饰":"37", "平台专用类目":"38", "厨房小工具":"39", "身体护肤":"40", "创意减压":"41", "服饰配件":"42", "美发造型":"43","户外玩具/游乐设施":"44", "茶具":"45", "椅类":"46", "厨房小电": "47", "早教/智能玩具":"48", "养生茶饮": "49", "户外家具":"50", "猫狗日用":"51", "饮料冲调":"52", "婚庆节庆":"53","男士面部护肤":"54", "美妆工具":"55", "潮玩/动漫":"56", "烘焙用具":"57", "运动护具":"58", "办公设备":"59", "清洁用具":"60", "火机烟具":"61", "基建材料":"62"},
    "seller_category": {"宠物健康":"1", "食品饮料":"2", "家用电器":"3", "电脑、办公":"4", "手机通讯":"5", "数码":"6", "玩具乐器":"7", "厨具":"8", "美妆护肤":"9", "家装建材":"10","宠物生活":"11", "医疗保健":"12" ,"家具":"13", "个人护理":"14","家居日用":"15","服饰内衣":"16"},
```

```
    "inventory_category": { "A":"1",   "B":"2", "C":"3", "D":"4"},
    "seller_level": {"Large":"1",   "Small":"2", "Special":"3","Medium":"4"},
    "warehouse _category": { "中心仓":"1","区域仓":"2"},
    "warehouse _region": { "华中":"1", "华北" :"2",   "华东":"3","华南": "4","西南":"5","西北
":"6","东北":"7"}
},inplace=True)
df
df.to_excel('E:/competition/附件 1（数字化指标）.xlsx')
df=pd.read_excel('E:/competition/附件 1（数字化指标）.xlsx')
```

附录 5

介绍：该代码是 Python 语言编写的，用于问题一对 6.1~6.15 的预测

```
start_date='20230516'
end_date='20230530'
date=pd.date_range(start=start_date,end=end_date,freq='D')
d=[]
predict=[]
for i in range(0,len(df.columns)):
    data=df.iloc[:,i]
    #对处理后的数据归一化，打印归一化后的图
    #scaler=MinMaxScaler()
    #scaled_data=pd.DataFrame(scaler.fit_transform(data.values.reshape(-1,1)))
    #通过 AIC 确定 ARIMA 参数，打印原始数据和差分后数据的自相关系数图和偏自相关系
数图，打印确定参数后的协差图
    aic_values={}
    for p in range(4):
        for q in range(4):
            try:
                model=ARIMA(scaled_data,order=(p,1,q))
                result=model.fit()
                aic_values[(p,1,q)]=result.aic
            except:
                continue
    min_aic=min(aic_values,key=aic_values.get)
    model=ARIMA(data.astype(float),order=min_aic)
    model.initialize_approximate_diffuse()
    result=model.fit()
    predictions=result.forecast(15)
    for v,time in zip(predictions.values.reshape(-1,1),date):
        predict.append(v)
        d.append(time)
result=pd.DataFrame({'qty':predict,"date":d})
print(result)
result.to_excel('E:/competition/结果 1 预测.xlsx')
```

```
zhibiao=pd.DataFrame(error)
zhibiao
zhibiao.to_excel('E:/competition/结果一训练集评价指标 1.xlsx')
```

附录 8

介绍：该代码是 Python 语言编写的，用于对数据集各组合数理特征指标的 K-means 聚类和主成分分析

```
x=pd.read_excel('E:/competition/数字化指标.xlsx')
biaoqian=x['biaoqian'].str.split('-',expand=True)
biaoqian.to_excel('E:/competition/固定三个指标数字化.xlsx')
x=pd.read_excel('E:/competition/有效数字化指标.xlsx')
#数据标准化
from sklearn.preprocessing import scale, StandardScaler, normalize
from sklearn.cluster import KMeans
scaler = StandardScaler()
x=scaler.fit_transform(x)
x
from sklearn.cluster import KMeans
cluster_def = range(2,30)
inertia =[]
for f in cluster_def:
    kmeans = KMeans(n_clusters=f, random_state=0)
    kmeans = kmeans.fit(x)
    u = kmeans.inertia_
    inertia.append(u)
    print("The inertia for :", f , "Cluster is : " , u)
#画出碎石图（手肘法）
fig = plt.figure(figsize =(16,8))
ax7=fig.add_subplot(111)
#xx = np.arange(len(cluster_def))
x1x=range(2,30,1)
ax7.plot(x1x, inertia,marker='o')
ax7.set_xticks(x1x)
#ax7.set_xticklabels(cluster_def, rotation ="vertical")
plt.xlabel("聚类数（簇）",fontsize=12,fontproperties=prop)
plt.ylabel("样本距离最近的聚类中心的总和",fontsize=12,fontproperties=prop)
plt.title("每个 k 下的聚类距离（碎石图）",fontsize=20,fontproperties=prop)
plt.savefig('E:/competition/有效数字化指标五类的碎石图.jpg',dpi=1150)
kmeans_mod = KMeans(n_clusters=5, random_state=540)
kmeans_mod.fit(x)
x['cluster'] = kmeans_mod.labels_
x.head()
x['cluster'].value_counts()
from sklearn.decomposition import PCA
```

```
pca_mod = PCA(n_components=5)
pca_mod.fit(x)
exp_variance = np.insert(pca_mod.explained_variance_ratio_, 0, 0)       #将向量插入某一行或列
# plot the explained variance
fig= plt.figure(figsize=(8, 5))

plt.plot(np.cumsum(exp_variance),marker='v')
plt.xticks(range(0,6))
plt.xlabel("主成分数", size=13)
plt.ylabel("累积方差贡献度", size=13)
plt.title("累积方差贡献度", size=20)
plt.rcParams['font.sans-serif']=['SimHei']#legend 里面 labels 有中文
plt.rcParams['axes.unicode_minus']=False
plt.savefig('E:/competition/有效数字化指标五类的累计方差贡献度.jpg',dpi=1150)
pca_mod = PCA(n_components=2)
data_pca = pd.DataFrame(data=pca_mod.fit_transform(x),
                                    columns=['PC1', 'PC2'])
data_pca.head()
# 各成分的重要性（载荷矩阵、特征向量）
fig = plt.figure(figsize=(8, 5))
sns.heatmap(pd.DataFrame(pca_mod.components_).transpose(),annot=True,xticklabels=['PC1',
'PC2'],yticklabels=x.columns)
plt.title('影响每个主成分方差的重要特征', fontsize=20,fontproperties=prop)
#plt.savefig('E:/competition/有效数字化指标五类的影响各主成分方差的重要特征.jpg',dpi=1150)
# 组合数据（主成分得分）
x.reset_index(drop=True, inplace=True)
data_pca.reset_index(drop=True, inplace=True)
plot_data = pd.concat([data_pca, x['cluster']], axis=1)
plot_data
plt.figure(figsize = (16,8))
sns.relplot(data=plot_data,x='PC1',y=range(0,1996),hue='cluster',palette='Set1')
plt.savefig('E:/competition/有效数字化指标 PC1 聚类效果展示.jpg',dpi=1150)
plt.figure(figsize = (16,8))
sns.relplot(data=plot_data,x=range(0,1996),y='PC2',hue='cluster',palette='Set1')
plt.savefig('E:/competition/有效数字化指标 PC2 聚类效果展示.jpg',dpi=1150)
```

附录 9

介绍：该代码是 Python 语言编写的，用于对问题三“双 11”期间各天的出货量的可视化

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
```

```
import seaborn as sns
from datetime import datetime
pd.options.display.float_format = '{:.2f}'.format
from itertools import combinations
from sklearn.metrics import mean_absolute_error
from sklearn.metrics import mean_squared_error
from statsmodels.tsa.stattools import adfuller
from statsmodels.tsa.stattools import acf, pacf
from statsmodels.tsa.arima_model import ARIMA as ARIMA
import statsmodels.api as sm
import statsmodels.tsa.api as smt
from pylab import mpl
# mpl.rcParams['font.sans-serif'] = ['SimHei']
mpl.rcParams['font.sans-serif'] = ['Microsoft YaHei']
mpl.rcParams['axes.unicode_minus'] = False
x6=pd.read_excel('E:/competition/附件 6-促销期间商家出货量表.xlsx')
xq=x6.groupby(['date'])['qty'].sum()
xq=pd.DataFrame(xq)
xq.columns=[u'出货量（需求量）']
xq.plot(kind='line',figsize=(12,8),marker='o')
plt.title("“双 11”出货量各天（需求量）展示",fontsize=20,fontproperties=prop)
plt.xlabel("日期",fontsize=12,fontproperties=prop)
plt.ylabel("出货量",fontsize=12,fontproperties=prop)
plt.savefig('E:/competition/“双 11”各天出货量（需求量）展示.jpg',dpi=1150)
###开门红、主题日、狂欢日
```

附录 10

介绍：该代码是 Python 语言编写的，用于对“双 11”期间各分区（开门红、主题日、狂欢日）各种类商品出货量的可视化

```
df=pd.read_excel('E:/competition/附件 1label.xlsx')
df=df.T
df=df.set_axis(df.iloc[0],axis=1,inplace= False)
df=df.drop(df.index[0])
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib.font_manager as mfm
font_path=r'C:/Windows/Fonts/msyh.ttc'
prop = mfm.FontProperties(fname = font_path)
import seaborn as sns
import plotly.express as px
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score
from statsmodels.tsa.stattools import adfuller
```

```
from statsmodels.tsa.arima.model import ARIMA
from sklearn.preprocessing import MinMaxScaler
from statsmodels.graphics.tsaplots import plot_acf,plot_pacf
from statsmodels.stats.diagnostic import acorr_ljungbox
import plotly.express as px
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score
from statsmodels.tsa.stattools import adfuller
from statsmodels.tsa.arima.model import ARIMA
from sklearn.preprocessing import MinMaxScaler
from statsmodels.graphics.tsaplots import plot_acf,plot_pacf
from statsmodels.stats.diagnostic import acorr_ljungbox
x11_11=pd.read_excel('E:/competition/11_11.xlsx')
x11_11.set_index(['category1'],inplace=True)
x11_11.rename(columns={'11.1.1':'11.10'})
from pylab import *
mpl.rcParams['font.sans-serif'] = ['SimHei']
for i in range(3):
    x11_11.iloc[0:,i].plot(kind='line',figsize=(12,8))
    plt.show
    plt.legend()
    plt.xticks(range(20),x11_11.index,rotation=60)
    plt.title("“双 11”前三天各种类销售趋势【开门红】',fontsize=20)
plt.savefig('E:/competition/“双 11”前三天各种类销售趋势【开门红】.jpg',dpi=1150)
from pylab import *
mpl.rcParams['font.sans-serif'] = ['SimHei']
for i in range(3,9):
    x11_11.iloc[0:,i].plot(kind='line',figsize=(12,8))
    plt.show
    plt.legend()
    plt.xticks(range(20),x11_11.index,rotation=60)
    plt.title("“双 11”4-9 号各种类销售趋势【主题日】',fontsize=20)
plt.savefig('E:/competition/“双 11”4-9 号各种类销售趋势【主题日】.jpg',dpi=1150)
from pylab import *
mpl.rcParams['font.sans-serif'] = ['SimHei']
for i in range(9,11):
    x11_11.iloc[0:,i].plot(kind='line',figsize=(12,8))
    plt.show
    plt.legend()
    plt.xticks(range(20),x11_11.index,rotation=60)
    plt.title("“双 11”后三天各种类销售趋势【狂欢日】',fontsize=20)
plt.savefig('E:/competition/“双 11”后三天各种类销售趋势【狂欢日】.jpg',dpi=1150)
```

附录 11

介绍：该代码是 Python 语言编写的，用于对“双 11”期间各天各种类商品出货量较正常时间的平均出货量的比例的可视化

```
x11_11_1=pd.read_excel('E:/competition/T3prop.xlsx')
x11_11_1=x11_11_1.T
x11_11_1.columns=['宠物生活', '厨具', '传统滋补', '电脑、办公', '服饰内衣', '个人护理', '家具', '家庭清洁/纸品', '家用电器',
       '家装建材', '酒类', '美妆护肤', '生活日用', '食品饮料', '手机通讯', '数码', '玩具乐器', '鲜花/奢侈品',
       '运动户外', '珠宝首饰']
x11_11_1
from pylab import *
mpl.rcParams['font.sans-serif'] = ['SimHei']
for i in range(20):
    x11_11_1.iloc[:,i].plot(kind='line',figsize=(12,8))
    plt.legend(loc='upper left')
    plt.xticks(range(1,12),x11_11_1.index,rotation=60)
    plt.title("“双 11”各天各商品种类较正常销售的出货比例",fontsize=20)
plt.savefig('E:/competition/“双 11”各天各商品种类较正常销售的出货比例.jpg',dpi=1150)
```

附录 12

介绍：该代码是 Python 语言编写的，用于对问题三的 ARIMA 预测

```
start_date='20230516'
end_date='20230620'
date=pd.date_range(start=start_date,end=end_date,freq='D')
d=[]
predict=[]
for i in range(0,len(df.columns)):
    data=df.iloc[:,i]
    #对处理后的数据归一化，打印归一化后的图
    #scaler=MinMaxScaler()
    #scaled_data=pd.DataFrame(scaler.fit_transform(data.values.reshape(-1,1)))
    #通过 AIC 确定 ARIMA 参数，打印原始数据和差分后数据的自相关系数图和偏自相关系数图，打印确定参数后的协差图
    aic_values={}
    for p in range(4):
        for q in range(4):
            try:
                model=ARIMA(scaled_data,order=(p,1,q))
                result=model.fit()
                aic_values[(p,1,q)]=result.aic
            except:
                continue
    min_aic=min(aic_values,key=aic_values.get)
```

```
        model=ARIMA(data.astype(float),order=min_aic)
        model.initialize_approximate_diffuse()
        result=model.fit()
        predictions=result.forecast(36)
        for v,time in zip(predictions.values.reshape(-1,1),date):
            predict.append(v)
            d.append(time)
result1=pd.DataFrame({'qty':predict,"date":d})
print(result1)
result1.to_excel('E:/competition/结果 3 预测.xlsx')
```

附录 13

介绍：该代码是 R 语言编写的，用于对给出的附件 1~4 进行合并（将所有特征汇总在一张表格中）

```
library(readxl)
library(dplyr)
library(reshape2)
library(tidyr)
library(openxlsx)
x1<-read_xlsx('E:/competition/附件 1-商家历史出货量表.xlsx')
x1$date<-as.Date(x1$date)
x2<-read_xlsx('E:/competition/附件 2-商品信息表.xlsx')
x3<-read_xlsx('E:/competition/附件 3-商家信息表.xlsx')
x4<-read_xlsx('E:/competition/附件 4-仓库信息表.xlsx')
x5<-read_xlsx('E:/competition/附件 5-新品历史出货量表.xlsx')
x6<-read_xlsx('E:/competition/附件 6-促销期间商家出货量表.xlsx')
summary(x1)
x<-left_join(x1,x2,by='product_no')
x<-left_join(x,x3,by='seller_no')
x<-left_join(x,x4,by='warehouse_no',relationship='many-to-many')
x<-x[,c(1,9,10,11,2,6,7,8,3,12,13,4,5)]
write.xlsx(x,file='E:/competition/附件 1-4(合并).xlsx')
```

附录 14

介绍：该代码是 R 语言编写的，用于对结果一的预测值表格的数据处理

```
###结果一处理
res1<-read_xlsx('E:/competition/附件 1label.xlsx',col_names =F)
re1<-res1[2:1824,1]
re1<-rep(re1$...1,each=15)
re1<-as.data.frame(re1)
res1<-read_xlsx('E:/competition/结果 1 预测.xlsx')
res1<-cbind(re1,res1)
res1<-res1[,c(1,3,4)]
```

```
write.xlsx(res1,'E:/competition/结果 1 预测.xlsx')
###1-wmape 新
ress1<-read_xlsx('E:/competition/结果一训练集评价指标 1.xlsx')
rs1<-read_xlsx('E:/competition/附件 1label.xlsx',col_names =F)
r1<-as.data.frame(rs1[2:1824,1])
ress1<-cbind(r1,ress1)
ress1<-ress1[,c(1,3)]
colnames(ress1)<-c('标签','1-wmape')
write.xlsx(ress1,'E:/competition/结果 1 评价指标 1.xlsx')
```

附录 15

介绍：该代码是 R 语言编写的，用于对结果一的聚类数据表格的处理

```
####问题一聚类表格处理
zhibiao<-read_xlsx('E:/competition/数字化指标.xlsx')
biaoqian<-read_xlsx('E:/competition/固定三个指标数字化.xlsx')
biaoqian<-biaoqian[,c(2,3,4)]
colnames(biaoqian)<-c('seller_no','product_no','warehouse_no')
zhibiao<-zhibiao[,c(2,3,4,5,6,7,8,9,11,12,13,14,15,16,17)]
label<-cbind(biaoqian,zhibiao)
write.xlsx(label,'E:/competition/有效数字化指标.xlsx')
```

附录 16

介绍：该代码是 R 语言编写的，用于对结果三的数据表格的处理

```
###结果三处理
res1<-read_xlsx('E:/competition/附件 1label.xlsx',col_names =F)
re1<-res1[2:1824,1]
re1<-rep(re1$...1,each=36)
re1<-as.data.frame(re1)
res1<-read_xlsx('E:/competition/结果 3 预测.xlsx')
res1<-cbind(re1,res1)
res1<-res1[,c(1,3,4)]
write.xlsx(res1,'E:/competition/结果 3 预测.xlsx')
```